



UNIVERSIDADE FEDERAL DA PARAÍBA

Programa de Pós-Graduação em Modelos de Decisão e Saúde

Sistema de Suporte ao Diagnóstico de Psoríase usando Aprendizado de Máquina

GUILHERME VIEIRA MUNIZ

João Pessoa
2026

GUILHERME VIEIRA MUNIZ

Sistema de Suporte ao Diagnóstico de Psoríase usando Aprendizado de Máquina

UNIVERSIDADE FEDERAL DA PARAÍBA
Programa de Pós-Graduação em Modelos de Decisão e Saúde

Orientador: Profª. Dra. Esther Bastos Palitot de Brito
Coorientador: Prof. Zildomar Carlos Féliz

João Pessoa
2026

1 AGRADECIMENTOS

Agradeço, primeiramente, à minha esposa pelo apoio, pela compreensão e pelo incentivo ao longo de toda esta trajetória. A conclusão deste trabalho representa não apenas o encerramento de uma importante etapa acadêmica, mas também o resultado do suporte recebido durante os desafios e aprendizados vivenciados ao longo do mestrado.

À minha orientadora, Profa. Esther Bastos Palitot de Brito, agradeço pela orientação, pela disponibilidade, pelas contribuições acadêmicas e pelo acompanhamento durante o desenvolvimento desta dissertação. Suas considerações foram fundamentais para o amadurecimento deste trabalho e para minha formação no Programa de Pós-Graduação em Modelos de Decisão e Saúde.

Ao Prof. Ronei Marcos de Moraes, registro meu sincero agradecimento pela orientação recebida ao longo do mestrado. Sua participação em minha trajetória acadêmica, suas contribuições, ensinamentos e direcionamentos foram importantes para a construção e o desenvolvimento desta pesquisa.

Ao Prof. Zildomar Carlos Féliz, que passou a integrar formalmente a orientação deste trabalho após esse processo, agradeço pela disponibilidade em assumir essa responsabilidade e pelas contribuições oferecidas para a conclusão desta etapa.

Aos professores do Programa de Pós-Graduação em Modelos de Decisão e Saúde da Universidade Federal da Paraíba (PPGMDS/UFPB), agradeço pelos conhecimentos compartilhados, pelas discussões e pelas experiências acadêmicas que contribuíram para minha formação científica e profissional.

Aos colegas do Programa, agradeço pelas trocas de experiências, pelo companheirismo e pelas discussões que, direta ou indiretamente, contribuíram para o desenvolvimento desta pesquisa e tornaram essa trajetória mais enriquecedora.

Ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), agradeço pela concessão da bolsa de estudos que proporcionou suporte durante minha formação no mestrado e contribuiu para a realização desta pesquisa.

Por fim, agradeço a todas as pessoas que, de alguma maneira, estiveram presentes nesta trajetória e contribuíram para que este trabalho pudesse ser concluído.

SUMÁRIO

1 AGRADECIMENTOS . . . 2

Resumo . . . 9

Abstract . . . 10

2 INTRODUÇÃO . . . 11
2.1 Contextualização do problema . . . 11
2.2 Relevância científica . . . 13
2.3 Objetivos do trabalho . . . 14

3 REVISÃO DA LITERATURA . . . 15
3.1 Psoríase: aspectos clínicos e epidemiológicos . . . 16
3.2 Diagnóstico diferencial e desafios . . . 18
3.3 Machine learning em dermatologia . . . 19
3.4 Redes neurais convolucionais . . . 22
3.5 Transferência de aprendizado . . . 25
3.6 Explicabilidade e interpretabilidade dos modelos . . . 25
3.6.1 Grad-CAM . . . 26
3.6.2 LIME . . . 26
3.6.3 SHAP . . . 26
3.6.4 Apresentação e leitura conjunta . . . 26
3.7 Trabalhos relacionados . . . 27

4 MATERIAIS E MÉTODOS . . . 30
4.1 Desenho do estudo e fluxo de desenvolvimento . . . 30
4.2 Base de imagens e preparação dos conjuntos . . . 30
4.3 Pré-processamento e aumento de dados . . . 31
4.4 Arquiteturas comparadas . . . 32
4.4.1 MobileNetV2 . . . 32
4.4.2 MobileNetV3 Small: ampliação da família móvel . . . 32
4.4.3 ShuffleNetV2 x1.0: eficiência além do número de operações . . . 32
4.4.4 EfficientNet-B0: modelo-base de uma família escalável . . . 33
4.4.5 ResNet18 e DenseNet121: referências de comparação . . . 33
4.5 Treinamento, repetição e seleção . . . 34
4.6 Métricas classificatórias . . . 34
4.7 Medição de tempo e recursos computacionais . . . 35

4.8 Protocolo de explicabilidade . . . 36
4.9 Ambiente e rastreabilidade . . . 36
4.10 Aspectos éticos e âmbito de uso . . . 36

5 RESULTADOS . . . 38
5.1 Cobertura experimental e seleção . . . 38
5.2 Desempenho classificatório . . . 38
5.3 Complexidade, tempo e memória . . . 39
5.4 Matrizes de confusão dos checkpoints representativos . . . 41
5.5 Explicabilidade exploratória . . . 42
5.6 Síntese das entregas . . . 44

6 IMPLEMENTAÇÃO DO SISTEMA ANDROID . . . 45
6.1 Da comparação de modelos ao protótipo . . . 45
6.2 Exportação e equivalência . . . 45
6.3 Importação, autoteste e persistência . . . 47
6.4 Processamento local e apresentação . . . 47
6.5 Medições e organização dos registros . . . 48
6.6 Verificações realizadas e avaliação posterior . . . 48

7 DISCUSSÃO . . . 49
7.1 Contribuição do processo integrado . . . 49
7.2 Seleção preditiva e restrições de implantação . . . 49
7.3 Explicabilidade como instrumento de inspeção . . . 50
7.4 Alcance da evidência e continuidade . . . 50

8 CONCLUSÃO . . . 51

9 TRABALHOS FUTUROS . . . 52

REFERÊNCIAS BIBLIOGRÁFICAS . . . 53

APÊNDICES 56

APÊNDICE A – MANUAL DE UTILIZAÇÃO DO APLICATIVO . 57
A.1 Finalidade e visão geral . . . 57
A.2 Arquivos e requisitos . . . 57
A.2.1 Diferenciar os três pacotes . . . 57
A.2.2 Requisitos do aparelho . . . 58
A.3 Instalação e atualização . . . 58
A.3.1 Primeira instalação . . . 58

A.3.2 Atualizar uma instalação existente 59
A.4 Preparação e exportação no computador 59
A.4.1 Quando esta etapa é necessária 59
A.4.2 Identificar a execução correta 59
A.4.3 Conferir a aprovação 60
A.5 Importação e autoteste no celular 60
A.6 Seleção e preparação da fotografia 61
A.7 Leitura da classificação 62
A.8 Rótulo de referência e repetição da análise 62
A.9 Medição de desempenho 63
A.9.1 Uma execução e benchmark 63
A.9.2 O que está sendo temporizado 63
A.9.3 Memória e condições de comparação 64
A.10 Exportação e leitura do CSV 64
A.10.1 Dicionário dos campos 65
A.11 Solução de problemas 66
A.12 Roteiro de uma sessão documentada 68

APÊNDICE B – REPRODUTIBILIDADE E ORGANIZAÇÃO DOS ARQUIVOS 69
B.1 Identificação do experimento 69
B.2 Estrutura das saídas 69
B.3 Comandos de manutenção 70
B.4 Computador e celular: medidas diferentes 70

APÊNDICE C – RESULTADOS GRÁFICOS COMPLEMENTARES 71

LISTA DE ILUSTRAÇÕES

Figura 1 – Estratégia de levantamento bibliográfico 15
Figura 2 – Subtipos clínicos de psoríase com manifestações características. 17
Figura 3 – Exemplos de dermatoses que compõem o diagnóstico diferencial da psoríase. 18
Figura 4 – Representação esquemática do fluxo de processamento em uma rede neural convolucional, desde a imagem de entrada até a classificação final. 23
Figura 5 – Fluxo do sistema: imagens organizadas e auditadas; comparação de seis CNNs em três sementes; seleção por validação; avaliação e explicabilidade; exportação ONNX; importação e inferência no Android. A avaliação no teste não retroalimenta a seleção da arquitetura. Fonte: elaboração do autor. 30
Figura 6 – Síntese do desempenho classificatório e da latência em CPU para as seis arquiteturas. As barras de variabilidade representam o desvio entre sementes na partição fixa; os tempos são do computador, não do aplicativo Android. Fonte: Autor. 39
Figura 7 – Matrizes de teste de checkpoints escolhidos pela validação. Linhas: classe real; colunas: classe estimada. Os percentuais são calculados por linha, e a escala de cor é comum a todos os painéis. Para PSOR como classe positiva, a célula superior direita indica falsos positivos e a inferior esquerda, falsos negativos. Fonte: Autor. 41
Figura 8 – Comparação exploratória de Original, LIME, SHAP e Grad-CAM para a EfficientNet-B0, semente 2026. Todas as explicações têm alvo PSOR. LIME e SHAP representam contribuições positivas e negativas; Grad-CAM representa contribuição positiva ao logit. As escalas são normalizadas por mapa. Informar em cada linha a classe real, a classe estimada, a pontuação PSOR, o R^2 local do LIME e o status do Grad-CAM. Fonte: saídas do experimento V5. 43
Figura 9 – Organização do protótipo: no computador, checkpoint PyTorch e exportação validada; no aparelho, importação do ZIP, autoteste, seleção de imagem, pré-processamento, sessão ONNX Runtime em CPU e apresentação do resultado; exportação local de medições em CSV. Fonte: elaboração do autor. 46

Figura 10 – Tela real do aplicativo após importação: arquitetura, indicação de CPU e quatro threads, tempo de carregamento e mensagem Autoteste OK. Ocultar notificações e informações pessoais do aparelho. Fonte: captura do protótipo. 61
Figura 11 – Exemplo autorizado de preparação da fotografia e sua visualização no aplicativo. Indicar orientação e enquadramento antes da seleção; não representar um recorte automático inexistente. Fonte: elaboração do autor e captura do protótipo. 61
Figura 12 – Duas capturas reais, uma por classe estimada, mostrando a imagem, a pontuação e a mensagem associada. Usar exemplos autorizados; identificar claramente os resultados como saídas experimentais. Fonte: capturas do protótipo. 62
Figura 13 – Tela após um benchmark real, destacando mediana de trinta inferências, leitura, pré-processamento, pico observado de PSS e quantidade de registros. Não inserir tempos ilustrativos como resultados medidos. Fonte: captura do protótipo. 64
Figura 14 – Exportação concluída e exemplo de cabeçalhos de um CSV real, mostrando modelo, versão, modo e métricas. Ocultar caminhos pessoais e não apresentar dados fictícios como medições. Fonte: captura do fluxo e arquivo exportado. 65
Figura 15 – Síntese de tempo e memória no computador. As definições dos relógios e de RSS estão nos métodos; não são medições de bateria ou do processo Android. Fonte: Autor. 71
Figura 16 – Curvas ROC de teste dos checkpoints representativos escolhidos pela validação. AUCs individuais não devem ser confundidas com médias entre sementes. Fonte: Autor. 72
Figura 17 – Evolução de validação dos checkpoints apresentados pelo relatório. O checkpoint de cada execução é determinado pela menor perda de validação. Fonte: Autor. 73

LISTA DE TABELAS

Tabela 1 – Caracterização geral dos estudos incluídos (n=36) 20
Tabela 2 – Linha do tempo de modelos de ML aplicados à predição de severidade da psoríase (Adaptado de McMullen et al., 2025). 21
Tabela 3 – Distribuição efetiva da base utilizada nas 18 execuções V5 31
Tabela 4 – Implementações pré-treinadas utilizadas no protocolo V5 33
Tabela 5 – Desempenho no teste: média e desvio-padrão entre as três sementes . . 38
Tabela 6 – Complexidade e tempos em CPU: cada resumo de latência é agregado entre sementes 40
Tabela 7 – Picos observados de RSS do processo Python 40
Tabela 8 – Contagens de teste dos checkpoints representativos escolhidos pela validação 41
Tabela 9 – Indicadores da explicabilidade: alvo PSOR nos quatro exemplos 42

RESUMO

A psoríase é uma doença inflamatória crônica cuja identificação em imagens clínicas constitui um problema relevante para o desenvolvimento de ferramentas de apoio à decisão. Este trabalho apresenta um processo integrado de organização dos dados, comparação de redes neurais convolucionais, análise exploratória de explicabilidade e implementação de um protótipo Android com inferência local. Foram utilizadas 798 imagens, distribuídas em treinamento (558), validação (118) e teste (122), com 386 imagens de psoríase e 412 de condições não psoriáticas. Foram comparadas MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0, EfficientNet-B0, ResNet18 e DenseNet121 em três sementes, totalizando 18 execuções em CPU. A arquitetura foi selecionada pelo maior F1 médio de validação, com AUC média como desempate. A EfficientNet-B0 foi selecionada e apresentou, no teste, F1 de $0{,}919 \pm 0{,}023$ e AUC de $0{,}974 \pm 0{,}010$. A MobileNetV2 apresentou F1 de $0{,}918 \pm 0{,}018$ e menor latência mediana, enquanto a MobileNetV3 Small teve a menor latência entre as redes avaliadas. Grad-CAM, LIME e SHAP produziram saídas exploratórias para quatro imagens, acompanhadas de indicadores de execução e fidelidade local. O checkpoint EfficientNet-B0 da semente 2026 foi exportado para ONNX; a comparação em 122 imagens apresentou erro absoluto máximo de $1{,}7285347 \times 10^{-6}$ e preservou as decisões classificatórias. O protótipo permite importar o modelo em ZIP, analisar imagens no aparelho, medir tempo e memória e exportar registros em CSV. A contribuição compreende a comparação reprodutível, a documentação dos custos computacionais e a integração funcional do modelo ao aplicativo. Os resultados caracterizam uma avaliação interna e uma prova de integração técnica; a validação clínica e a avaliação quantitativa em diferentes celulares constituem etapas posteriores.

Palavras-chave: Psoríase; Redes Neurais Convolucionais; Eficiência Computacional; Explicabilidade; Inferência Local.

ABSTRACT

Psoriasis is a chronic inflammatory disease whose identification in clinical images is relevant to the development of decision-support tools. This study presents an integrated workflow for data organization, convolutional neural network comparison, exploratory explainability analysis, and implementation of an Android prototype with on-device inference. The dataset comprised 798 images, divided into training (558), validation (118), and test (122) sets, with 386 psoriasis images and 412 non-psoriatic images. MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0, EfficientNet-B0, ResNet18, and DenseNet121 were compared using three random seeds, totaling 18 CPU runs. Architecture selection used the highest mean validation F1, with mean validation AUC as a tie-breaker. EfficientNet-B0 was selected and achieved a test F1 of 0.919 ± 0.023 and AUC of 0.974 ± 0.010. MobileNetV2 achieved a test F1 of 0.918 ± 0.018 with lower median latency, whereas MobileNetV3 Small had the lowest latency among the evaluated networks. Grad-CAM, LIME, and SHAP were applied to four images, with execution status and local fidelity reported. The EfficientNet-B0 checkpoint from seed 2026 was exported to ONNX; comparison on 122 images yielded a maximum absolute error of 1.7285347×10^{-6} and preserved classification decisions. The prototype supports ZIP model import, on-device image analysis, time and memory measurement, and CSV export. Contributions include a reproducible comparison, documentation of computational costs, and functional integration of the selected model into the application. Findings represent internal evaluation and a technical integration proof of concept; clinical validation and quantitative assessment across smartphones remain subsequent stages.

Keywords: Psoriasis; Convolutional Neural Networks; Computational Efficiency; Explainability; On-device Inference.

2 INTRODUÇÃO

2.1 CONTEXTUALIZAÇÃO DO PROBLEMA

A psoríase é uma condição inflamatória crônica que acomete a pele, afetando entre 2% e 3% da população mundial. Essa doença tem um impacto significativo na qualidade de vida dos pacientes, devido aos sintomas físicos debilitantes e às repercussões emocionais e sociais. Clinicamente, manifesta-se por placas eritematosas cobertas por escamas prateadas, que geralmente surgem em regiões como cotovelos, joelhos, couro cabeludo e área lombar(BRASIL, 2021; SILVA; SILVA, 2007).

Como uma doença imunomediada e de caráter sistêmico, a psoríase pode ser desencadeada por uma combinação de fatores genéticos e ambientais. Embora não seja contagiosa, a condição apresenta um curso cíclico, alternando entre períodos de exacerbação e remissão. Além dos sintomas dermatológicos, os pacientes frequentemente enfrentam desafios emocionais significativos, incluindo estigmatização, ansiedade e baixa autoestima, particularmente quando as lesões envolvem áreas expostas, como rosto, mãos e unhas, ou regiões sensíveis, como os genitais.

O diagnóstico da psoríase é predominantemente clínico, fundamentado na inspeção das lesões características. Contudo, a identificação pode ser desafiadora em casos mais sutis ou atípicos, como quando não apresentam o aspecto clássico de placas bem delimitadas com escamas espessas, quando acometem regiões de difícil avaliação clínica, como couro cabeludo, unhas, genitais e dobras cutâneas, ou ainda quando se confundem com outras dermatoses inflamatórias frequentes, como dermatite atópica, dermatite seborreica, micose e líquen plano. Essas situações tendem a aumentar a dificuldade diagnóstica, sobretudo entre médicos não especialistas. Dificuldades como essas abrem espaço para ferramentas diagnósticas automatizadas, que possam complementar a análise clínica, reduzir erros humanos e acelerar a implementação de intervenções terapêuticas eficazes (HAENSSLE et al., 2018; CHRISTOPHERS, 2001).

Nesse contexto, métodos computacionais voltados à análise de imagens, especialmente aqueles baseados em visão computacional e aprendizado de máquina, têm se mostrado promissores para a classificação de imagens médicas (GHORBIAN; GHOBAEI-ARANI; GHORBIAN, 2024; JEONG et al., 2023; MCMULLEN et al., 2025; SCHAFFERT et al., 2024; SHAPIRO et al., 2024). Tradicionalmente, essa tarefa envolve etapas como pré-processamento das imagens, segmentação de regiões de interesse (ROI), extração de características e classificação. Embora essa abordagem seja amplamente empregada, avanços recentes em aprendizado profundo, particularmente por meio de redes neurais convolucionais (*Convolutional Neural Networks* – CNNs), têm permitido automatizar parte

substancial desse fluxo, com ganhos relevantes em métricas como acurácia, sensibilidade, especificidade e F1-score.

Contudo, modelos de aprendizado profundo, em sua formulação original, tendem a apresentar elevada complexidade computacional, demandando maior capacidade de processamento, uso intensivo de memória e, em muitos casos, mecanismos de aceleração computacional. Em dispositivos móveis, essa execução não ocorre nos mesmos moldes de ambientes convencionais de treinamento ou de estações com GPUs dedicadas, mas por meio de mecanismos de inferência embarcada e aceleração, que podem explorar, conforme a plataforma disponível, GPU móvel, NPU, DSP ou interfaces específicas de otimização. Ainda assim, restrições de energia, memória e capacidade de processamento tornam desafiadora a implantação direta de arquiteturas profundas de grande porte em smartphones e outros dispositivos com recursos limitados (OTA et al., 2017; FENG et al., 2019).

Como consequência, o uso de modelos de aprendizado profundo em aplicações móveis exige não apenas arquiteturas leves, mas também estratégias adequadas de implantação (SARKER et al., 2021). Após o treinamento, o modelo precisa ser convertido para formatos otimizados de execução local, integrado ao aplicativo e preparado para utilizar os recursos disponíveis no dispositivo, como CPU, GPU móvel ou unidades específicas de aceleração. Técnicas como poda de parâmetros e compressão podem reduzir o tamanho do modelo, o consumo de memória e o tempo de inferência, favorecendo sua execução em smartphones. Dessa forma, a combinação entre arquiteturas leves e otimizações pós-treinamento contribui para equilibrar desempenho computacional, rapidez de resposta e qualidade preditiva em aplicações móveis de saúde baseadas em aprendizado profundo (WANG et al., 2018).

A popularização dos dispositivos móveis, em especial os smartphones, tem ampliado significativamente o acesso da população a tecnologias de informação e saúde. Esses aparelhos deixaram de ser apenas meios de comunicação e passaram a constituir plataformas multifuncionais com capacidade de processamento local, armazenamento e conectividade sem fio avançada (WANG et al., 2018). Atualmente, smartphones ocupam papel central em ecossistemas digitais conectados e vêm sendo empregados em monitoramento remoto, apoio à decisão clínica e oferta de serviços em saúde.

Essa transformação tecnológica está associada ao avanço de sistemas computacionais sensíveis ao contexto, isto é, aplicações capazes de adaptar seu comportamento com base em informações do ambiente físico, computacional e de uso em que o usuário está inserido (DEY, 2018). Nesse cenário, a Inteligência Artificial (IA), entendida como o campo mais amplo dedicado ao desenvolvimento de sistemas capazes de realizar tarefas associadas à percepção, decisão, aprendizagem e adaptação, abrange subáreas como o aprendizado de máquina (*Machine Learning* – ML) e, mais especificamente, o aprendizado profundo (*Deep Learning*). Essas abordagens têm sido progressivamente incorporadas a aplicativos móveis oferecendo suporte a tarefas como diagnóstico médico, recomendação personalizada

e análise preditiva em tempo real.

A incorporação de sistemas inteligentes a dispositivos móveis no contexto da saúde demanda atenção rigorosa a aspectos éticos, jurídicos e técnicos, sobretudo no que diz respeito à privacidade e proteção de dados sensíveis. Informações clínicas, imagens dermatológicas e metadados coletados por sensores móveis enquadram-se como dados pessoais sensíveis pela Lei Geral de Proteção de Dados (LGPD — Lei nº 13.709/2018), o que impõe obrigações específicas quanto à coleta, tratamento e compartilhamento dessas informações.

Diretrizes internacionais, como o Regulamento Geral sobre a Proteção de Dados da União Europeia (GDPR) (European Union, 2016) e os princípios do *Privacy by Design* (Privacidade desde a Concepção) (CAVOUKIAN, 2009; CAVOUKIAN, 2011), reforçam a importância de incorporar salvaguardas éticas desde as fases iniciais do desenvolvimento tecnológico. Isso inclui práticas de anonimização, registro auditável de decisões algorítmicas, controle de acesso e limitação de finalidade — aspectos centrais para a construção de sistemas confiáveis e socialmente responsáveis.

Embora este estudo não envolva, nesta fase, a coleta direta de dados identificáveis, focando unicamente em aspectos técnicos da tarefa de classificação, é crucial que eventuais aplicações derivadas estejam alinhadas aos princípios de transparência, equidade e justiça algorítmica. Ferramentas diagnósticas baseadas em IA devem ser construídas com vistas à proteção da autonomia do paciente e à integridade das decisões clínicas.

2.2 RELEVÂNCIA CIENTÍFICA

A relevância deste trabalho está na articulação entre desempenho classificatório, custo computacional e implementação de uma ferramenta experimental de apoio à análise dermatológica. A comparação de arquiteturas sob um protocolo comum permite examinar quais redes oferecem alternativas para ambientes com restrições de memória e processamento, sem reduzir a escolha à acurácia isolada. A execução em três sementes, os registros de recursos e a separação entre seleção por validação e avaliação no teste conferem rastreabilidade ao processo.

Na interface entre computação e saúde, a pesquisa produz três entregas complementares: uma avaliação interna de seis CNNs, uma análise exploratória de suas explicações visuais no checkpoint selecionado e um protótipo Android capaz de executar o modelo localmente. O aplicativo amplia o alcance aplicado do estudo ao demonstrar a integração entre o experimento e uma interface de uso, com importação independente dos pesos e exportação de medições. A avaliação assistencial permanece uma etapa própria, que poderá utilizar essa base técnica já implementada.

A inferência local também permite explorar formas de processamento sem envio das fotografias a um servidor. Essa característica é pertinente à pesquisa em saúde digital,

pois reduz a dependência de conectividade para a execução e oferece maior controle sobre o fluxo das imagens. O estudo, assim, contribui com um processo documentado que pode ser ampliado em investigações sobre desempenho em aparelhos, auditoria de explicabilidade e avaliação com profissionais de saúde.

2.3 OBJETIVOS DO TRABALHO

Objetivo geral

Desenvolver e avaliar um sistema experimental de suporte à classificação de imagens de psoríase, integrando a comparação de arquiteturas convolucionais, a análise de eficiência computacional, a explicabilidade exploratória e a implementação de inferência local em um protótipo Android.

Objetivos específicos

- Organizar e auditar uma base de imagens de psoríase e de condições não psoriáticas, mantendo rastreável sua distribuição em treinamento, validação e teste.
- Comparar seis arquiteturas pré-treinadas em três sementes, sob um protocolo comum de ajuste fino e avaliação.
- Avaliar F1 da classe psoríase, sensibilidade, especificidade, AUC, acurácia e concordância, mantendo a seleção da arquitetura restrita à validação.
- Medir tempo de execução, latência, memória do processo, número de parâmetros e tamanho dos checkpoints.
- Aplicar Grad-CAM, LIME e SHAP a uma amostra exploratória do checkpoint selecionado, documentando parâmetros, status e limites de interpretação.
- Exportar o modelo selecionado para ONNX e verificar a equivalência numérica e classificatória em relação ao modelo PyTorch.
- Implementar um aplicativo Android com importação de modelo, inferência local, medição de recursos e exportação em CSV, acompanhado de manual de utilização.

3 REVISÃO DA LITERATURA

Foi conduzida uma revisão sistematizada da literatura, com abordagem descritiva e crítica, para contextualizar aplicações de inteligência artificial à psoríase. Foram considerados estudos de síntese e trabalhos originais sobre classificação de imagens, segmentação, gravidade, resposta terapêutica e dados multimodais. A revisão oferece a fundamentação do experimento computacional; não corresponde a uma nova avaliação clínica dos modelos aqui treinados.

A Figura 1 sintetiza a estratégia de levantamento bibliográfico adotada na revisão da literatura. A busca foi conduzida a partir da combinação de descritores relacionados à psoríase e à inteligência artificial, incluindo termos como *psoriasis*, *artificial intelligence*, *machine learning*, *deep learning* e *systematic review*. As consultas foram realizadas em bases biomédicas e multidisciplinares, como PubMed, Scopus, Embase, Wiley Online Library, Springer e Elsevier, considerando publicações entre 2018 e 2025. A seleção dessas bases priorizou a literatura biomédica, clínica e interdisciplinar, uma vez que o foco central do trabalho está na aplicação de modelos de aprendizado profundo à análise de imagens dermatológicas para apoio ao diagnóstico da psoríase.

Após a aplicação dos critérios de inclusão, foram selecionados estudos que abordavam o uso de inteligência artificial na psoríase em tarefas como classificação de imagens, segmentação de lesões, predição de gravidade, resposta terapêutica e análise multimodal envolvendo dados clínicos e imagens.



Figura 1 – Estratégia de levantamento bibliográfico

Reconhece-se, contudo, que bases especializadas da área de computação, como IEEE Xplore e ACM Digital Library, reúnem publicações relevantes sobre arquiteturas

de aprendizado profundo, visão computacional, computação de borda, inferência em dispositivos móveis e otimização de modelos. Dessa forma, a ausência dessas bases constitui uma limitação da estratégia de busca adotada, especialmente no que se refere ao levantamento de estudos voltados aos aspectos computacionais e de implantação dos modelos. Para mitigar essa limitação, foram consideradas referências complementares sobre arquiteturas leves, inferência embarcada e otimização de modelos, quando diretamente relacionadas aos objetivos técnicos deste estudo.

Foram selecionados 36 estudos dentre 173 registros inicialmente identificados. Os critérios de inclusão abrangeram revisões sistemáticas, revisões narrativas relevantes e estudos originais que aplicavam inteligência artificial à psoríase em tarefas como: (i) classificação de imagens, (ii) segmentação de lesões, (iii) predição de gravidade, (iv) resposta terapêutica e (v) integração de dados clínicos multimodais, incluindo prontuários eletrônicos.

Os dados extraídos dos estudos incluíram: tipo de modelo aplicado, arquitetura utilizada, escopo da aplicação, métricas de desempenho e limitações metodológicas apontadas pelos autores. Entre as arquiteturas e abordagens identificadas, destacaram-se redes neurais convolucionais, modelos baseados em *transformers*, algoritmos fuzzy e estratégias híbridas de classificação e integração de dados.

A análise crítica revelou que, embora as redes neurais convolucionais sejam amplamente empregadas na literatura, observa-se uma tendência crescente na adoção de arquiteturas baseadas em *transformers* e abordagens multimodais, sobretudo em tarefas que combinam imagens clínicas e dados estruturados. Apesar da alta acurácia relatada por diversos estudos, a generalização dos modelos ainda representa uma limitação recorrente, especialmente pela ausência de validações externas, pela baixa diversidade dos conjuntos de dados e pela limitada transparência metodológica quanto à origem e composição das bases utilizadas.

Esses achados fundamentam a comparação de arquiteturas pré-treinadas e a integração a um protótipo móvel. A avaliação considera tanto o desempenho na classificação binária quanto o custo computacional, com a implantação local tratada como uma etapa concreta do desenvolvimento experimental.

3.1 PSORÍASE: ASPECTOS CLÍNICOS E EPIDEMIOLÓGICOS

A psoríase é uma doença inflamatória crônica da pele que apresenta diferentes formas clínicas, as quais podem variar quanto à morfologia das lesões, extensão do acometimento cutâneo e gravidade. Essas variações podem, em determinados contextos clínicos, ser confundidas com outras dermatoses, especialmente a depender da região corporal afetada e do estágio evolutivo das placas eritematosas.

Clinicamente, a forma mais comum é a psoríase em placas (ou psoríase vulgar),

responsável por aproximadamente 75% a 90% dos casos. Caracteriza-se por lesões eritematosas bem delimitadas, recobertas por escamas prateadas, com predileção por regiões como cotovelos, joelhos, couro cabeludo e região lombar. Em alguns casos, pode haver também o acometimento ungueal.

Além da forma em placas, outras variantes clínicas relevantes para a contextualização incluem a psoríase gutata e a psoríase eritrodérmica. A psoríase gutata manifesta-se por múltiplas lesões pequenas, em formato de gotas, frequentemente associadas a infecções estreptocócicas prévias, sendo mais comum em crianças e adultos jovens. Já a psoríase eritrodérmica representa uma forma grave e potencialmente ameaçadora à vida, caracterizada por eritema difuso e descamação generalizada, podendo comprometer a termorregulação e o estado geral do paciente.

Outras manifestações, como acometimento invertido, pustuloso, articular, ungueal e do couro cabeludo, apresentam particularidades clínicas. A Figura 2 contextualiza a diversidade de apresentações, sem definir subclasses aprendidas pelo modelo. O experimento utiliza apenas os rótulos PSOR e NonPsor e não estima desempenho por subtipo (GRIFFITHS; BARKER, 2007).



(a) Psoríase em placas



(b) Psoríase eritrodérmica



(c) Psoríase gutata



(d) Psoríase pustulosa

Figura 2 – Subtipos clínicos de psoríase com manifestações características.

Do ponto de vista fisiopatológico, a psoríase resulta de uma ativação exacerbada da resposta imune inata e adaptativa, com papel central das células T, particularmente Th1, Th17 e Th22. Essa ativação leva à hiperproliferação dos queratinócitos e à inflamação crônica da epiderme. A produção excessiva de citocinas inflamatórias, como TNF-α, IL-17 e IL-23, tem sido alvo de terapias biológicas modernas (LOWES; BOWCOCK; KRUEGER, 2007).

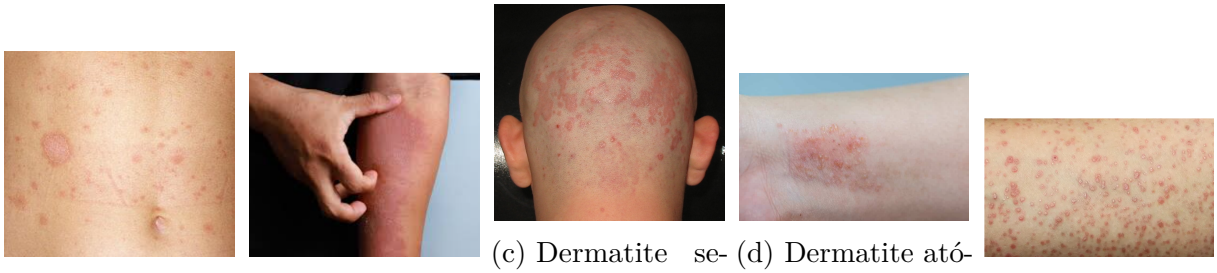
Além dos sintomas dermatológicos, a psoríase está associada a diversas comorbidades sistêmicas, incluindo artrite psoriásica (presente em até 30% dos casos), síndrome metabólica, obesidade, diabetes tipo 2, hipertensão arterial e risco cardiovascular aumentado. Tais associações reforçam seu caráter sistêmico e a necessidade de abordagem multidisciplinar no cuidado ao paciente (BOEHNCKE, 2018; TAKESHITA et al., 2017).

Do ponto de vista epidemiológico, há um predomínio da doença em adultos jovens e de meia-idade, com impacto socioeconômico significativo, especialmente quando associada a quadros graves ou refratários. A carga emocional e o estigma social decorrentes das lesões visíveis são fatores importantes na redução da qualidade de vida, contribuindo para quadros de ansiedade e depressão.

3.2 DIAGNÓSTICO DIFERENCIAL E DESAFIOS

O diagnóstico da psoríase é, na maioria dos casos, clínico, baseado na observação direta das características morfológicas das lesões. Em geral, dermatologistas experientes são capazes de reconhecer a doença com alta acurácia. No entanto, em estágios iniciais ou formas clínicas atípicas, o diagnóstico pode ser dificultado, especialmente por profissionais não especializados (GORELICK et al., 2019).

Um dos principais desafios reside no diagnóstico diferencial com outras dermatoses inflamatórias, como dermatite atópica, dermatite seborreica, líquen plano, pitiríase rósea, eczemas e infecções fúngicas. Muitas dessas condições compartilham sinais clínicos semelhantes, como eritema, descamação e prurido, dificultando a distinção com base apenas no exame físico (HAENSSLE et al., 2018).



(a) Pitiríase rósea (b) Eczema (c) Dermatite seborreica (d) Dermatite atópica (e) Líquen plano

Figura 3 – Exemplos de dermatoses que compõem o diagnóstico diferencial da psoríase.

Além disso, em pacientes com fototipos mais escuros, as manifestações clínicas

podem apresentar características diferentes, como menor eritema e maior hiperpigmentação residual, o que pode impactar a sensibilidade do diagnóstico visual tradicional (DESAI; ALEXIS; JACOBSON, 2020). Em casos duvidosos, a biópsia cutânea pode ser solicitada para confirmação histopatológica. Contudo, esse método é invasivo, pode gerar desconforto ao paciente, e nem sempre é factível em contextos de atenção primária ou em locais com acesso restrito à dermatologia especializada.

Tais desafios reforçam a importância de soluções complementares baseadas em tecnologias assistivas, capazes de apoiar a tomada de decisão clínica. A implementação de sistemas fundamentados em aprendizado de máquina pode desempenhar um papel central na padronização e no aprimoramento do diagnóstico diferencial, especialmente em contextos marcados pela escassez de especialistas (GHORBIAN; GHOBAEI-ARANI; GHORBIAN, 2024; SHAPIRO et al., 2024). Esses modelos são capazes de aprender padrões visuais complexos em imagens de lesões cutâneas, mitigando limitações humanas relacionadas à subjetividade e à variabilidade interobservador. Dessa forma, a inteligência artificial apresenta-se como uma ferramenta promissora para aumentar a acurácia diagnóstica, reduzir o tempo de avaliação clínica e ampliar o acesso ao diagnóstico precoce da psoríase.

3.3 MACHINE LEARNING EM DERMATOLOGIA

Modelos baseados em CNNs são frequentes nas tarefas de classificação por imagem e segmentação de lesões, com estudos relatando acurácias acima de 90% (MCMULLEN et al., 2025; SCHAFFERT et al., 2024). A Tabela 1 apresenta a categorização geral dos estudos, evidenciando que a maioria se concentrou em diagnóstico automático, predição de gravidade e resposta terapêutica. Ao todo, foram selecionados 36 estudos dentre os 173 registros inicialmente identificados. Esse quantitativo foi obtido após a aplicação dos critérios de inclusão e exclusão definidos na estratégia de revisão, contemplando revisões sistemáticas e estudos originais que abordavam o uso de inteligência artificial aplicada à psoríase em tarefas de classificação de imagens, segmentação de lesões, predição de gravidade, resposta terapêutica e integração de dados clínicos multimodais.

Ressalta-se que as categorias apresentadas na Tabela 1 possuem caráter temático e não mutuamente exclusivo. Assim, um mesmo estudo pôde ser classificado em mais de uma categoria quando abordava múltiplas aplicações ou técnicas, como classificação por imagem associada à predição de gravidade, segmentação de lesões ou análise multimodal. Por esse motivo, a soma dos estudos por categoria não corresponde ao número total de estudos incluídos, mas sim à frequência com que cada eixo temático apareceu no conjunto analisado.

Alguns estudos relatam modelos parcimoniosos, notadamente o Fuzzy C-Means combinado com algoritmos de otimização como o Seeker Optimization, que demonstraram alta eficiência com menor demanda computacional (DASH et al., 2022). A escassez

de dados abertos e a sub-representação de fototipos diversos foram lacunas recorrentes apontadas em algumas revisões sobre o tema (YU et al., 2020; GULZAR et al., 2024; RAVIPATI; ELMAN, 2024; LIU et al., 2023)

Tabela 1 – Caracterização geral dos estudos incluídos (n=36)

Categoria	**n**	**Modelos/Técnicas**	**Aplicações principais**
Classificação e diagnóstico por imagem	18	CNN, U-Net, ResNet, DenseNet, Vision Transformers	Diagnóstico automático, segmentação de lesões
Predição de gravidade clínica	12	CNN, Mask R-CNN, Swin Transformer	PASI, BSA, NAPSI
Predição de resposta terapêutica	8	CNN, Gradient Boosting, Multimodal DL	Mudança de terapia, biomarcadores
NLP aplicado a prontuários	3	NLP com LLMs (ex.: ChatGPT-4)	Extração de dados clínicos não estruturados
Modelos parcimoniosos	3	Fuzzy C-Means + Seeker Optimization	Segmentação eficiente de lesões
Revisões sistemáticas e guidelines	12	-	Avaliação crítica e recomendações éticas/regulatórias

A Tabela 2 apresenta uma síntese cronológica de aplicações distintas de IA à psoríase. Entre elas, técnicas de AutoML foram utilizadas para predição de mudança terapêutica, com AUC relatada de 0.9078 (SCHAFFERT et al., 2024).

Tabela 2 – Linha do tempo de modelos de ML aplicados à predição de severidade da psoríase (Adaptado de McMullen et al., 2025).

Ano	**Autor**	**Modelo / Técnica**	**Desempenho / Métricas principais**
2007	Ihtatho *et al.*	Sistema de representação de cores e distância Euclidiana	PASI Escore em 93.8% (30/32 imagens)
2017	Shrivastava *et al.*	Aplicação dos modelos SVM, Arvore de decisão e Rede Neural	Acurácia de classificação 99.84%, confiabilidade de 99.99%
2020	Dash *et al.*	Deep Learning alimentando software para auxiliar profissionais de saúde na detecção e classificação	Acurácia média de 0.9092 e AUC de 0.9886
2022	Lee *et al.*	Cascade mask R-CNN modelo de visão computacional	Acurácia do escore PASI: 95.96%, MAE (1.23% ± 2.34%), Coeficiente de Correlação Intraclasse (0.973; Intervalo de Confiança 95% 0.966–0.979)
2022	Lin *et al.*	U-Net - Arquitetura de rede neural convolucional especialmente projetada para segmentação de imagens, e é amplamente utilizada na área médica	Coeficiente de Correlação Intraclasse do dataset de teste: 0.966 (IC 95% 0.966–0.979)
2024	Schaffert *et al.*	Proposta de AutoML - conjunto de técnicas e ferramentas que automatiza o processo de desenvolvimento de modelos de aprendizado de máquina, desde a preparação dos dados até a avaliação e escolha do melhor modelo.	AUC de 0.9078 para mudanças de terapia e AUC de 0.88 a 0.83 para mudanças no escore PASI.

Note que a Tabela 2 deve ser interpretada como uma síntese cronológica e descritiva dos principais avanços no uso de aprendizado de máquina e inteligência artificial aplicados à psoríase, e não como uma comparação direta de desempenho entre os estudos. Os trabalhos listados diferem quanto ao objetivo da tarefa, ao tipo de dado utilizado, ao tamanho e à composição das bases, às métricas empregadas e ao contexto clínico de aplicação. Enquanto alguns estudos se concentram na classificação ou detecção de lesões, outros abordam a segmentação, a estimativa de escores clínicos como PASI e BSA, ou ainda a predição de resposta terapêutica. Dessa forma, métricas como acurácia, AUC, MAE e coeficiente de correlação intraclasse não devem ser comparadas de maneira direta, pois refletem problemas preditivos distintos. A finalidade da tabela é evidenciar a trajetória de desenvolvimento da área, destacando a diversificação progressiva das técnicas e aplicações.

3.4 REDES NEURAIS CONVOLUCIONAIS

As redes neurais convolucionais, ou *Convolutional Neural Networks* (CNNs), constituem uma das principais arquiteturas de aprendizado profundo aplicadas à análise de imagens, sendo amplamente utilizadas em tarefas de classificação, detecção e segmentação visual (GOODFELLOW, 2016). Diferentemente das redes neurais totalmente conectadas tradicionais, que tratam os pixels de uma imagem como entradas independentes, as CNNs exploram explicitamente a estrutura espacial dos dados visuais, preservando relações locais entre pixels vizinhos. Essa característica torna a arquitetura especialmente adequada para imagens médicas, nas quais padrões morfológicos, texturas, bordas e variações cromáticas carregam informações diagnósticas relevantes (HAMMAD et al., 2023).

Do ponto de vista computacional, uma imagem digital pode ser representada como um tensor tridimensional $X \in R^{H \times W \times C}$, em que H corresponde à altura, W à largura e C ao número de canais da imagem. Em imagens RGB, por exemplo, $C = 3$, representando os canais vermelho, verde e azul. No caso deste estudo, as imagens dermatológicas foram redimensionadas para 224×224 pixels e normalizadas antes de serem fornecidas às arquiteturas avaliadas, garantindo compatibilidade com modelos pré-treinados e estabilidade durante o processo de otimização.

A operação fundamental de uma CNN é a convolução. Nessa etapa, pequenos filtros ou *kernels* aprendíveis percorrem a imagem de entrada e produzem mapas de ativação, nos quais regiões com determinados padrões visuais recebem respostas mais intensas. Formalmente, para uma imagem de entrada X e um filtro K, a convolução bidimensional pode ser representada de forma simplificada por:

$$Y(i, j) = \sum_{m} \sum_{n} X(i + m, j + n)K(m, n),$$

em que $Y(i, j)$ representa o valor do mapa de ativação na posição (i, j), e $K(m, n)$ corresponde aos pesos do filtro convolucional. Durante o treinamento, esses pesos são ajustados automaticamente por retropropagação do erro, permitindo que a rede aprenda quais padrões visuais são mais relevantes para a tarefa de classificação.

Cada filtro convolucional é responsável por detectar um tipo específico de padrão local. Nas primeiras camadas, os filtros tendem a capturar características simples, como bordas, contrastes, orientações e transições de cor. Em camadas intermediárias, passam a representar texturas, formas e regiões lesionais. Nas camadas mais profundas, essas informações são combinadas em representações mais abstratas e semanticamente relevantes para a distinção entre classes. No contexto dermatológico, isso permite que a rede identifique padrões associados à psoríase, como descamação, espessamento, limites das placas, irregularidades texturais e variações eritematosas.

Além dos filtros, outros hiperparâmetros influenciam diretamente o comportamento das camadas convolucionais. O *stride* define o deslocamento do filtro sobre a imagem,

controlando o grau de redução espacial dos mapas de ativação. Já o *padding* consiste na adição de bordas artificiais à imagem, permitindo controlar a preservação das dimensões espaciais após a convolução. Essas escolhas afetam tanto a resolução das representações internas quanto o custo computacional do modelo.

Após a operação de convolução, é comum a aplicação de uma função de ativação não linear, como a ReLU (*Rectified Linear Unit*), definida por:

$$f(x) = \max(0, x).$$

Essa função introduz não linearidade ao modelo, permitindo que a rede aprenda relações complexas entre os padrões visuais da imagem e a classe de interesse. Além disso, a ReLU contribui para reduzir problemas de saturação do gradiente, favorecendo o treinamento de redes profundas.

Outro componente recorrente nas CNNs são as camadas de *pooling*, utilizadas para reduzir a dimensionalidade espacial dos mapas de ativação e aumentar a robustez do modelo a pequenas variações de posição, escala ou orientação. O *max pooling*, por exemplo, seleciona o maior valor dentro de uma janela local, preservando as ativações mais relevantes e reduzindo o volume de dados propagado para as camadas seguintes. Essa redução é importante para diminuir o número de parâmetros, controlar o custo computacional e mitigar o risco de sobreajuste.

A organização típica de uma CNN envolve a combinação sucessiva de camadas convolucionais, funções de ativação e operações de *pooling*. Ao final do processo de extração de características, os mapas de ativação podem ser achatados por meio de uma operação de *flattening* ou sintetizados por *global average pooling*. Em seguida, uma ou mais camadas totalmente conectadas realizam a etapa de decisão, transformando as representações aprendidas em uma saída compatível com a tarefa de classificação.

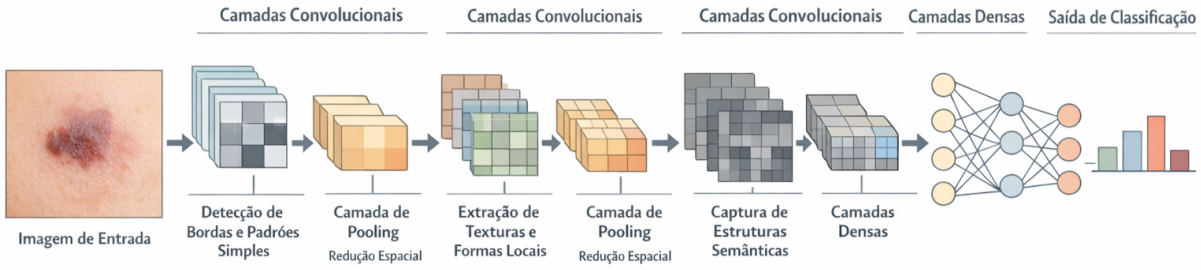


Figura 4 – Representação esquemática do fluxo de processamento em uma rede neural convolucional, desde a imagem de entrada até a classificação final.

No caso da classificação binária entre psoríase e não psoríase, a última camada do modelo produz uma saída escalar, denominada *logit*. Esse valor é posteriormente convertido em probabilidade por meio da função sigmoide:

$$p = \sigma(z) = \frac{1}{1 + e^{-z}},$$

em que z representa o logit produzido pela rede e p a pontuação sigmoide associada à classe positiva, sem calibração clínica. Durante o treinamento, a diferença entre a predição do modelo e o rótulo verdadeiro é quantificada por uma função de perda, como a *Binary Cross-Entropy with Logits*, adotada neste estudo por sua estabilidade numérica em problemas de classificação binária.

No contexto da classificação de lesões dermatológicas, as CNNs são particularmente relevantes porque automatizam a extração de características visuais. Em abordagens clássicas de visão computacional, descritores como SIFT, HOG e SURF precisavam ser definidos manualmente, exigindo decisões heurísticas sobre quais atributos da imagem deveriam ser considerados. Nas CNNs, por outro lado, os filtros são aprendidos diretamente a partir dos dados, reduzindo a dependência de conhecimento técnico manual para a construção de descritores e permitindo a identificação de padrões complexos que podem não ser facilmente perceptíveis ao observador humano.

Essa característica é especialmente importante em imagens de lesões cutâneas, nas quais diferenças sutis de textura, cor, descamação e delimitação das bordas podem ser clinicamente relevantes. No caso da psoríase, a distinção em relação a outras dermatoses inflamatórias, como eczema, dermatite atópica, dermatite seborreica e infecções fúngicas superficiais, pode envolver padrões visuais parcialmente sobrepostos. Assim, as CNNs oferecem uma estratégia promissora para apoiar o diagnóstico diferencial, desde que treinadas com bases suficientemente diversas e avaliadas de forma rigorosa (RAVIPATI; ELMAN, 2024; GHORBIAN; GHOBAEI-ARANI; GHORBIAN, 2024; MCMULLEN et al., 2025).

Apesar de suas vantagens, as CNNs apresentam limitações importantes. Modelos profundos podem demandar grande volume de dados rotulados, elevado poder computacional e maior tempo de treinamento. Além disso, arquiteturas com muitos parâmetros tendem a apresentar maior risco de sobreajuste, especialmente em bases médicas pequenas ou desbalanceadas. Esse aspecto fundamenta a avaliação de custo computacional e a implementação do protótipo móvel neste estudo.

Por esse motivo, a escolha da arquitetura não deve considerar apenas métricas preditivas, como acurácia, F1-score e AUC, mas também aspectos de eficiência, como número de parâmetros, tempo de inferência e custo computacional. Essa preocupação fundamenta a comparação entre MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0, EfficientNet-B0, ResNet18 e DenseNet121, articulando desempenho classificatório e recursos efetivamente medidos no mesmo protocolo.

3.5 TRANSFERÊNCIA DE APRENDIZADO

A transferência de aprendizado reutiliza representações obtidas em uma tarefa anterior para inicializar um novo problema. Em redes convolucionais, filtros aprendidos em bases extensas podem representar padrões visuais elementares, como bordas e texturas, que também participam da análise de imagens dermatológicas. O ajuste supervisionado adapta esses parâmetros à tarefa de interesse, reduzindo a necessidade de iniciar o treinamento a partir de pesos aleatórios (GOODFELLOW, 2016).

Neste trabalho, seis arquiteturas foram inicializadas com pesos ImageNet e tiveram sua última camada de classificação substituída por uma saída escalar. O processo pode ser representado por

$$z = g_\phi(h_\theta(x)), \qquad p_{\mathrm{PSOR}} = \sigma(z) = \frac{1}{1 + e^{-z}},$$

em que x é a imagem normalizada, h_θ é o extrator de características, g_ϕ é a cabeça classificadora e z é o logit. Foi realizado ajuste fino integral: os parâmetros do extrator e da cabeça foram atualizados pela função de perda binária com logits e pelo otimizador Adam.

As arquiteturas empregam estratégias distintas: blocos residuais invertidos na MobileNetV2, refinamentos voltados à eficiência móvel na MobileNetV3 Small, reorganização de canais na ShuffleNetV2, blocos MBConv na EfficientNet-B0, conexões residuais na ResNet18 e conectividade densa na DenseNet121. Suas características e implementações são descritas nos métodos. O uso de um protocolo comum permite comparar essas implementações pré-treinadas, mas não elimina diferenças nas receitas originais de pré-treinamento.

A transferência de aprendizado é uma estratégia adotada neste experimento, e não um ganho isoladamente estimado: não foi executado um grupo equivalente com inicialização aleatória. Dessa forma, os resultados comparam as seis redes ajustadas ao mesmo problema, sem atribuir causalmente suas diferenças ao pré-treinamento.

3.6 EXPLICABILIDADE E INTERPRETABILIDADE DOS MODELOS

As técnicas de explicabilidade pós-hoc auxiliam a inspecionar como o modelo responde à imagem e quais regiões estão associadas à sua saída. Elas complementam as métricas de classificação com uma perspectiva local e visual, útil para examinar contribuições na lesão, no fundo e em eventuais artefatos. No presente estudo, foram empregados Grad-CAM, LIME e SHAP; os três métodos foram configurados para explicar a mesma classe-alvo, PSOR.

3.6.1 Grad-CAM

O Grad-CAM combina ativações convolucionais e gradientes da classe de interesse para produzir uma localização espacial aproximada das contribuições positivas (**??**). Para mapas de ativação A^k e escore z da classe-alvo, a forma adotada é

$$\alpha_k = \frac{1}{Z} \sum_i \sum_j \frac{\partial z}{\partial A_{ij}^k}, \qquad L = \mathrm{ReLU}\left(\sum_k \alpha_k A^k \right).$$

O mapa é ampliado para a dimensão da imagem e normalizado para exibição. A resolução espacial depende da camada escolhida; portanto, a saída não constitui uma segmentação da lesão. Um mapa sem amplitude positiva variável deve ser identificado como tal, sem produzir artificialmente uma região de destaque.

3.6.2 LIME

O LIME aproxima localmente a saída de um classificador por um modelo interpretável ajustado a perturbações da entrada (**??**). Em imagens, regiões são agrupadas em superpixels, perturbadas e avaliadas novamente pelo classificador. Os coeficientes do modelo local indicam contribuições positivas ou negativas para a saída explicada. O R^2 local descreve a fidelidade dessa aproximação nas perturbações utilizadas; não mede acurácia diagnóstica, localização clínica correta ou confiança calibrada na predição. A segmentação, a distribuição das perturbações e o orçamento de amostras influenciam a explicação.

3.6.3 SHAP

O SHAP organiza atribuições aditivas de contribuição para uma predição (**??**). Nesta pesquisa, foi utilizada a aproximação Partition com mascaramento por referência preta e orçamento limitado de avaliações. As contribuições indicam aumento ou redução da saída PSOR em relação a essa referência, de acordo com o procedimento de perturbação. A interpretação depende da referência e da aproximação utilizadas; os valores não correspondem a efeitos causais de estruturas anatômicas.

3.6.4 Apresentação e leitura conjunta

Um painel comparativo deve manter a imagem original, a classe real quando conhecida, a classe estimada, a pontuação PSOR, a arquitetura e o alvo explicado. As colunas podem apresentar Original, LIME, SHAP e Grad-CAM. No LIME e no SHAP, cores de sinais distintos representam contribuições positivas e negativas; no Grad-CAM adotado, o mapa representa contribuição positiva ao logit PSOR.

As escalas visuais são normalizadas por mapa. Por isso, a intensidade de uma cor não deve ser comparada numericamente entre métodos ou imagens. A concordância

visual entre mapas pode orientar inspeções, mas a qualidade clínica da localização requer avaliação própria, preferencialmente com anotações de especialistas. O aplicativo Android desta versão exibe a classificação e as medições; os mapas explicativos permanecem no relatório do computador.

3.7 TRABALHOS RELACIONADOS

Diversos estudos recentes têm demonstrado o potencial do uso de aprendizado de máquina e visão computacional na detecção e classificação da psoríase. Haenssle et al. (2018) foram destaques ao comparar CNNs para diagnóstico de com outros profissionais, e terem sucesso em um desempenho do modelo acima do que foi a performance do grupo de profissionais. Esse resultado impulsionou uma série de investigações subsequentes que passaram a explorar arquiteturas profundas não apenas para detecção de câncer de pele, mas também para doenças inflamatórias crônicas, como a psoríase, cuja avaliação clínica envolve maior subjetividade.

Nesse contexto, Chakraborty et al. apresentaram o CAD-PsorNet, um framework de diagnóstico assistido por computador baseado em redes pré-treinadas como MobileNetV1, VGG16/19 e ResNet50. O estudo demonstrou que arquiteturas mais leves, como a MobileNet, podem alcançar acurácia superior a 99% após ajuste fino e otimização de hiperparâmetros, indicando que modelos compactos podem ser competitivos mesmo em tarefas complexas (CHAKRABORTY et al., 2024). Contudo, os autores destacam que a generalização do modelo permanece dependente da qualidade das imagens e da diversidade do conjunto de treinamento.

Entre os estudos recentes, focados especificamente na psoríase, Milani et al. propuseram uma aplicação de aprendizado profundo comparando arquiteturas clássicas — ResNet50, VGG19 e InceptionV3 — para a classificação de imagens de pele com lesões psoriáticas. Os autores reportaram desempenho superior do modelo InceptionV3, com acurácia e F1-score acima de 97%, sugerindo o potencial dessas redes como ferramentas de apoio ao diagnóstico clínico (MILANI et al., 2025). Apesar dos resultados expressivos, o estudo se baseia em imagens provenientes de plataformas especializadas e não discute aspectos relacionados à variabilidade populacional, diversidade de fototipos ou viabilidade computacional para implantação em ambientes clínicos reais.

A questão da diversidade dos dados — especialmente no que se refere à representação étnica e aos diferentes fototipos de pele — tem sido apontada como uma das principais lacunas da literatura. Gulzar et al. e Yu et al. evidenciam que muitos modelos apresentam queda significativa de desempenho quando aplicados a populações distintas daquelas utilizadas no treinamento, o que levanta preocupações quanto à equidade e à validade clínica dessas soluções. Essa limitação torna-se particularmente crítica em países como o Brasil, caracterizados por alta heterogeneidade populacional e desigualdade no acesso a

especialistas.

Buscando contornar a escassez de bases públicas e a sub-representação de determinados grupos, Tanantong et al. (2025) propuseram o uso combinado de com imagens geradas sintéticas representativas de tons de pele tailandeses. Os autores demonstraram que a incorporação dessa técnica resultou em ganhos significativos de desempenho, com destaque para a EfficientNetB4, que atingiu acurácia de 93% e sensibilidade superior a 91% (TANANTONG et al., 2025). O estudo reforça a importância de estratégias que ampliem a diversidade dos dados, embora permaneça restrito a um cenário experimental controlado e não discuta a implantação em dispositivos de baixa capacidade computacional.

Paralelamente aos estudos voltados à classificação, uma vertente relevante da literatura tem se dedicado à avaliação da severidade da psoríase por meio de aprendizado de máquina. A revisão sistemática conduzida por McMullen et al. (2025) identificou que a maioria das abordagens emprega modelos baseados em imagens para estimar índices clínicos como PASI e BSA, frequentemente alcançando AUCs superiores a 0.90. Apesar dos avanços, os autores ressaltam que os estudos existentes apresentam amostras reduzidas, alta heterogeneidade metodológica e baixa maturidade para aplicação clínica prospectiva (MCMULLEN et al., 2025).

Outro aspecto ainda pouco explorado refere-se à viabilidade computacional dos modelos propostos. Grande parte das pesquisas prioriza métricas clássicas de desempenho, como acurácia e sensibilidade, negligenciando fatores como tamanho do modelo, consumo de memória e tempo de inferência. Alguns autores investigaram explicitamente o compromisso entre resolução de imagem e desempenho em arquiteturas como MobileNet e ResNet18, demonstrando que resoluções intermediárias (128×128) associadas a modelos leves mantêm acurácia acima de 90% com consumo substancialmente menor de recursos, reforçando a adequação dessas soluções para dispositivos móveis e aplicações em saúde digital(HAMMAD et al., 2023; SANVER; KASAPBASI, 2026; ESTUDO, 2026).

De forma geral, a literatura aponta avanços consistentes no uso de CNNs para detecção, classificação e avaliação da psoríase, mas também revela limitações estruturais persistentes: escassez de bases abertas, baixa diversidade populacional, foco excessivo em métricas isoladas de desempenho e pouca atenção à implantação em ambientes com restrições de infraestrutura. Revisões sistemáticas recentes reforçam que a transição dessas soluções para a prática clínica depende não apenas de ganhos incrementais de acurácia, mas da integração entre robustez metodológica, eficiência computacional e usabilidade (JEONG et al., 2023).

Nesse contexto, o presente trabalho se insere ao propor uma abordagem orientada à leveza arquitetural, treinada por um conjunto selecionado de imagens que transmita variações de tons de pele. Ao considerar explicitamente limitações computacionais e cenários de uso com baixa complexidade tecnológica, esta pesquisa busca contribuir para a redução da distância entre modelos experimentais e ferramentas efetivamente utilizáveis

no apoio à decisão clínica em contextos reais. O trabalho também discorre sobre formas de integração em sistemas embarcados não apenas os celulares, priorizando o equilíbrio entre desempenho, eficiência e aplicabilidade.

4 MATERIAIS E MÉTODOS

4.1 DESENHO DO ESTUDO E FLUXO DE DESENVOLVIMENTO

Trata-se de um estudo experimental quantitativo de classificação binária de imagens dermatológicas, acompanhado do desenvolvimento de um protótipo de software. O processo compreendeu a organização e auditoria das imagens, a comparação de seis redes convolucionais, a seleção por validação, a avaliação no teste, a produção de explicações exploratórias e a integração do checkpoint selecionado a um aplicativo Android.

O desenvolvimento foi organizado em dois ambientes. No computador, foram realizados o treinamento, a avaliação, a explicabilidade e a exportação. No celular, o aplicativo executa somente a inferência do modelo já treinado, além de medir recursos e exportar registros. A Figura 5 apresenta essa separação funcional.

Espaço reservado para figura

<pngs/fluxo_integrado_v5.png>

Inserir o arquivo correspondente conforme o guia das figuras.

Figura 5 – Fluxo do sistema: imagens organizadas e auditadas; comparação de seis CNNs em três sementes; seleção por validação; avaliação e explicabilidade; exportação ONNX; importação e inferência no Android. A avaliação no teste não retroalimenta a seleção da arquitetura. Fonte: elaboração do autor.

4.2 BASE DE IMAGENS E PREPARAÇÃO DOS CONJUNTOS

As fontes descritas na organização do acervo incluem PUMCH-ISD[1], acervo clínico privado anonimizado e repositórios dermatológicos, como DermIS[2] e DermPicX[3], além de fontes utilizadas para compor a classe de condições não psoriáticas. Essas informações de procedência devem ser mantidas no inventário original de coleta. O relatório computacional V5 registra classes, arquivos, dimensões e hashes das imagens utilizadas; ele não fornece quantitativos discriminados por instituição de origem, paciente, fototipo ou subtipo clínico.

Foram considerados registros previamente preparados para uso acadêmico, sem coleta prospectiva ou intervenção clínica nesta etapa. A preparação do acervo envolveu

[1] <https://www.kaggle.com/datasets/jcwang10000/pumch-isd>
[2] <https://www.dermis.net/dermisroot/pt/home/index.htm>
[3] <https://www.dermpicx.com/photo-library-tool/>

seleção de imagens e revisão de artefatos visuais. Recortes manuais anteriores ao treinamento pertencem à preparação do acervo; não constituem uma funcionalidade de recorte automático da rede ou do aplicativo. A análise computacional utilizou os rótulos binários disponíveis, sem estimar gravidade, subtipo de psoríase ou diagnóstico específico dentro da classe negativa.

A versão final avaliada contém **798 imagens**: **386 PSOR** e **412 NonPsor**. A Tabela 3 apresenta as contagens efetivamente lidas na execução V5. A divisão já havia sido realizada pelo separador, com proporções aproximadas de 70%, 15% e 15% por classe. A rinha de modelos preservou esses conjuntos durante todas as execuções; as três sementes variaram o treinamento, e não a partição das imagens.

Tabela 3 – Distribuição efetiva da base utilizada nas 18 execuções V5

Conjunto	Psoríase (PSOR)	Não psoríase (NonPsor)	Total
Treinamento	270	288	558
Validação	57	61	118
Teste	59	63	122
Total	386	412	798

Fonte: Relatório final da execução V5.

A classe NonPsor reúne imagens rotuladas como não psoriáticas; ela não equivale necessariamente a pele saudável. A codificação utilizada foi NonPsor = 0 e PSOR = 1, com psoríase definida como classe positiva. O conjunto de teste é aproximadamente equilibrado entre as classes.

Antes do treinamento, foram verificadas a leitura das imagens e a ocorrência de duplicatas exatas a partir de conteúdo RGB decodificado e dimensões. O manifesto registra a assinatura da base e permite identificar alterações de arquivos entre execuções. Essa auditoria reconhece igualdade exata de pixels, mas não estabelece identidade de paciente, equivalência entre recortes ou semelhança visual. Como os artefatos disponíveis não demonstram agrupamento por paciente ou fotografia original, a separação é descrita como partição por imagem; não se atribui a ela independência clínica individual não documentada.

4.3 PRÉ-PROCESSAMENTO E AUMENTO DE DADOS

As imagens foram carregadas em RGB e redimensionadas para 224×224 pixels. Após conversão para tensores no intervalo $[0, 1]$, os canais foram normalizados por

$$x'_c = \frac{x_c - \mu_c}{\sigma_c}, \qquad \boldsymbol{\mu} = (0{,}485; 0{,}456; 0{,}406), \quad \boldsymbol{\sigma} = (0{,}229; 0{,}224; 0{,}225).$$

Esses valores correspondem à normalização ImageNet utilizada no código V5 e foram preservados na exportação do modelo e no pré-processamento Android.

Somente no treinamento foram aplicados espelhamento horizontal aleatório e rotação aleatória de até ±15°. Validação e teste utilizaram transformação determinística: redimensionamento, conversão para tensor e normalização. O embaralhamento dos exemplos ocorreu no carregador de treinamento. Não foi implementada segmentação automática da lesão, e a imagem inteira fornecida ao modelo foi redimensionada para o formato de entrada.

4.4 ARQUITETURAS COMPARADAS

O conjunto final compreende **MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0, EfficientNet-B0, ResNet18 e DenseNet121**. A seleção reúne quatro alternativas compactas e duas referências arquiteturais com conexões residuais e densas. ResNet18 e DenseNet121 permitem examinar se maior complexidade, neste problema e neste ambiente, se traduz em vantagem classificatória. A VGG16, explorada em uma etapa preliminar, foi retirada do protocolo final por seu custo pouco alinhado ao objetivo de leveza operacional. Seus resultados antigos não são misturados às 18 execuções aqui apresentadas.

4.4.1 MobileNetV2

A MobileNetV2 utiliza blocos residuais invertidos e gargalos lineares, com convoluções separáveis em profundidade (SANDLER et al., 2018). A decomposição entre filtragem espacial por canal e combinação pontual reduz o custo em relação à convolução convencional. Sua inclusão mantém uma referência de arquitetura móvel já amplamente empregada. Na adaptação binária utilizada, a rede contém aproximadamente 2,23 milhões de parâmetros.

4.4.2 MobileNetV3 Small: ampliação da família móvel

A MobileNetV3 combina busca de arquitetura orientada ao hardware, refinamento de rede e modificações nos blocos móveis. A variante Small foi concebida para menores orçamentos de recursos e incorpora mecanismos de atenção por canais e ativações eficientes (**??**). Sua inclusão permite comparar uma evolução da família MobileNet com a V2 sob a mesma resolução e protocolo de ajuste. Nesta implementação binária, são aproximadamente 1,52 milhão de parâmetros. Essa motivação arquitetural não pressupõe vantagem automática de classificação ou latência em todo hardware.

4.4.3 ShuffleNetV2 x1.0: eficiência além do número de operações

A ShuffleNetV2 utiliza divisão e reorganização de canais, concatenando caminhos de processamento para favorecer a troca de informações entre grupos. Seu projeto considera fatores como acesso à memória, fragmentação das operações e paralelismo, ressaltando

que o número de operações não determina isoladamente a velocidade observada (**??**). A variante x1.0 foi incluída como alternativa compacta de aproximadamente 1,25 milhão de parâmetros após adaptação binária. O custo efetivo foi medido, em vez de deduzido apenas de sua dimensão estrutural.

4.4.4 EfficientNet-B0: modelo-base de uma família escalável

A EfficientNet propõe dimensionamento coordenado de profundidade, largura e resolução. A B0 constitui o modelo-base da família e emprega blocos MBConv com atenção por canais (**??**). Foi incluída para examinar uma alternativa compacta com capacidade representacional diferente das famílias MobileNet e ShuffleNet. Na configuração binária deste estudo, possui aproximadamente 4,01 milhões de parâmetros. O experimento utiliza a B0 na resolução padronizada de 224 pixels; não realiza uma busca entre B0 e variantes maiores.

4.4.5 ResNet18 e DenseNet121: referências de comparação

A ResNet18 emprega conexões residuais que somam a entrada à transformação aprendida nos blocos, favorecendo o fluxo de gradientes (HE et al., 2016). A DenseNet121 concatena características de camadas anteriores, incentivando sua reutilização (HUANG et al., 2017). As versões binárias utilizadas têm, respectivamente, aproximadamente 11,18 e 6,95 milhões de parâmetros. Essas arquiteturas foram mantidas como referências para comparar desempenho e recursos com as redes mais compactas, e não como exemplos necessariamente equivalentes de leveza móvel.

Tabela 4 – Implementações pré-treinadas utilizadas no protocolo V5

Arquitetura	Estratégia principal	Pesos Torchvision
MobileNetV2	Residual invertido e gargalo linear	ImageNet1K V2
MobileNetV3 Small	Blocos móveis, atenção por canais e busca de arquitetura	ImageNet1K V1
ShuffleNetV2 x1.0	Divisão e reorganização de canais	ImageNet1K V1
EfficientNet-B0	MBConv e modelo-base de escalonamento composto	ImageNet1K V1
ResNet18	Conexões residuais	ImageNet1K V1
DenseNet121	Conectividade densa	ImageNet1K V1

Fonte: Código V5 e implementações Torchvision utilizadas na execução.

Todas as redes tiveram a última camada de classificação substituída por uma unidade. O script conserva as demais partes da cabeça e da arquitetura. Os pesos pré-treinados não provêm de uma única receita comum: em particular, a MobileNetV2 usa ImageNet1K V2 e as demais versões utilizam V1. A comparação, portanto, é entre essas implementações pré-treinadas submetidas a um mesmo protocolo de ajuste fino.

4.5 TREINAMENTO, REPETIÇÃO E SELEÇÃO

Cada arquitetura foi executada com as sementes 42, 123 e 2026, totalizando $6 \times 3 = 18$ execuções. Foram controladas as sementes de Python, NumPy e PyTorch. As imagens dos conjuntos permaneceram fixas. Os resultados agregados são apresentados como média e desvio-padrão amostral entre as três execuções; esse desvio descreve variabilidade do treinamento nesta partição, sem constituir intervalo de confiança ou validação cruzada.

Foi empregado ajuste fino integral, otimizador Adam, taxa de aprendizado de 0,001, lote de treinamento 16 e função `BCEWithLogitsLoss`. O limite foi de 20 épocas, com parada antecipada após três épocas consecutivas sem redução da perda média de validação. Os carregadores de validação e teste utilizaram lote unitário e não realizaram embaralhamento.

Há três níveis distintos de decisão no protocolo:

1. **Época salva em cada execução:** o checkpoint é atualizado quando ocorre redução da perda de validação. Ao término, mantém-se a época de menor perda de validação daquela combinação arquitetura–semente.

2. **Arquitetura selecionada:** entre as arquiteturas com as três execuções concluídas, escolhe-se a de maior F1 médio de validação. A AUC média de validação é o primeiro desempate; o identificador da arquitetura estabelece ordem determinística se persistir empate.

3. **Semente representativa:** dentro da arquitetura selecionada, escolhe-se o checkpoint com maior F1 de validação, seguido por maior AUC de validação e menor valor da semente em caso de empate.

Esse procedimento selecionou EfficientNet-B0, semente 2026. O conjunto de teste foi utilizado para caracterizar o desempenho dos checkpoints, sem entrar nos critérios de seleção. Para cada uma das demais arquiteturas, uma semente representativa também foi escolhida pela validação, permitindo construir painéis de matrizes de confusão e curvas ROC de checkpoints individuais.

4.6 MÉTRICAS CLASSIFICATÓRIAS

A decisão binária utilizou limiar fixo $p_{\mathrm{PSOR}} \geq 0{,}5$. Considerando PSOR como classe positiva, foram calculados

$$\text{Sensibilidade} = \frac{TP}{TP+FN}, \qquad \text{Especificidade} = \frac{TN}{TN+FP}, \qquad \text{Precisão} = \frac{TP}{TP+FP},$$

$$F1_{\mathrm{PSOR}} = \frac{2TP}{2TP+FP+FN}, \qquad \text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN}.$$

Também foram obtidos AUC, Kappa de Cohen, F1 macro e acurácia balanceada. A AUC utiliza as saídas contínuas e resume a ordenação das classes ao variar o limiar; o Kappa corrige a concordância observada pela concordância esperada a partir das marginais. A matriz de confusão explicita os erros e acertos por classe.

O F1 principal corresponde à classe positiva, e não à média dos F1 das duas classes. Nos painéis, as matrizes apresentam contagens e percentuais por classe real, com a mesma escala visual. Não foi realizado teste formal de superioridade entre arquiteturas. A saída sigmoide é tratada como pontuação do modelo; não foi realizada calibração de probabilidade clínica.

4.7 MEDIÇÃO DE TEMPO E RECURSOS COMPUTACIONAIS

O treinamento e a avaliação foram executados em processos independentes. A avaliação inicia um processo novo, carrega o checkpoint e não conserva o otimizador ou os tensores do treinamento. Foram registradas inicialização, treinamento por época, validação, carregamento do checkpoint, avaliação com leitura dos dados e benchmark de inferência.

O tempo total de treinamento inclui épocas, validação, gravação de checkpoints e registros; a inicialização e eventuais downloads de pesos são medidos separadamente. Como a parada antecipada pode encerrar execuções em épocas diferentes, os tempos totais representam o custo do protocolo completo, e não necessariamente o mesmo número de atualizações.

Na avaliação com entrada e saída, o relógio abrange leitura, transformação, transferência, execução e coleta das saídas; o cálculo final das métricas ocorre fora desse intervalo. No benchmark da rede, a entrada já está transformada e transferida. O relógio inclui o forward e a sigmoide, com lote unitário. Foram realizados dez aquecimentos na preparação da avaliação e três passagens sobre as 122 imagens de teste, totalizando 366 latências por execução. A mediana e o percentil 95 são calculados nessas observações; posteriormente, seus valores são resumidos entre sementes.

A memória RAM foi medida como RSS do processo Python, por amostragem aproximadamente a cada 50 ms. Foram registrados nível inicial, pico observado, incremento, média amostral e nível final. O RSS inclui intérprete, bibliotecas, tensores e alocações mantidas, além dos pesos; picos mais curtos que o intervalo de amostragem podem não ser captados. O tamanho do checkpoint é uma medida de arquivo, não uma estimativa do RSS. O tempo acumulado de CPU do processo foi registrado separadamente do tempo decorrido, podendo refletir trabalho simultâneo em múltiplos núcleos.

O código prevê campos de memória alocada e reservada pelo PyTorch em CUDA, porém a execução apresentada foi em CPU; por isso, não são reportados valores de VRAM. Não foram medidos energia elétrica, descarga de bateria ou temperatura. Esses termos não são usados como equivalentes de tempo ou ocupação de memória.

4.8 PROTOCOLO DE EXPLICABILIDADE

A análise exploratória utilizou o checkpoint EfficientNet-B0 da semente 2026. Foram sorteadas, com semente 42, duas imagens de teste por classe, sem seleção visual pela qualidade dos mapas. Todos os métodos explicaram a saída PSOR, inclusive nas imagens NonPsor. Assim, um mapa para uma imagem negativa descreve contribuições em relação à hipótese PSOR, e não necessariamente uma explicação da classe predita.

O Grad-CAM foi calculado na última etapa de características da EfficientNet-B0, usando o logit PSOR e mantendo apenas contribuições positivas. A amplitude anterior à normalização foi registrada para distinguir mapas com variação de mapas sem ativação positiva variável. O LIME utilizou mil perturbações e segmentação SLIC com solicitação de 50 regiões; a quantidade efetiva pode diferir. O relatório registra essa quantidade e o R^2 local. O SHAP utilizou Partition, referência preta e limite de 500 avaliações, com atribuições aproximadas para a saída PSOR.

Foram preservados mapas numéricos, imagens PNG, status de execução e medições de recursos. A geração dos métodos ocorre sequencialmente no processo de explicabilidade; seus picos de RSS caracterizam o processo no momento de cada etapa e podem incluir alocações já retidas. Não foi feita avaliação clínica dos mapas ou comparação quantitativa com máscaras de lesão.

4.9 AMBIENTE E RASTREABILIDADE

O relatório registra Windows 11, Python 3.14.2, PyTorch 2.10.0+cpu, Torchvision 0.25.0+cpu, NumPy 2.4.2 e psutil 7.2.2. A CPU foi identificada como AMD64 Family 25 Model 80 Stepping 0, AuthenticAMD, com 12 núcleos lógicos e aproximadamente 15,79 GiB de RAM física total. O PyTorch foi configurado para quatro threads.

A execução de referência foi iniciada em 22 de outubro de 2026 e identificada pela pasta `<20261022_151228_934149>`. O relatório registra 18/18 execuções concluídas e tempo de sessão de 6.949,6 s. Esse tempo inclui trabalho do controlador e montagem do relatório, não somente a soma de forwards ou épocas.

As saídas são separadas em `<csv/>`, `<png/>`, `<checkpoints/>`, `<dados/>` e `<logs/>`. A configuração registra versões de software, assinatura dos dados, parâmetros e hash do código. O relatório HTML oferece uma síntese autossuficiente, enquanto os CSVs e PNGs preservam os resultados tabulares e visuais para conferência e reutilização.

4.10 ASPECTOS ÉTICOS E ÂMBITO DE USO

O estudo utiliza imagens secundárias e não inclui atendimento, intervenção ou coleta prospectiva nesta etapa. A descrição original informa anonimização do acervo privado

e ausência de vínculo com prontuários identificáveis. A documentação de procedência, autorização de uso e apreciação ética, quando aplicável, pertence ao registro institucional da pesquisa; hashes e relatórios de software não substituem essa documentação.

A disponibilidade pública de uma imagem não é tomada, por si só, como autorização irrestrita de reprodução. A seleção de figuras para publicação deve observar sua procedência e as condições de uso correspondentes. Não se declara dispensa automática de avaliação ética com base apenas na execução computacional. O tratamento de dados deve observar a legislação e as orientações institucionais pertinentes (**????**).

O protótipo tem finalidade acadêmica experimental. Ele classifica imagens segundo as duas classes do experimento, sem confirmação diagnóstica, recomendação terapêutica ou validação assistencial. Essa delimitação permite apresentar a contribuição técnica realizada e definir de forma objetiva os estudos necessários para ampliar seu uso.

5 RESULTADOS

5.1 COBERTURA EXPERIMENTAL E SELEÇÃO

As 18 execuções previstas foram concluídas: seis arquiteturas, cada uma treinada com três sementes na mesma partição. A seleção pela validação indicou a **EfficientNet-B0**, com o checkpoint da **semente 2026**. Esse resultado decorre do critério definido na Seção 4.5; a classificação das redes no teste e seus custos computacionais são apresentados como informações complementares.

O experimento permite distinguir a arquitetura selecionada pelo critério preditivo de validação das alternativas de menor custo. Essa distinção é relevante para a continuidade do sistema: o modelo integrado ao aplicativo segue a seleção registrada, enquanto uma eventual escolha baseada em restrições adicionais de latência ou memória exigirá critério próprio, definido e avaliado de forma explícita.

5.2 DESEMPENHO CLASSIFICATÓRIO

A Tabela 5 reúne as métricas do teste como média e desvio-padrão entre as três sementes. Todas as execuções foram avaliadas nas mesmas 122 imagens, sendo 59 PSOR e 63 NonPsor. Portanto, as três avaliações não correspondem a 366 indivíduos independentes, e o desvio entre sementes não expressa incerteza populacional.

Tabela 5 – Desempenho no teste: média e desvio-padrão entre as três sementes

Arquitetura	F1 PSOR	Sensibilidade	Especificidade	AUC	Acurácia	Kappa
MobileNetV2	$0{,}918 \pm 0{,}018$	$0{,}949 \pm 0{,}034$	$0{,}889 \pm 0{,}000$	$0{,}965 \pm 0{,}016$	$0{,}918 \pm 0{,}016$	$0{,}836 \pm 0{,}033$
MobileNetV3 Small	$0{,}889 \pm 0{,}016$	$0{,}927 \pm 0{,}020$	$0{,}852 \pm 0{,}024$	$0{,}965 \pm 0{,}016$	$0{,}888 \pm 0{,}017$	$0{,}776 \pm 0{,}034$
ShuffleNetV2 x1.0	$0{,}913 \pm 0{,}005$	$0{,}955 \pm 0{,}020$	$0{,}873 \pm 0{,}016$	$0{,}977 \pm 0{,}014$	$0{,}913 \pm 0{,}005$	$0{,}825 \pm 0{,}010$
EfficientNet-B0	$0{,}919 \pm 0{,}023$	$0{,}932 \pm 0{,}045$	$0{,}910 \pm 0{,}018$	$0{,}974 \pm 0{,}010$	$0{,}921 \pm 0{,}021$	$0{,}841 \pm 0{,}041$
ResNet18	$0{,}844 \pm 0{,}027$	$0{,}876 \pm 0{,}054$	$0{,}815 \pm 0{,}018$	$0{,}920 \pm 0{,}002$	$0{,}844 \pm 0{,}022$	$0{,}689 \pm 0{,}044$
DenseNet121	$0{,}898 \pm 0{,}024$	$0{,}898 \pm 0{,}045$	$0{,}905 \pm 0{,}016$	$0{,}960 \pm 0{,}017$	$0{,}902 \pm 0{,}022$	$0{,}803 \pm 0{,}044$

Fonte: Relatório final V5; média e desvio-padrão entre três sementes.

A EfficientNet-B0 apresentou F1 médio de $0{,}919 \pm 0{,}023$, AUC de $0{,}974 \pm 0{,}010$ e especificidade de $0{,}910 \pm 0{,}018$. A MobileNetV2 apresentou F1 de $0{,}918 \pm 0{,}018$ e sensibilidade de $0{,}949 \pm 0{,}034$. A diferença de 0,001 no F1 médio dessas duas redes é apenas descritiva; não foi realizado teste de superioridade ou equivalência.

A ShuffleNetV2 x1.0 apresentou a maior AUC média de teste, $0{,}977 \pm 0{,}014$, e sensibilidade de $0{,}955 \pm 0{,}020$, com F1 de $0{,}913 \pm 0{,}005$. Esse resultado reforça a utilidade de examinar métricas complementares: a maior AUC no teste não substitui o critério de F1 médio de validação utilizado na seleção. A MobileNetV3 Small apresentou F1 de

$0{,}889 \pm 0{,}016$, compondo uma alternativa de menor custo cuja contrapartida classificatória deve ser considerada.

A DenseNet121 apresentou F1 de $0{,}898 \pm 0{,}024$ e AUC de $0{,}960 \pm 0{,}017$. A ResNet18 obteve F1 de $0{,}844 \pm 0{,}027$ e AUC de $0{,}920 \pm 0{,}002$. Nesse protocolo, as redes de maior dimensão estrutural não apresentaram vantagem geral sobre as alternativas mais compactas. A Figura 6 sintetiza a relação entre qualidade classificatória e latência, sem transformar essa visualização em um novo critério de seleção.

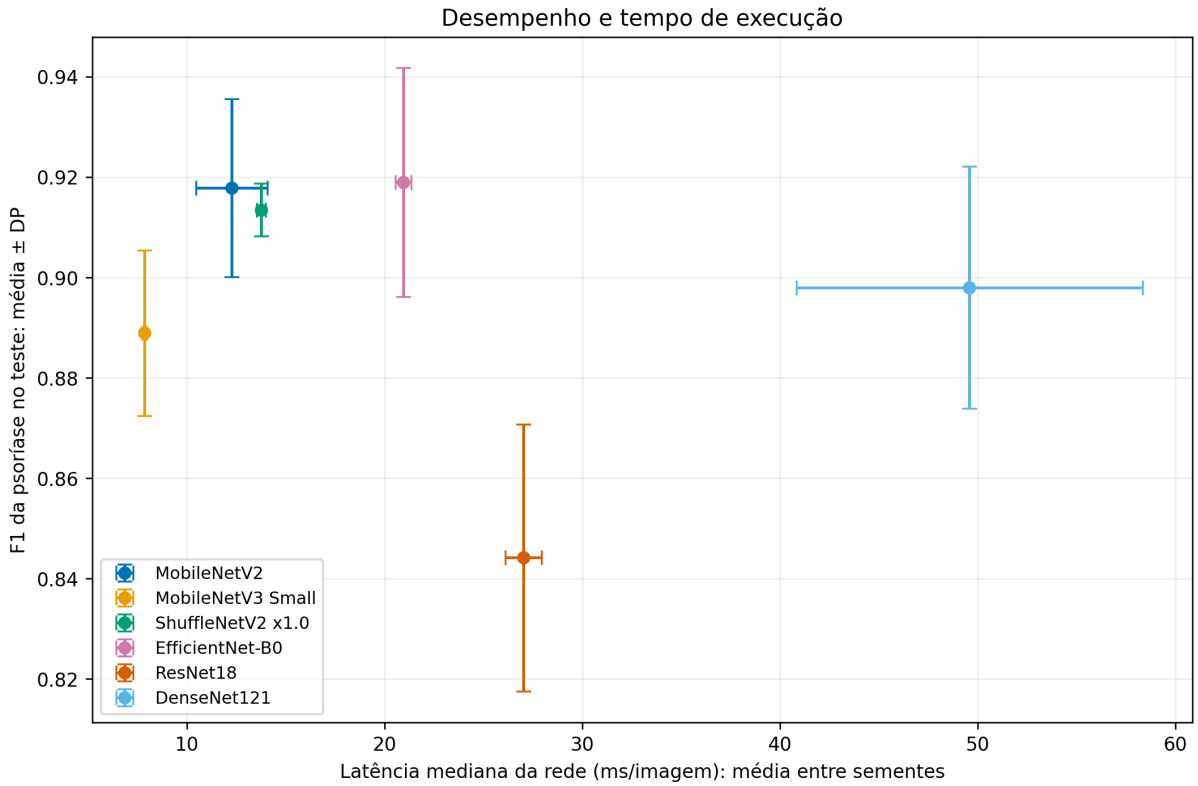


Figura 6 – Síntese do desempenho classificatório e da latência em CPU para as seis arquiteturas. As barras de variabilidade representam o desvio entre sementes na partição fixa; os tempos são do computador, não do aplicativo Android. Fonte: Autor.

5.3 COMPLEXIDADE, TEMPO E MEMÓRIA

A Tabela 6 reúne tamanho estrutural, arquivo de checkpoint e tempos. A MobileNetV3 Small apresentou a menor latência mediana, $7{,}87 \pm 0{,}11$ ms. A ShuffleNetV2 x1.0 apresentou o menor número de parâmetros e o menor checkpoint, aproximadamente 1,25 milhão e 4,95 MiB. A MobileNetV2 combinou F1 descritivamente próximo ao da EfficientNet-B0 com mediana de $12{,}28 \pm 1{,}81$ ms e checkpoint de 8,72 MiB.

A EfficientNet-B0, selecionada pela validação, apresentou mediana de $20{,}95 \pm 0{,}40$ ms e checkpoint de 15,58 MiB. A ResNet18 apresentou o maior checkpoint, 42,71 MiB,

Tabela 6 – Complexidade e tempos em CPU: cada resumo de latência é agregado entre sementes

Arquitetura	Parâmetros (milhões)	Checkpoint (MiB)	Treino e validação (s)	Mediana (ms)	p95 (ms)
MobileNetV2	2,23	8,72	$271{,}7 \pm 37{,}8$	$12{,}28 \pm 1{,}81$	$18{,}51 \pm 1{,}39$
MobileNetV3 Small	1,52	5,92	$144{,}4 \pm 35{,}7$	$7{,}87 \pm 0{,}11$	$10{,}02 \pm 0{,}73$
ShuffleNetV2 x1.0	1,25	4,95	$142{,}8 \pm 31{,}4$	$13{,}77 \pm 0{,}23$	$16{,}93 \pm 0{,}35$
EfficientNet-B0	4,01	15,58	$547{,}1 \pm 129{,}5$	$20{,}95 \pm 0{,}40$	$25{,}77 \pm 1{,}14$
ResNet18	11,18	42,71	$304{,}6 \pm 53{,}9$	$27{,}02 \pm 0{,}92$	$30{,}72 \pm 0{,}98$
DenseNet121	6,95	27,10	$688{,}4 \pm 96{,}8$	$49{,}59 \pm 8{,}76$	$55{,}12 \pm 4{,}86$

Fonte: Relatório final V5; média e desvio-padrão entre três sementes.

enquanto a DenseNet121 apresentou a maior latência mediana, $49{,}59 \pm 8{,}76$ ms. Esses resultados indicam que arquitetura selecionada, menor latência e menor arquivo são atributos diferentes, permitindo fundamentar decisões de implantação de acordo com as restrições do uso pretendido.

O tempo de treinamento inclui validação e gravação de checkpoints. A parada antecipada pode produzir números de épocas diferentes; assim, a comparação descreve o custo para executar o protocolo adotado. Não se atribui toda a diferença de tempo exclusivamente ao custo de uma época de cada arquitetura.

Tabela 7 – Picos observados de RSS do processo Python

Arquitetura	Treinamento (MiB)	Inferência (MiB)
MobileNetV2	$1879{,}8 \pm 10{,}4$	$525{,}6 \pm 0{,}5$
MobileNetV3 Small	$820{,}9 \pm 3{,}6$	$504{,}4 \pm 6{,}6$
ShuffleNetV2 x1.0	$901{,}2 \pm 13{,}7$	$504{,}7 \pm 7{,}7$
EfficientNet-B0	$2068{,}6 \pm 32{,}1$	$534{,}6 \pm 0{,}8$
ResNet18	$1098{,}5 \pm 17{,}0$	$586{,}4 \pm 1{,}5$
DenseNet121	$2747{,}9 \pm 2{,}6$	$547{,}4 \pm 15{,}7$

Fonte: Relatório final V5; média e desvio-padrão entre três sementes.

Na Tabela 7, o menor pico médio de RSS durante o treino foi observado na MobileNetV3 Small, $820{,}9 \pm 3{,}6$ MiB, e o maior na DenseNet121, $2747{,}9 \pm 2{,}6$ MiB. Na inferência, os picos ficaram entre aproximadamente 504 e 586 MiB. A proximidade de parte desses valores, apesar das diferenças no tamanho dos checkpoints, evidencia a contribuição do processo Python e de suas bibliotecas para o RSS total. Não se deve interpretar o RSS como memória exclusiva dos parâmetros da rede.

Os resultados de tempo e memória documentam a execução em CPU no ambiente registrado. Eles sustentam a escolha de candidatas para avaliação no celular, mas não representam medições de consumo energético, bateria ou latência móvel. O aplicativo possui instrumentação própria para essa etapa, descrita no capítulo de implementação e no manual.

5.4 MATRIZES DE CONFUSÃO DOS CHECKPOINTS REPRESENTATIVOS

Para facilitar a comparação de erros, a Figura 7 apresenta um checkpoint por arquitetura, escolhido pela validação. A Tabela 8 transcreve suas contagens. Cada matriz contém 122 observações; as matrizes não são somas ou médias das três sementes.

Tabela 8 – Contagens de teste dos checkpoints representativos escolhidos pela validação

Arquitetura	Semente	TN	FP	FN	TP
MobileNetV2	2026	56	7	3	56
MobileNetV3 Small	123	54	9	3	56
ShuffleNetV2 x1.0	2026	55	8	2	57
EfficientNet-B0	2026	58	5	2	57
ResNet18	2026	52	11	11	48
DenseNet121	42	57	6	3	56

Fonte: Transcrição das contagens do painel de matrizes V5. Cada linha corresponde a 122 imagens.

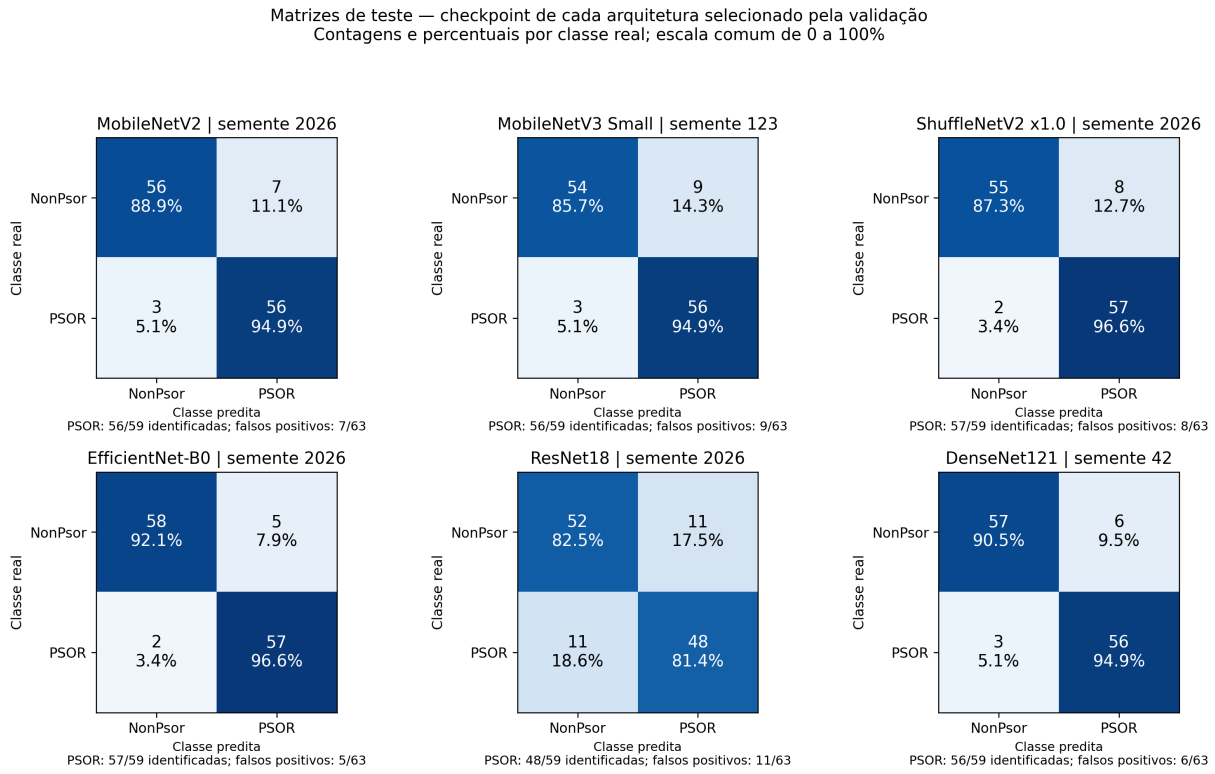


Figura 7 – Matrizes de teste de checkpoints escolhidos pela validação. Linhas: classe real; colunas: classe estimada. Os percentuais são calculados por linha, e a escala de cor é comum a todos os painéis. Para PSOR como classe positiva, a célula superior direita indica falsos positivos e a inferior esquerda, falsos negativos. Fonte: Autor.

No checkpoint integrado ao aplicativo, EfficientNet-B0 da semente 2026, foram observados 58 verdadeiros negativos, cinco falsos positivos, dois falsos negativos e 57

verdadeiros positivos. A partir dessas contagens, obtêm-se sensibilidade de $57/59 \approx 96{,}61\%$, especificidade de $58/63 \approx 92{,}06\%$ e F1 PSOR de $114/121 \approx 0{,}942$. Esses valores descrevem o checkpoint individual; não substituem as médias da arquitetura na Tabela 5.

A leitura por classe permite avaliar a distribuição dos erros sem depender apenas da acurácia global. Ela também oferece um roteiro de apresentação: identificar o número de imagens de cada classe, localizar falsos positivos e negativos e, em seguida, relacionar esses padrões às métricas e ao limiar utilizado. Não se infere, a partir das contagens, o mecanismo clínico ou visual responsável por cada erro.

5.5 EXPLICABILIDADE EXPLORATÓRIA

Foram produzidas 12 tentativas de explicação para quatro imagens. O relatório registra **11 saídas com status OK** e **um Grad-CAM sem ativação positiva variável**, correspondente à imagem 01_NonPsor. Não foram registrados erros de execução nesses resultados. O status OK indica conclusão técnica da etapa; não atesta qualidade clínica da explicação.

Tabela 9 – Indicadores da explicabilidade: alvo PSOR nos quatro exemplos

Imagem	R^2 LIME	Segmentos	SHAP	Grad-CAM
`01_NonPsor`	0,580742	44	OK	Sem variação Amplitude: 0
`02_NonPsor`	0,687944	46	OK	OK Amplitude: 0,105724
`03_PSOR`	0,735491	43	OK	OK Amplitude: 0,836909
`04_PSOR`	0,687648	45	OK	OK Amplitude: 0,710662

Fonte: Relatório V5. LIME: mil perturbações. SHAP: Partition, referência preta, 500 avaliações.

No LIME, os valores de R^2 local variaram de aproximadamente 0,581 a 0,735, com 43 a 46 segmentos efetivamente obtidos. A solicitação de 50 segmentos ao SLIC não obriga a obtenção de exatamente 50 regiões. Esses indicadores descrevem a aproximação local da saída PSOR nas perturbações; não correspondem ao F1 do classificador nem à probabilidade de a explicação estar clinicamente correta.

No SHAP, o procedimento Partition utilizou referência preta e limite de 500 avaliações. O valor-base registrado foi aproximadamente 0,00801, referente à referência e à saída explicada nessa configuração. As atribuições são aproximadas e devem ser lidas em relação ao procedimento de mascaramento empregado.

O Grad-CAM da imagem 01_NonPsor teve amplitude zero antes da normalização e foi corretamente identificado sem fabricar um mapa de calor variável. Como o alvo permanece PSOR, a ausência de contribuição positiva variável não confirma, isoladamente,

o diagnóstico negativo. Nos outros três casos, as amplitudes foram aproximadamente 0,105724, 0,836909 e 0,710662. A normalização independente de cada mapa impede comparar diretamente suas intensidades como uma escala comum de evidência.



Figura 8 – Comparação exploratória de Original, LIME, SHAP e Grad-CAM para a EfficientNet-B0, semente 2026. Todas as explicações têm alvo PSOR. LIME e SHAP representam contribuições positivas e negativas; Grad-CAM representa contribuição positiva ao logit. As escalas são normalizadas por mapa. Informar em cada linha a classe real, a classe estimada, a pontuação PSOR, o R^2 local do LIME e o status do Grad-CAM. Fonte: saídas do experimento V5.

A figura deve reproduzir mapas reais do experimento, e não ilustrações sintéticas de atenção. O painel originalmente incorporado ao relatório contém uma marca de origem visível em 01_NonPsor. Esse elemento pertence à imagem de entrada, não foi criado pelo Grad-CAM, LIME ou SHAP e integra a auditoria visual dos dados. Sua presença impede afirmar que a versão avaliada esteja integralmente livre de marcas. A regularização das imagens e de sua publicação deve preservar a rastreabilidade; mudanças na base de treinamento ou teste requerem nova versão e reavaliação correspondente.

Quanto ao tempo de geração das explicações, o relatório registra aproximadamente 0,03–0,04 s por Grad-CAM, 15,74–16,02 s por LIME e 7,47–7,68 s por SHAP. Esses intervalos correspondem aos valores arredondados apresentados para os quatro exemplos e ao orçamento adotado. Não demonstram que um método seja universalmente mais eficiente ou mais fiel. Os picos de RSS do processo de explicabilidade e seus tempos individuais permanecem disponíveis nas saídas de conferência.

5.6 SÍNTESE DAS ENTREGAS

Os resultados reúnem uma comparação concluída de seis CNNs, um critério de seleção reproduzível, registros de tempo e memória, painéis de erros e explicações exploratórias. A etapa seguinte do processo utiliza o checkpoint selecionado para exportação e inferência local. As figuras de ROC, evolução da validação e recursos computacionais são mantidas no apêndice de resultados complementares, preservando um corpo principal mais sintético.

6 IMPLEMENTAÇÃO DO SISTEMA ANDROID

6.1 DA COMPARAÇÃO DE MODELOS AO PROTÓTIPO

Foi desenvolvido um aplicativo nativo Android denominado *Sistema de Suporte ao Diagnóstico de Psoríase*, identificado tecnicamente como um protótipo acadêmico experimental. Sua função é receber uma imagem selecionada pelo usuário, aplicar o pré-processamento compatível com o experimento e executar o modelo treinado no próprio dispositivo. O aplicativo também registra medidas de tempo e memória, permitindo iniciar a avaliação operacional sem depender de um servidor de inferência.

A interface inclui as identidades visuais da UFPB e do PPGMDS, o nome do sistema, a identificação do modelo carregado, a imagem analisada, a classe estimada e uma mensagem associada ao resultado. As classes são apresentadas como *Psoríase* e *Não é psoríase*, preservando os códigos técnicos PSOR e NonPsor nos metadados e registros. A mensagem negativa esclarece que a classificação experimental não descarta a condição; a positiva informa que o resultado não confirma diagnóstico.

O modelo não é incorporado de forma fixa aos pesos internos do APK. Ele é importado por um pacote ZIP, permitindo atualizar ou substituir um modelo compatível sem recompilar a interface. No fluxo utilizado, foi importado o checkpoint EfficientNet-B0 da semente 2026. Não foram aplicadas quantização, poda ou compressão com perda de precisão nessa exportação: o modelo permanece em FP32.

6.2 EXPORTAÇÃO E EQUIVALÊNCIA

O exportador reconstrói a arquitetura selecionada, carrega o checkpoint e inclui a sigmoide no grafo ONNX. A entrada é FP32, com formato $1 \times 3 \times 224 \times 224$ e disposição NCHW; a saída é a pontuação `p_psor`. A exportação utiliza opset 17 e o ONNX Runtime 1.24.3 para a comparação no computador. Antes da validação, a pasta de teste é conferida contra o manifesto V5, utilizando classe, arquivo e hash de pixels.

O critério de aprovação exige erro absoluto máximo de saída não superior a 10^{-4} e preservação de todas as decisões no limiar original. Na execução informada pelo exportador, foram comparadas **122 imagens**, com erro máximo de $1{,}7285347 \times 10^{-6}$ e decisões preservadas. Trata-se de equivalência numérica e classificatória entre implementações nessas imagens, e não de nova estimativa de desempenho clínico.

O pacote gerado, `<modelo_android.zip>`, contém `<model.onnx>`, `<model.json>`, `<selftest.json>` e padrões sintéticos em `<selftest/>`. Os metadados identificam

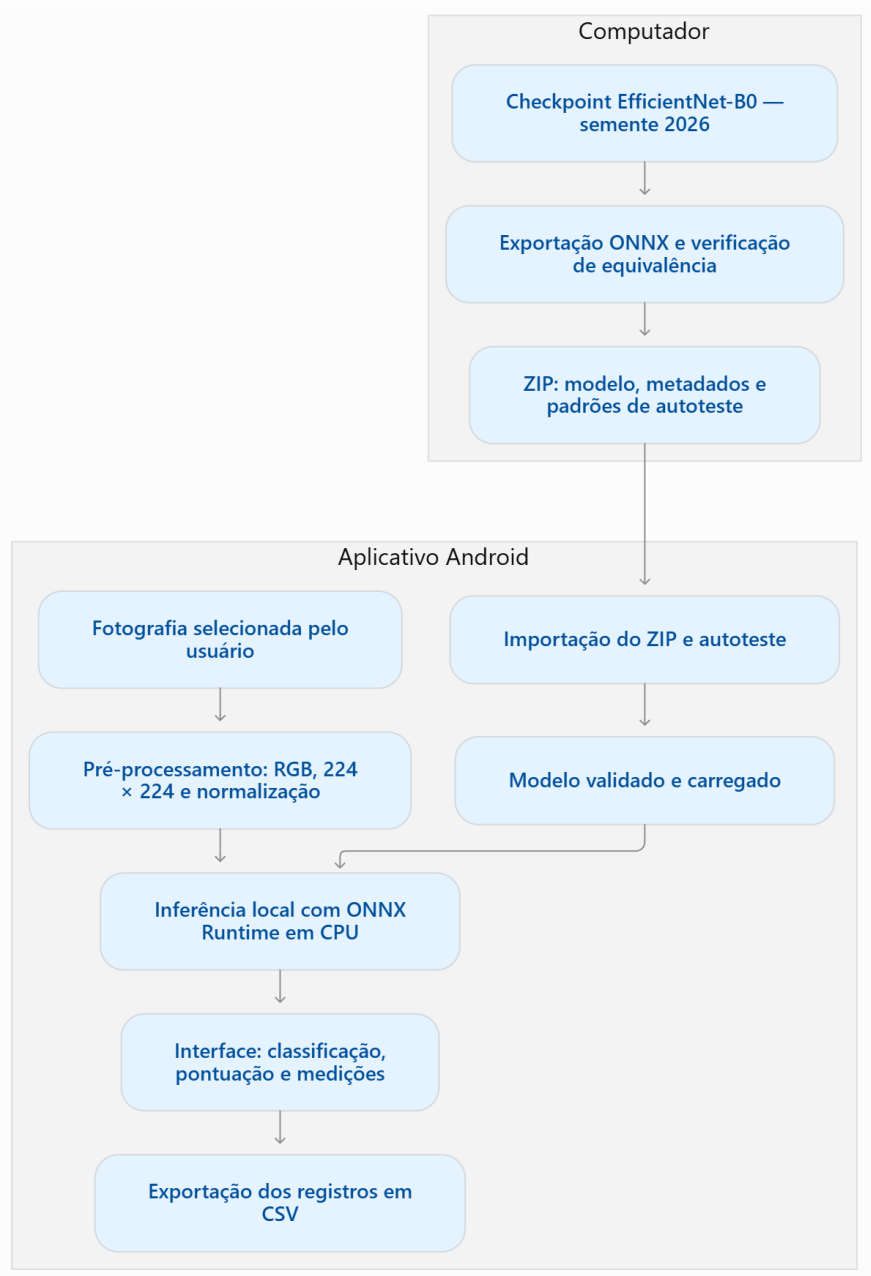


Figura 9 – Organização do protótipo: no computador, checkpoint PyTorch e exportação validada; no aparelho, importação do ZIP, autoteste, seleção de imagem, pré-processamento, sessão ONNX Runtime em CPU e apresentação do resultado; exportação local de medições em CSV. Fonte: elaboração do autor.

arquitetura, semente, normalização, classes, limiar, hashes e resultados da exportação. Três imagens sintéticas, seus tensores de referência e as saídas esperadas permitem conferir a integração no celular. As fotografias clínicas do teste não entram nesse ZIP; o CSV de equivalência permanece no computador.

6.3 IMPORTAÇÃO, AUTOTESTE E PERSISTÊNCIA

A importação verifica os arquivos permitidos, rejeita entradas duplicadas e limita o tamanho descompactado do pacote a 120 MiB. O hash SHA-256 do modelo é comparado ao valor registrado nos metadados. Essa conferência detecta inconsistência em relação ao pacote descrito; não equivale a uma assinatura de autoria ou certificação clínica do modelo.

Após criar a sessão de inferência, o aplicativo compara o pré-processamento dos padrões sintéticos com os tensores de referência e confere suas saídas. Os limites implementados são 2×10^{-5} para diferença máxima da entrada normalizada e 10^{-3} para diferença máxima da saída. Somente um pacote aprovado é ativado. O modelo validado é mantido no armazenamento privado do aplicativo e restaurado em aberturas posteriores. A assinatura digital do APK, utilizada pelo Android para instalação e atualização, é um mecanismo distinto do hash do modelo.

6.4 PROCESSAMENTO LOCAL E APRESENTAÇÃO

O protótipo foi implementado em Kotlin, com ONNX Runtime Android 1.24.3 (**??**), execução em CPU, quatro threads intraoperação e uma interoperacional. O pacote distribuído contempla ARM de 32 e 64 bits, com Android mínimo 8.0. A implementação não habilita GPU, NPU ou NNAPI nesta versão, e não utiliza permissão de internet.

A fotografia é selecionada pelo seletor de documentos do Android. O aplicativo aceita imagens decodificáveis com até 16 megapixels, lê os pixels, redimensiona a imagem inteira para 224 pixels e aplica a normalização registrada no pacote. Não realiza recorte de região de interesse, segmentação, correção automática de orientação EXIF ou verificação algorítmica da qualidade fotográfica. A orientação exibida é: “Sugestão: Use uma imagem já orientada, onde a região de interesse está bem enquadrada.”

A classe estimada é obtida no mesmo limiar registrado no experimento. O percentual exibido corresponde a $100p_{\mathrm{PSOR}}$ e é identificado como pontuação associada à psoríase. A interface não o apresenta como probabilidade clínica calibrada. O rótulo de referência é opcional, inserido para documentação no CSV, e não interfere no cálculo da predição.

6.5 MEDIÇÕES E ORGANIZAÇÃO DOS REGISTROS

O modo de análise executa uma inferência. O modo de desempenho realiza cinco aquecimentos e trinta inferências temporizadas sobre a mesma entrada preparada. O CSV registra latências individuais, média, mediana e p95, além de leitura, pré-processamento, tempo total da etapa, carregamento da sessão e tempo acumulado de CPU. O forward no aplicativo inclui criação do tensor ONNX, execução e leitura da saída; seu escopo difere do forward PyTorch registrado no computador.

A memória é obtida como PSS do processo Android, por amostragem aproximadamente a cada 50 ms (**??**). São registrados nível inicial, pico observado, final e quantidade de amostras. PSS e RSS são medidas distintas; por isso, os valores do aplicativo e do processo Python não devem ser comparados como se fossem a mesma variável. Não há medição de energia, temperatura ou bateria nesta versão.

Os registros de medições permanecem na memória da sessão e podem ser exportados em CSV UTF-8, com separador ponto e vírgula. O aplicativo não grava fotografias no histórico e não inclui nomes ou caminhos de imagens no CSV. Essa minimização também significa que a vinculação de múltiplas imagens em um estudo de benchmark precisará de um protocolo externo de identificação codificada ou de evolução específica do aplicativo.

6.6 VERIFICAÇÕES REALIZADAS E AVALIAÇÃO POSTERIOR

O desenvolvimento produziu código-fonte, APK, exportador e documentação de operação. A exportação em 122 imagens foi aprovada no computador, e uma versão inicial do aplicativo foi instalada com importação do EfficientNet-B0, conforme verificação funcional inicial de desenvolvimento. A atualização 0.1.2 foi conferida quanto a estrutura do pacote, assinatura e compatibilidade de atualização com a 0.1.1. Essas verificações documentam integração e empacotamento, não substituindo um ensaio controlado no aparelho.

Não foi fornecida, para esta redação, uma série de CSVs de benchmark Android acompanhada da identificação do dispositivo. Assim, não são atribuídos ao celular os tempos ou picos de memória obtidos no computador. A avaliação quantitativa em aparelho real, a usabilidade e a comparação entre dispositivos permanecem etapas delimitadas para continuidade. O manual detalhado de instalação, importação, análise, medição e solução de problemas está no Apêndice A.

7 DISCUSSÃO

7.1 CONTRIBUIÇÃO DO PROCESSO INTEGRADO

O estudo avançou de uma comparação isolada de classificadores para um processo que conecta preparação dos dados, experimentação, explicabilidade, exportação verificada e inferência local. Essa integração constitui uma contribuição aplicada: os resultados deixam de se restringir às métricas de uma execução e passam a ser acompanhados por configuração, registros de recursos, critérios de seleção e um protótipo utilizável em desenvolvimento.

A inclusão de MobileNetV3 Small, ShuffleNetV2 x1.0 e EfficientNet-B0 ampliou o contraste entre alternativas compactas, enquanto ResNet18 e DenseNet121 mantiveram referências de outras estratégias arquiteturais. Os resultados desse conjunto mostram que ampliar a complexidade estrutural não produziu vantagem geral de classificação nesta partição.

7.2 SELEÇÃO PREDITIVA E RESTRIÇÕES DE IMPLANTAÇÃO

A EfficientNet-B0 foi selecionada pela validação e integrada ao aplicativo sem substituir o critério após observar o teste. Ao mesmo tempo, MobileNetV2, MobileNetV3 Small e ShuffleNetV2 oferecem perfis de custo relevantes para a continuidade do projeto. A MobileNetV2 apresentou F1 de teste descritivamente próximo ao da EfficientNet-B0 com menor mediana de inferência; a MobileNetV3 Small foi a mais rápida, e a ShuffleNetV2 apresentou o menor checkpoint e a maior AUC média de teste.

Esses perfis não determinam um vencedor universal. A decisão de implantação pode envolver limite de latência, memória disponível, estabilidade e qualidade preditiva. A opção utilizada neste protótipo reproduz a seleção preditiva registrada; um estudo posterior poderá estabelecer uma regra que combine desempenho e recursos, utilizando a validação para escolhê-la e uma avaliação independente para caracterizar o resultado.

Os tempos em CPU permitem identificar candidatas, mas não estabelecem sua ordenação em qualquer celular. Operações, bibliotecas de execução e características do hardware influenciam a latência. Além disso, o benchmark de desktop e o do aplicativo têm escopos de medição diferentes. A implementação Android cria as condições para investigar essa questão com registros próprios, em vez de extrapolar diretamente os números do computador.

7.3 EXPLICABILIDADE COMO INSTRUMENTO DE INSPEÇÃO

O painel de explicabilidade permite confrontar contribuições de três métodos sob uma mesma classe-alvo e examinar imagens positivas e negativas. O registro de parâmetros, fidelidade local e status evita interpretar toda imagem produzida como uma explicação igualmente informativa. O Grad-CAM sem amplitude positiva variável exemplifica a importância desse controle: documentar a ausência de variação é mais informativo do que normalizar ruído e apresentá-lo como evidência visual.

Os mapas oferecem subsídios à auditoria da imagem e do modelo, mas não avaliam por si mesmos a localização clínica da lesão. A marca de origem ainda visível em um dos exemplos evidencia uma questão de curadoria que pode ser examinada de forma rastreável. A inspeção de regiões externas, marcas e fundo é uma aplicação coerente das explicações, sem concluir que o algoritmo os utilizou causalmente ou que a remoção visual de um artefato corrige automaticamente o aprendizado.

7.4 ALCANCE DA EVIDÊNCIA E CONTINUIDADE

Os resultados constituem avaliação interna por imagem em uma partição fixa, com três inicializações de treinamento. A dimensão do conjunto de teste e a falta de agrupamento documentado por paciente limitam a extensão das inferências. O desvio entre sementes caracteriza variabilidade de treinamento, e não desempenho externo. A ausência de metadados padronizados por fototipo, fonte e subtipo também impede apresentar desempenho estratificado confiável nesses grupos.

A implementação e a equivalência numérica demonstram uma etapa concreta de integração. Ainda não foram apresentados benchmark Android controlado, estudo de usabilidade ou validação clínica prospectiva. Essas etapas são complementares às entregas realizadas: a instrumentação e o manual reduzem o esforço para conduzi-las de forma organizada. A delimitação do escopo preserva o significado dos achados e permite reconhecer a contribuição técnica sem atribuir benefícios assistenciais ainda não medidos.

8 CONCLUSÃO

Este trabalho desenvolveu um sistema experimental de suporte à classificação de imagens de psoríase, integrando comparação de modelos, medição de recursos, explicabilidade exploratória e inferência local em Android. A base final de 798 imagens foi mantida em uma partição fixa de treinamento, validação e teste, e as seis arquiteturas foram executadas em três sementes, com conclusão das 18 combinações previstas.

A seleção baseada exclusivamente na validação indicou a EfficientNet-B0, com checkpoint da semente 2026. A arquitetura apresentou F1 médio de teste de $0{,}919 \pm 0{,}023$ e AUC de $0{,}974 \pm 0{,}010$. As alternativas compactas exibiram perfis distintos de eficiência: a MobileNetV2 combinou desempenho descritivamente próximo com menor latência; a MobileNetV3 Small apresentou a menor latência; e a ShuffleNetV2 x1.0 apresentou o menor checkpoint. A avaliação conjunta permite orientar estudos de implantação conforme restrições explícitas de desempenho e recursos.

Grad-CAM, LIME e SHAP foram incorporados à análise exploratória de quatro imagens, com documentação de execução e limites de interpretação. O modelo selecionado foi exportado para ONNX com decisões preservadas em 122 imagens e erro máximo de saída de $1{,}7285347 \times 10^{-6}$. O protótipo Android implementa importação do modelo em ZIP, autoteste, classificação local, medição de tempo e memória e exportação de registros, acompanhado de manual detalhado.

A contribuição do trabalho é, portanto, um processo técnico documentado que conecta a avaliação experimental a uma ferramenta funcional de pesquisa. A validação externa, a independência por paciente, os ensaios em celulares e a avaliação clínica constituem próximos estudos para ampliar a evidência produzida. O sistema atual oferece uma base implementada e auditável para essa continuidade.

9 TRABALHOS FUTUROS

A continuidade imediata consiste em executar o protocolo de medições em aparelhos identificados, usando as mesmas imagens e o mesmo modelo, com registro das condições de cada sessão. A comparação deverá distinguir leitura, pré-processamento e inferência, além de examinar estabilidade, aquecimento e variação entre dispositivos. Consumo energético e bateria poderão ser incorporados por instrumentação específica, sem serem estimados apenas a partir da latência.

Na base de dados, as prioridades são consolidar procedência e permissões, revisar artefatos, identificar fotografias originais e agrupar derivados por paciente ou origem antes da divisão. Uma versão revisada deverá ser registrada como novo experimento, preservando a rastreabilidade da V5. Também são relevantes ampliação do acervo, avaliação externa e caracterização por fototipo e subtipo quando houver rótulos adequados.

A análise de explicabilidade poderá ser ampliada para mais imagens, erros e diferentes referências de mascaramento, com avaliação por especialistas e métricas de localização quando houver anotações pertinentes. A qualidade de uma explicação deverá ser investigada além do status de execução e da aparência do mapa.

Na implementação, podem ser investigadas outras arquiteturas compactas já comparadas, quantização com nova verificação de equivalência e desempenho, identificação codificada das imagens nos registros, captura pela câmera e tratamento explícito da orientação. A interface e suas mensagens podem ser avaliadas em estudo de usabilidade. A utilização assistencial exigirá uma etapa própria de avaliação clínica e institucional, distinta da prova de integração apresentada.

REFERÊNCIAS BIBLIOGRÁFICAS

BOEHNCKE, W.-H. Systemic inflammation and cardiovascular comorbidity in psoriasis patients: causes and consequences. *Frontiers in immunology*, Frontiers Media SA, v. 9, p. 579, 2018.

BRASIL. *Protocolo clínico e diretrizes terapêuticas da psoríase*. 2021. Portaria Conjunta nº 18, de 14 de outubro de 2021. Disponível em: <https://www.gov.br/conitec/pt-br/midias/relatorios/2021/20211021_relatorio_652_pcdt_psoriase.pdf>.

CAVOUKIAN, A. *Privacy by Design: The 7 Foundational Principles*. 2009. Information and Privacy Commissioner of Ontario.

CAVOUKIAN, A. *Privacy by Design in Law, Policy and Practice*. 2011. Information and Privacy Commissioner of Ontario.

CHAKRABORTY, C. et al. Cad-psornet: deep transfer learning for computer-assisted diagnosis of skin psoriasis. *Scientific Reports*, Nature Publishing Group, v. 14, n. 1, p. 26557, 2024.

CHRISTOPHERS, E. Psoriasis - epidemiology and clinical spectrum. *Clinical and Experimental Dermatology*, v. 26, n. 4, p. Pages 314–320, 2001.

DASH, M. et al. Hybrid seeker optimization algorithm-based accurate image clustering for automatic psoriasis lesion detection. In: *Artificial Intelligence Applications for Health Care*. [S.l.]: CRC Press, 2022. p. 227–240.

DESAI, S. R.; ALEXIS, A. F.; JACOBSON, A. Successful management of a black male with psoriasis and dyspigmentation treated with halobetasol propionate 0.01%/tazarotene 0.045% lotion: case report. *Journal of Drugs in Dermatology: JDD*, v. 19, n. 10, p. 1000–1004, 2020.

DEY, A. K. Context-aware computing. In: *Ubiquitous computing fundamentals*. [S.l.]: Chapman and Hall/CRC, 2018. p. 335–366.

ESTUDO, A. do. Image resolution vs. accuracy trade-off in dermatology ai. *Dermatology AI Journal*, 2026. Avalia o impacto da resolução de entrada em desempenho de CNNs na classificação de imagens dermatológicas.

European Union. *Regulation (EU) 2016/679 of the European Parliament and of the Council of 27 April 2016 (General Data Protection Regulation)*. 2016. EUR-Lex. Official text of the GDPR.

FENG, X. et al. Computer vision algorithms and hardware implementations: A survey. *Integration*, v. 69, p. 309–320, 2019. ISSN 0167-9260. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0167926019301762>.

GHORBIAN, M.; GHOBAEI-ARANI, M.; GHORBIAN, S. A comprehensive study on the application of machine learning in psoriasis diagnosis and treatment: taxonomy, challenges and recommendations. *Artificial Intelligence Review*, v. 58, n. 2, p. 60, 2024.

GOODFELLOW, I. *Deep learning*. [S.l.]: MIT press, 2016.

GORELICK, J. et al. Understanding treatment preferences in patients with moderate to severe plaque psoriasis in the usa: results from a cross-sectional patient survey. *Dermatology and Therapy*, Springer, v. 9, n. 4, p. 785–797, 2019.

GRIFFITHS, C. E.; BARKER, J. N. Pathogenesis and clinical features of psoriasis. *The Lancet*, Elsevier, v. 370, n. 9583, p. 263–271, 2007.

GULZAR, M. A. et al. Skin disease detection and classification. In: SHARMA, N.; CENGIZ, K.; CHATTERJEE, P. (Ed.). *Intelligent Data Analytics for Bioinformatics and Biomedical Systems*. [S.l.]: Wiley-Scrivener, 2024, (Sustainable Computing and Optimization). p. 67–92. ISBN 9781394270880.

HAENSSLE, H. A. et al. Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists. *Annals of oncology*, Elsevier, v. 29, n. 8, p. 1836–1842, 2018.

HAMMAD, M. et al. Enhanced deep learning approach for accurate eczema and psoriasis skin detection. *Sensors*, v. 23, n. 16, 2023. ISSN 1424-8220. Disponível em: <https://www.mdpi.com/1424-8220/23/16/7295>.

HE, K. et al. Deep residual learning for image recognition. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.l.: s.n.], 2016. p. 770–778.

HUANG, G. et al. Densely connected convolutional networks. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.l.: s.n.], 2017. p. 4700–4708.

JEONG, H. K. et al. Deep learning in dermatology: a systematic review of current approaches, outcomes, and limitations. *JID Innovations*, v. 3, n. 1, p. 100150, 2023.

LIU, Z. et al. Artificial intelligence in psoriasis: where we are and where we are going. *Experimental Dermatology*, v. 32, n. 11, p. 1884–1899, 2023.

LOWES, M. A.; BOWCOCK, A. M.; KRUEGER, J. G. Pathogenesis and therapy of psoriasis. *Nature*, Nature Publishing Group UK London, v. 445, n. 7130, p. 866–873, 2007.

MCMULLEN, E. P. et al. Predicting psoriasis severity using machine learning: a systematic review. *Clinical and Experimental Dermatology*, v. 50, n. 3, p. 520–528, 2025.

MILANI, A. et al. A deep learning application for psoriasis detection. *arXiv preprint arXiv:2508.18528*, 2025. Disponível em: <https://arxiv.org/abs/2508.18528>.

OTA, K. et al. Deep learning for mobile multimedia: A survey. *ACM Trans. Multimedia Comput. Commun. Appl.*, Association for Computing Machinery, New York, NY, USA, v. 13, n. 3s, jun. 2017. ISSN 1551-6857. Disponível em: <https://doi.org/10.1145/3092831>.

RAVIPATI, A.; ELMAN, S. A. The state of artificial intelligence for systemic dermatoses: Background and applications for psoriasis, systemic sclerosis, and much more. *Clinics in Dermatology*, v. 42, n. 5, p. 487–491, 2024.

SANDLER, M. et al. Mobilenetv2: Inverted residuals and linear bottlenecks. In: *Proceedings of the IEEE conference on computer vision and pattern recognition*. [S.l.: s.n.], 2018. p. 4510–4520.

SANVER, U.; KASAPBASI, M. C. Comparison of deep learning methods for detection of psoriasis lesions. In: CHOUDRIE, J. et al. (Ed.). *ICT for Intelligent Systems*. Singapore: Springer Nature Singapore, 2026. p. 381–389. ISBN 978-981-95-1357-4.

SARKER, I. H. et al. Mobile data science and intelligent apps: concepts, ai-based modeling and research directions. *Mobile Networks and Applications*, Springer, v. 26, n. 1, p. 285–303, 2021.

SCHAFFERT, D. et al. Using automated machine learning to predict necessary upcoming therapy changes in patients with psoriasis vulgaris and psoriatic arthritis and uncover new influences on disease progression: retrospective study. *JMIR Formative Research*, v. 8, p. e55855, 2024.

SHAPIRO, J. et al. Application of a natural language processing artificial intelligence tool in psoriasis: A cross-sectional comparative study on identifying affected areas in patients' data. *Clinics in Dermatology*, v. 42, n. 5, p. 480–486, 2024.

SILVA, K. d. S.; SILVA, E. A. T. d. Psoríase e sua relação com aspectos psicológicos, stress e eventos da vida. *Estudos de Psicologia*, v. 24, n. 2, 2007.

TAKESHITA, J. et al. Psoriasis and comorbid diseases: epidemiology. *Journal of the American Academy of Dermatology*, Elsevier, v. 76, n. 3, p. 377–390, 2017.

TANANTONG, T. et al. A study on area assessment of psoriasis lesions using image augmentation and deep learning: Addressing the lack of thai skin disease data. *Journal of Current Science and Technology*, v. 15, n. 3, p. 119–119, 2025.

WANG, J. et al. Deep learning towards mobile applications. In: IEEE. *2018 IEEE 38th International Conference on Distributed Computing Systems (ICDCS)*. [S.l.], 2018. p. 1385–1393.

YU, K. et al. Machine learning applications in the evaluation and management of psoriasis: A systematic review. *Journal of Psoriasis and Psoriatic Arthritis*, v. 5, n. 4, p. 147–159, 2020.

Apêndices

APÊNDICE A – MANUAL DE UTILIZAÇÃO DO APLICATIVO

A.1 FINALIDADE E VISÃO GERAL

Este manual descreve a versão **0.1.2-pesquisa** do *Sistema de Suporte ao Diagnóstico de Psoríase*, protótipo acadêmico desenvolvido no contexto do PPGMDS/UFPB. Ele orienta a instalação, a importação do modelo treinado, a análise de uma fotografia, a medição de desempenho e a exportação dos registros.

O fluxo básico é: **instalar o aplicativo; importar o ZIP do modelo; aguardar o autoteste; selecionar uma fotografia; ler a classificação; exportar as medições**. O treinamento e a comparação de modelos são realizados no computador. O celular executa o modelo já treinado e não refaz o aprendizado a cada fotografia.

A ferramenta tem finalidade experimental de pesquisa. As classes exibidas descrevem a estimativa do modelo; a imagem isolada e a pontuação produzida não confirmam nem excluem um diagnóstico clínico. A versão atual não recomenda tratamento.

A.2 ARQUIVOS E REQUISITOS

A.2.1 Diferenciar os três pacotes

APK do aplicativo

Arquivo de instalação Android, por exemplo `<Psoriase_Pesquisa_v0_1_2_corrigido.apk>`. Instala a interface e o mecanismo de inferência. Não contém os pesos treinados do experimento.

ZIP do modelo

Arquivo `<modelo_android.zip>`, produzido pelo exportador. Deve ser selecionado **dentro do aplicativo**, no botão de importação. Mantenha-o compactado, sem renomear seus arquivos internos.

ZIP do projeto

Pacote com código-fonte e documentação para desenvolvimento no computador. Não deve ser importado como modelo. Se contiver uma pasta APK, extraia o APK antes de instalar.

A.2.2 Requisitos do aparelho

O APK fornecido requer Android 8.0 ou superior e processador ARM de 32 ou 64 bits. É necessário espaço para o aplicativo, para o pacote do modelo e para sua extração temporária. O tamanho dos arquivos não determina, isoladamente, a memória necessária para executar a rede. A implementação utiliza CPU e quatro threads; não é necessário configurar GPU ou outro acelerador.

As fotografias devem estar em formato reconhecido pelo decodificador do Android e ter, no máximo, **16.000.000 pixels**. A limitação corresponde ao produto largura por altura, e não ao tamanho do arquivo em megabytes. O pacote de modelo é limitado a **120 MiB descompactados**. Depois de instalados o app e o modelo e disponibilizada a imagem no aparelho, a inferência ocorre sem servidor e sem transmissão da fotografia pelo aplicativo.

A.3 INSTALAÇÃO E ATUALIZAÇÃO

A.3.1 Primeira instalação

1. Copie o APK completo para o celular. Se ele estiver dentro de um ZIP de instalação, extraia-o primeiro.

2. Abra o APK pelo gerenciador de arquivos. Quando o Android solicitar autorização de instalação para essa origem, siga o fluxo apresentado pelo sistema.

3. Conclua a instalação e abra o aplicativo, identificado no launcher como *Psoríase • Pesquisa*.

4. Confira o título *Sistema de Suporte ao Diagnóstico de Psoríase* e os elementos institucionais.

5. Na primeira abertura, a mensagem informa que falta importar o modelo. Essa é uma condição esperada, pois os pesos são fornecidos separadamente.

   O APK corrigido 0.1.2 tem **45.668.605 bytes**. Seu SHA-256 de referência é:

   <c3b0fba2ec2ba5359d9f4f44a9d38ce455e7c4f180819a72b3cccac4383507b3>

Esse tamanho e esse hash identificam especificamente o arquivo fornecido nesta revisão; uma compilação diferente terá outra identificação. A versão avulsa inicialmente enviada estava truncada e foi substituída pela cópia íntegra. Caso tenha guardado o download anterior com erro, utilize a cópia corrigida.

A.3.2 Atualizar uma instalação existente

As versões 0.1.1 e 0.1.2 utilizam o mesmo certificado de assinatura. A atualização da 0.1.1 deve ser instalada por cima da anterior, preservando o armazenamento privado do modelo. Antes de fechar o aplicativo, **exporte as medições pendentes**, pois esses registros pertencem à sessão em memória.

A versão 0.1.0 utiliza outro certificado. Nessa transição, mantenha `<modelo_android.zip>` fora do armazenamento privado do app e exporte os CSVs antes de desinstalar a versão antiga. Após instalar a nova versão, importe novamente o mesmo ZIP. A desinstalação remove os dados privados do aplicativo; não é necessário treinar o modelo novamente.

Não desinstale como primeira tentativa diante de qualquer falha. Confira antes o arquivo, a versão instalada e a mensagem apresentada, para evitar perda desnecessária de dados.

A.4 PREPARAÇÃO E EXPORTAÇÃO NO COMPUTADOR

A.4.1 Quando esta etapa é necessária

Se `<modelo_android.zip>` já foi exportado, aprovado e importado anteriormente, utilize esse mesmo arquivo. A troca de textos ou logos do aplicativo não exige novo treinamento nem nova exportação. Esta etapa é necessária para preparar outro checkpoint compatível ou refazer um pacote que esteja ausente ou danificado.

A.4.2 Identificar a execução correta

A pasta deve conter `<configuracao.json>`, `<modelo_selecionado.json>`, o checkpoint indicado e `<csv/manifesto_imagens.csv>`. Na execução utilizada, a pasta é `<Resultados_Rinha_V5/20261022_151228_934149>`, o modelo é EfficientNet-B0 e a semente é 2026. O checkpoint correspondente é `<checkpoints/efficientnet_b0_s2026.pt>`.

Abra o prompt na pasta `PsoraseApp` do projeto e utilize o mesmo Python que executou a V5. Instale as dependências específicas de exportação:

```
python -m pip install -r ferramentas\requirements_exportacao.txt
```

Em seguida, execute

```
EXPORTAR_MODELO.bat
```

e informe a pasta completa da execução que contém `<configuracao.json>`. Também é possível utilizar

```
python ferramentas\exportar_modelo.py --execucao "PASTA_V5"
```

substituindo `PASTA_V5` pelo caminho completo. A pasta original `Teste` deve continuar acessível, com as mesmas imagens do manifesto. Se apenas sua localização mudou, utilize a opção `-teste` com o novo caminho; ela não autoriza substituir o conjunto por outras imagens.

A.4.3 Conferir a aprovação

O exportador compara PyTorch e ONNX nas imagens do teste e exige decisões iguais e erro máximo não superior a 10^{-4}. A execução de referência aprovou 122 imagens, com erro máximo de $1{,}7285347 \times 10^{-6}$. Ao final, são produzidos `<modelo_android.zip>` e `<modelo_android.equivalencia.csv>`.

Transfira o ZIP para o celular. O CSV de equivalência é um registro de conferência no computador e não precisa ser importado no app. Não descompacte e recomprima o ZIP do modelo acrescentando uma pasta externa: os arquivos esperados devem permanecer em sua estrutura original. Se a saída já existir, o exportador a preserva; utilize `-saida` com outro nome para uma nova exportação.

A.5 IMPORTAÇÃO E AUTOTESTE NO CELULAR

1. Abra o aplicativo e toque em **1. Importar pacote do modelo (.zip)**.
2. No seletor de arquivos, localize `<modelo_android.zip>`. Selecione o arquivo, e não uma pasta ou o ZIP do projeto.
3. Aguarde a mensagem de processamento. Durante uma tarefa, os botões ficam temporariamente desabilitados.
4. O aplicativo confere a estrutura, os metadados, o SHA-256 do modelo e três padrões sintéticos de entrada e saída.
5. Confirme a mensagem **Autoteste OK**, a arquitetura carregada e o tempo de carregamento do modelo.

O autoteste verifica a compatibilidade técnica do pacote com o pré-processamento e o mecanismo de inferência. Ele não mede sensibilidade clínica e não é um teste de uma fotografia do paciente. O botão **Conferir autoteste do modelo** permite repetir essa conferência; ele reabre a sessão e atualiza a medição de carregamento utilizada nos registros seguintes.

O modelo aprovado fica no armazenamento privado do aplicativo e é restaurado nas próximas aberturas. Um novo modelo só é ativado após aprovação das verificações; pacotes anteriores são removidos após a ativação do novo. Mantenha uma cópia do ZIP original fora do app para reinstalações.

Espaço reservado para figura

<pngs/manual_importacao_autoteste.png>

Inserir o arquivo correspondente conforme o guia das figuras.

Figura 10 – Tela real do aplicativo após importação: arquitetura, indicação de CPU e quatro threads, tempo de carregamento e mensagem Autoteste OK. Ocultar notificações e informações pessoais do aparelho. Fonte: captura do protótipo.

A.6 SELEÇÃO E PREPARAÇÃO DA FOTOGRAFIA

Toque em **2. Selecionar fotografia** e escolha uma imagem disponível no aparelho. Ao retornar do seletor, o aplicativo inicia automaticamente uma análise e define o rótulo de referência como *Não informado*. Aguarde a conclusão antes de iniciar outra tarefa.

A recomendação da interface é: *Sugestão: Use uma imagem já orientada, onde a região de interesse está bem enquadrada.* Prepare a orientação antes de selecionar. O app utiliza os pixels como são decodificados e não aplica rotação automática baseada em EXIF. A imagem inteira é redimensionada para 224×224; ela não é recortada, segmentada ou centralizada automaticamente na lesão. Uma imagem retangular pode ter suas proporções modificadas por esse redimensionamento.

Para documentar o uso, confira se a região a analisar está visível e com resolução suficiente. Fotografias desfocadas, iluminação extrema, textos, molduras e marcas de origem podem alterar a entrada; o protótipo não detecta nem corrige automaticamente esses problemas. A escolha de exemplos para pesquisa deve seguir o protocolo do estudo, evitando selecionar somente resultados visualmente favoráveis.

Espaço reservado para figura

<pngs/manual_imagem_enquadramento.png>

Inserir o arquivo correspondente conforme o guia das figuras.

Figura 11 – Exemplo autorizado de preparação da fotografia e sua visualização no aplicativo. Indicar orientação e enquadramento antes da seleção; não representar um recorte automático inexistente. Fonte: elaboração do autor e captura do protótipo.

A.7 LEITURA DA CLASSIFICAÇÃO

O resultado apresenta a classe estimada, a pontuação associada à psoríase e medidas da execução. As classes legíveis correspondem aos códigos internos:

Código	Classe na interface	Regra no limiar de referência
`PSOR`	Psoríase	$p_{\mathrm{PSOR}} \geq 0{,}5$
`NonPsor`	Não é psoríase	$p_{\mathrm{PSOR}} < 0{,}5$

O limiar é lido dos metadados do modelo; o pacote da V5 utiliza 0,5. A pontuação exibida é $100p_{\mathrm{PSOR}}$, inclusive quando a classe estimada é negativa. Portanto, 8% significa pontuação PSOR de 0,08, e não "8% de acerto" da ferramenta. Não há calibração para interpretar esse valor como probabilidade clínica individual.

Para **Psoríase**, a mensagem associada é:

> Esta imagem foi associada pelo modelo à classe de psoríase. O resultado é experimental e não confirma um diagnóstico.

Para **Não é psoríase**, a mensagem é:

> Esta imagem foi associada pelo modelo à classe sem psoríase. O resultado é experimental e não descarta a condição.

A classe negativa reúne condições não psoriáticas do experimento e não significa necessariamente pele saudável. O aplicativo não identifica qual outra dermatose estaria presente. Grad-CAM, LIME e SHAP são produzidos no computador e não aparecem como funções nesta versão do APK.

Espaço reservado para figura

<pngs/manual_resultados_classes.png>

Inserir o arquivo correspondente conforme o guia das figuras.

Figura 12 – Duas capturas reais, uma por classe estimada, mostrando a imagem, a pontuação e a mensagem associada. Usar exemplos autorizados; identificar claramente os resultados como saídas experimentais. Fonte: capturas do protótipo.

A.8 RÓTULO DE REFERÊNCIA E REPETIÇÃO DA ANÁLISE

O campo **Rótulo de referência (opcional, para o CSV)** possui as opções *Não informado*, *Não é psoríase* e *Psoríase*. Use um rótulo apenas quando ele for conhecido por

uma fonte independente da predição. Se não houver referência, mantenha *Não informado*; não copie a classe estimada para preencher uma verdade de referência.

Mudar esse campo não altera a predição e **não reescreve um registro já concluído**. Para gerar um registro com a referência escolhida, selecione o rótulo e toque em **Analisar novamente** ou em **Medir desempenho • 30 inferências**. Cada ação concluída acrescenta uma nova linha à sessão. Ao selecionar outra fotografia, a referência é novamente reiniciada como *Não informado*.

Se houver múltiplos registros da mesma fotografia, eles não devem ser tratados como novos indivíduos ou novas imagens independentes em uma avaliação classificatória. O CSV não contém identificador de fotografia; para um estudo com várias imagens, mantenha externamente uma correspondência codificada entre protocolo, imagem e registros, sem acrescentar identificação pessoal.

A.9 MEDIÇÃO DE DESEMPENHO

A.9.1 Uma execução e benchmark

Analisar novamente relê a fotografia, refaz o pré-processamento e executa uma inferência. **Medir desempenho • 30 inferências** também prepara a imagem uma vez, realiza cinco aquecimentos e mede trinta inferências sobre a mesma entrada. Os aquecimentos não entram nas trinta latências nem em sua média, mediana ou p95; entram no tempo total da etapa e no uso de recursos observado durante ela.

A média resume as trinta latências, a mediana descreve seu centro e o p95 é o percentil 95 calculado por interpolação. A pontuação registrada é a saída da última inferência, não uma média de probabilidades de imagens diferentes. No modo de análise única, média, mediana e p95 são a mesma observação e não descrevem variabilidade.

A.9.2 O que está sendo temporizado

Carregamento

Criação da sessão ONNX da última abertura ou conferência; exclui cópia do ZIP e o autoteste completo.

Leitura

Abertura e decodificação da fotografia, incluindo a leitura prévia de suas dimensões.

Pré-processamento

Extração dos pixels, redimensionamento, normalização e criação da imagem de prévia.

Forward

Criação do tensor ONNX, execução da sessão e leitura da saída. A fotografia já foi decodificada e normalizada.

Tempo total da etapa

Inclui preparação e execuções, inclusive aquecimentos no benchmark, com custos de controle do processamento. Não equivale à soma apenas das trinta latências.

CPU do processo

Tempo acumulado de CPU durante a etapa. Pode diferir do tempo decorrido em relógio por causa do trabalho em múltiplas threads.

A.9.3 Memória e condições de comparação

A memória apresentada é o **PSS do processo Android**, com amostras aproximadamente a cada 50 ms. O pico é o maior valor observado nas amostras, e não uma garantia de capturar todo pico instantâneo. O PSS inclui o processo e sua parcela proporcional de memória compartilhada; não corresponde ao arquivo de pesos nem ao RSS medido no Python.

Para comparar sessões, mantenha aparelho, modelo, versão do app, imagem e modo de execução identificados. Registre também as condições de uso que possam influenciar o resultado. O protótipo não mede temperatura, consumo energético, nível de bateria ou atividade de outros aplicativos; essas condições dependem de documentação externa ou instrumentação posterior. O benchmark de trinta inferências descreve uma única imagem repetida e não substitui um estudo com várias imagens e aparelhos.

Espaço reservado para figura

<pngs/manual_benchmark.png>

Inserir o arquivo correspondente conforme o guia das figuras.

Figura 13 – Tela após um benchmark real, destacando mediana de trinta inferências, leitura, pré-processamento, pico observado de PSS e quantidade de registros. Não inserir tempos ilustrativos como resultados medidos. Fonte: captura do protótipo.

A.10 EXPORTAÇÃO E LEITURA DO CSV

1. Após ao menos uma análise concluída, toque em **Exportar medições em CSV**.

2. Escolha no seletor do Android o local e o nome do arquivo. O nome sugerido é `<medicoes_psorase.csv>`.

3. Aguarde a mensagem de exportação com a quantidade de registros.

4. Abra o arquivo salvo e confirme a presença dos cabeçalhos e das linhas esperadas antes de encerrar a coleta.

O arquivo exporta uma fotografia do conjunto de registros existente no momento da solicitação. A exportação não apaga a sessão; uma segunda exportação pode conter novamente as mesmas linhas. Ao combinar arquivos, utilize `id` para reconhecer registros repetidos. Encerrar ou recriar a atividade, inclusive por ação do Android, pode descartar os registros em memória. Exporte durante a coleta, antes de atualizar, reinstalar ou fechar o aplicativo.

O formato é UTF-8 com BOM e separador ponto e vírgula. Os números decimais são gravados com ponto. No Excel, utilize a importação de texto/CSV, confira UTF-8 e o delimitador e, quando necessário, configure a localidade de conversão dos campos numéricos. Não substitua indiscriminadamente pontos e vírgulas no arquivo. Fotografias, nomes de imagens e caminhos não são incluídos.

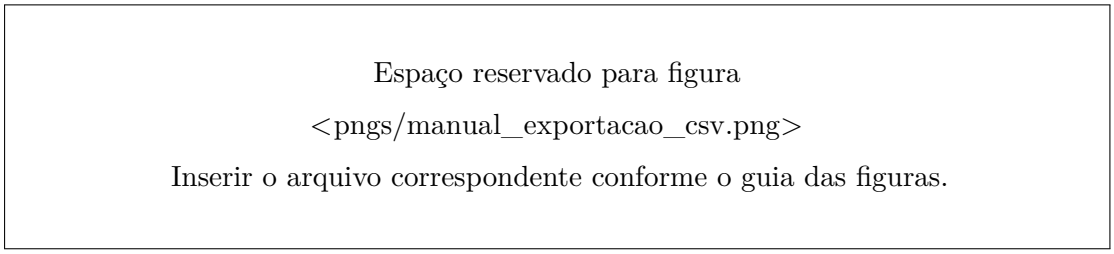


Figura 14 – Exportação concluída e exemplo de cabeçalhos de um CSV real, mostrando modelo, versão, modo e métricas. Ocultar caminhos pessoais e não apresentar dados fictícios como medições. Fonte: captura do fluxo e arquivo exportado.

A.10.1 Dicionário dos campos

Os nomes abaixo correspondem à implementação 0.1.2. Campos de latências adicionais aparecem quando há benchmark.

Campo ou grupo	Conteúdo e interpretação
`<id>`	Identificador único do registro, útil para reconhecer repetições entre exportações. Não identifica a imagem.
`<data_hora>`	Data e hora do registro com deslocamento de fuso, obtidas no aparelho.

Campo ou grupo	Conteúdo e interpretação
`<modo>`	`analise` ou `benchmark`.
`<modelo>`, `<semente>`	Arquitetura e semente lidas do pacote importado.
`<versao_app>`, `<onnxruntime>`	Versões do aplicativo e do mecanismo de execução.
`<modelo_sha256>`	Hash do arquivo ONNX usado no registro.
`<modelo_mib>`, `<apk_mib>`	Tamanhos dos arquivos do modelo e do APK em MiB. Não são uso de RAM.
`<aparelho>`, `<android>`, `<api_android>`, `<threads>`	Fabricante/modelo, versão e API Android e número de threads configurado.
`<rotulo_referencia>`, `<rotulo_referencia_texto>`	Código e descrição da referência opcional; o código fica vazio quando não informado.
`<classe_estimada>`, `<classe_estimada_texto>`	Código técnico e descrição legível da predição.
`<mensagem_resultado>`	Texto associado à classificação experimental.
`<p_psor>`, `<limiar>`	Pontuação PSOR entre zero e um e limiar usado para a decisão.
`<carregamento_modelo_ms>`	Tempo da última criação da sessão ONNX, em ms.
`<leitura_imagem_ms>`, `<preprocessamento_ms>`	Tempos de decodificação e preparação da fotografia, em ms.
`<forward_media_ms>`, `<forward_mediana_ms>`, `<forward_p95_ms>`	Resumos das inferências temporizadas.
`<medicoes_forward>`, `<aquecimentos>`	Quantidade de latências registradas e de aquecimentos.
`<forward_1_ms>` a `<forward_30_ms>`	Latências individuais. Na análise única, somente a primeira é preenchida.
`<tempo_total_etapa_ms>`	Tempo decorrido da etapa de análise ou benchmark.
`<cpu_processo_ms>`	Tempo acumulado de CPU do processo durante a etapa.
`<pss_inicial_mib>`, `<pss_pico_amostrado_mib>`, `<pss_final_mib>`	PSS inicial, maior amostra observada e amostra final do monitor.
`<pss_amostras>`, `<monitor_duracao_ms>`	Quantidade de amostras e duração do monitoramento.

A.11 SOLUÇÃO DE PROBLEMAS

Situação	Conferência e ação
Arquivo corrompido ou erro ao instalar	Utilize o APK completo e corrigido; extraia-o se estiver em ZIP. Confira tamanho/hash e compatibilidade Android/ARM. Diferencie truncamento do arquivo de conflito com versão já instalada.
Conflito com instalação anterior	Confira se a versão anterior é 0.1.0, cuja assinatura difere. Preserve CSVs e ZIP do modelo antes de eventual desinstalação.
Importe o modelo primeiro	O aplicativo está instalado, mas ainda não há modelo ativo. Importe `<modelo_android.zip>`.
Arquivo não permitido no pacote	Confirme que selecionou o ZIP do modelo, com a estrutura original, e não o projeto completo ou arquivos adicionais.
Entrada duplicada ou pacote maior que 120 MiB	Utilize um pacote produzido pelo exportador compatível; não reempacote múltiplos modelos no mesmo ZIP.
Assinatura do modelo diverge dos metadados	O SHA-256 do ONNX não coincide com o JSON. Recopie o pacote original ou exporte outra saída válida; não edite o hash para contornar o erro.
Pré-processamento ou inferência divergente	O autoteste não passou. Preserve a mensagem e a identificação do aparelho e do pacote para investigação. Não trate o modelo recusado como validado.
Formato não reconhecido ou falha de leitura	Abra a imagem em um visualizador, confirme que o arquivo está disponível localmente e selecione um formato decodificável.
Imagem maior que 16 megapixels	Prepare uma cópia de dimensão menor antes de selecionar. Essa preparação não é realizada automaticamente pelo app.
Fotografia aparece girada ou esticada	Oriente a imagem antes da seleção e confira o enquadramento. O app não corrige EXIF e redimensiona a imagem inteira para um quadrado.
Botões temporariamente desabilitados	Aguarde o término da tarefa. O modo benchmark executa várias inferências e pode demorar mais que a análise única.
CSV não contém o rótulo recém-selecionado	Selecione a referência e execute novamente a análise ou o benchmark. Registros anteriores não são alterados retroativamente.
Resultados desapareceram ao reabrir	As medições pertencem à sessão em memória. Use um CSV já exportado; o modelo persistente e os registros temporários têm comportamentos diferentes.

Se aparecer *Não foi possível salvar o CSV*, escolha um destino acessível no seletor

Android e confira o espaço disponível. A sessão continua precisando ser exportada enquanto estiver ativa.

Para relatar uma falha, registre a mensagem exata, fabricante e modelo do aparelho, versão do Android, versão do aplicativo e arquitetura/semente do pacote. Uma captura da tela pode auxiliar, desde que não exponha fotografias ou informações pessoais sem autorização.

A.12 ROTEIRO DE UMA SESSÃO DOCUMENTADA

1. Identifique aparelho, Android, versão do app e hash do modelo. Confirme o autoteste.
2. Defina previamente as imagens e a ordem de execução. Mantenha uma chave externa codificada para rastrear cada imagem.
3. Selecione a fotografia e aguarde a análise automática; registre que ela fica inicialmente sem referência.
4. Se houver rótulo conhecido, selecione-o e execute a etapa que será usada na coleta. Diferencie análise única de benchmark.
5. Aguarde a conclusão e confira a quantidade de registros. Não interprete as trinta repetições como trinta imagens independentes.
6. Exporte o CSV e confira a gravação. Ao agregar exportações, reconheça linhas repetidas por seu `id`.
7. Guarde o protocolo, os CSVs e a identificação dos arquivos associados. Separe a análise de desempenho computacional de uma avaliação classificatória ou clínica.

O manual descreve o comportamento implementado. As figuras reservadas devem ser preenchidas com capturas da versão correspondente, sem alterar resultados ou acrescentar funcionalidades inexistentes.

APÊNDICE B – REPRODUTIBILIDADE E ORGANIZAÇÃO DOS ARQUIVOS

B.1 IDENTIFICAÇÃO DO EXPERIMENTO

A execução de referência é a pasta `<Resultados_Rinha_V5/20261022_151228_934149>`. O arquivo `<configuracao.json>` registra as seis arquiteturas, as sementes 42, 123 e 2026, os parâmetros de treinamento, as versões de software e a assinatura dos dados. O arquivo `<modelo_selecionado.json>` identifica EfficientNet-B0, semente 2026, e o critério de validação utilizado.

O código-fonte associado ao processo é `<rinha_modelos_v5.py>`. A identificação registrada pelo relatório é:

<718cab1a042f60e5393d7886098d0491a632b9f5e47f9c330d8e5ef66939a7a7>

O pacote de documentação inclui uma cópia do script disponível para conferência. Sua identidade é registrada no arquivo de conferência; alterações futuras devem ter nova identificação. O código e seus parâmetros devem corresponder à execução utilizada nas tabelas, sem misturar versões do experimento.

B.2 ESTRUTURA DAS SAÍDAS

<csv/>

Manifesto de imagens, resultados individuais, resumo por arquitetura, checkpoints representativos, históricos, predições, matrizes, latências e recursos.

<png/>

Figuras de síntese, matrizes de confusão, recursos, curvas ROC, evolução de validação e painéis de explicabilidade.

<checkpoints/>

Pesos de cada arquitetura e semente. O selecionado para o aplicativo é `<efficientnet_b0_s2026.pt>`.

<dados/>

Resultados intermediários, mapas numéricos e descrições de classificação.

<logs/>

Registros de execução e eventuais erros.

<relatorio_final.html>

Síntese visual com figuras incorporadas, configuração e ambiente.

<resumo_final.txt>

Resumo textual das métricas e do estado das execuções.

As médias e os desvios entre sementes devem ser conferidos nos resultados agregados. Matrizes e curvas de checkpoints representativos não devem ser descritas como médias. A pasta de uma execução é a unidade de rastreabilidade: dados, configuração, pesos e relatório devem permanecer associados.

B.3 COMANDOS DE MANUTENÇÃO

Para o experimento já concluído, não é necessário executar novamente o separador. No diretório que contém o script, a verificação inicial pode ser acionada por

```
python rinha_modelos_v5.py --verificar
```

Para reconstruir apenas o relatório ou as explicações, substituir `PASTA_V5` pela pasta completa da execução:

```
python rinha_modelos_v5.py --so-relatorio "PASTA_V5"
python rinha_modelos_v5.py --so-explicabilidade "PASTA_V5"
```

A opção `-retomar` destina-se à continuação de uma execução compatível e exige consistência de dados, configuração, código e versões. Alterar a base ou os parâmetros não é mera atualização editorial do relatório: requer novo registro experimental.

B.4 COMPUTADOR E CELULAR: MEDIDAS DIFERENTES

No computador, o benchmark de rede temporiza forward e sigmoide com entrada preparada; a memória é RSS do processo Python. No Android, o forward inclui criação do tensor ONNX, execução e leitura da saída; a memória é PSS do processo do aplicativo. Os arquivos originais devem preservar essas definições. Uma comparação entre plataformas pode colocar as medidas lado a lado com seus escopos, mas não deve tratá-las como variáveis idênticas ou como consumo energético.

APÊNDICE C – RESULTADOS GRÁFICOS COMPLEMENTARES

As figuras deste apêndice foram extraídas sem alteração das imagens incorporadas no relatório final V5 anexado. As curvas ROC representam checkpoints escolhidos pela validação, enquanto os resumos entre sementes permanecem nas tabelas do capítulo de resultados.

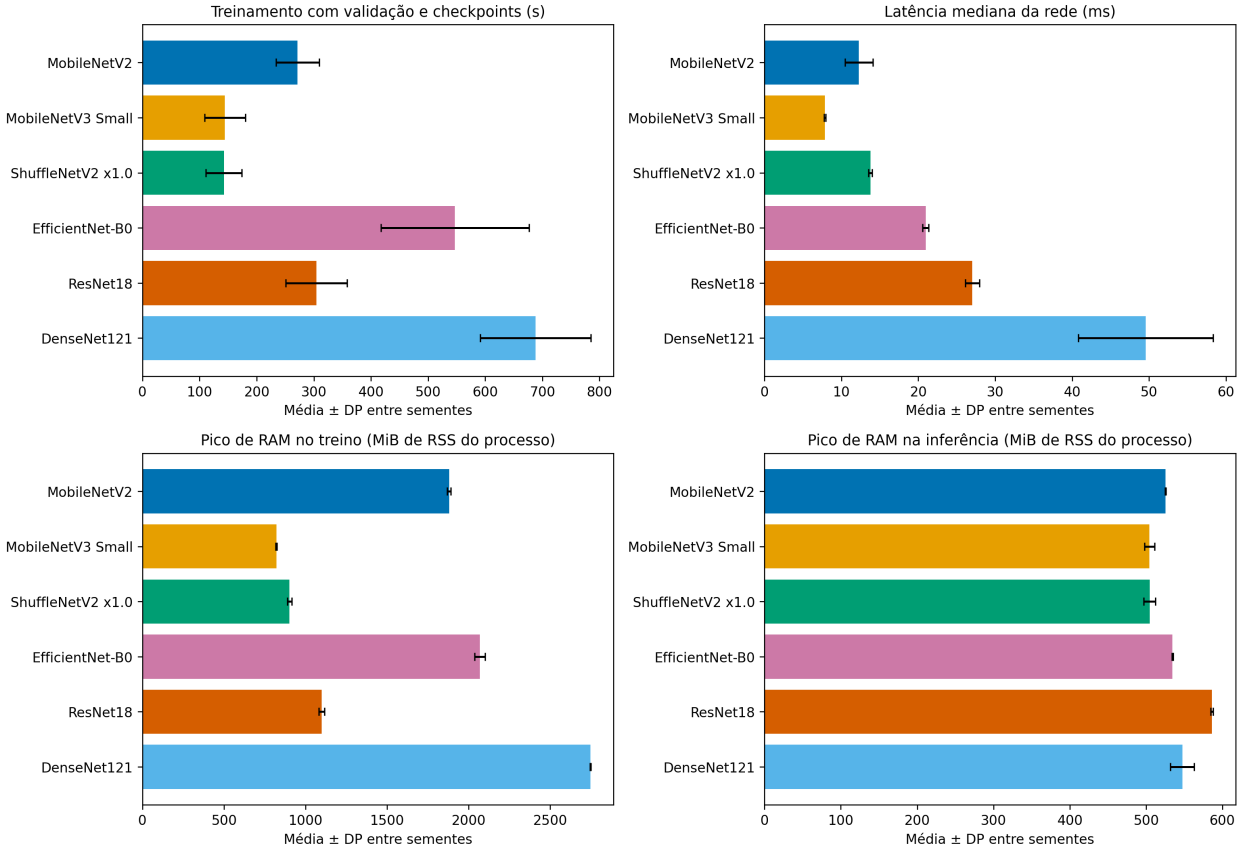


Figura 15 – Síntese de tempo e memória no computador. As definições dos relógios e de RSS estão nos métodos; não são medições de bateria ou do processo Android. Fonte: Autor.

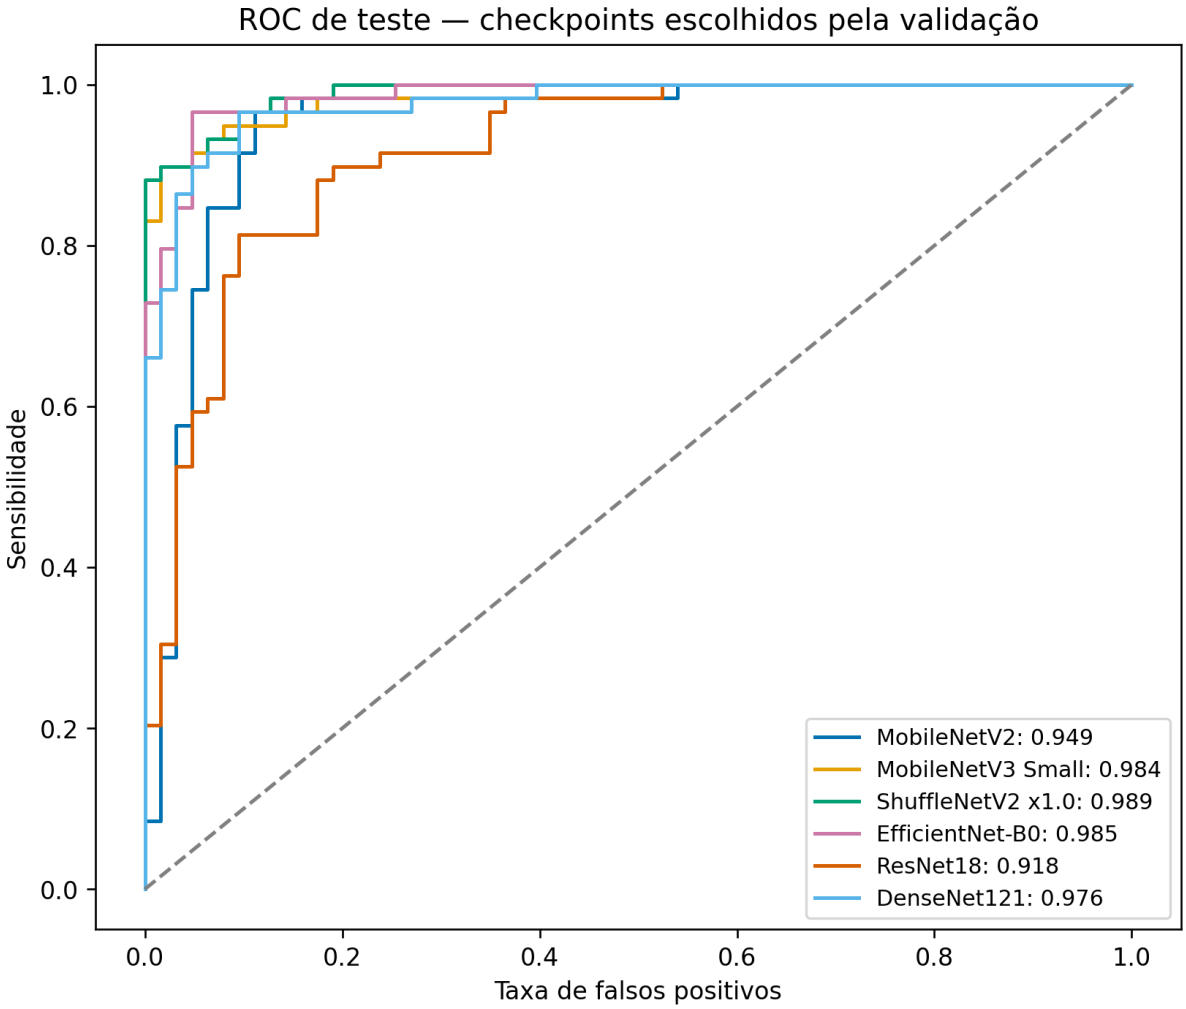


Figura 16 – Curvas ROC de teste dos checkpoints representativos escolhidos pela validação. AUCs individuais não devem ser confundidas com médias entre sementes. Fonte: Autor.

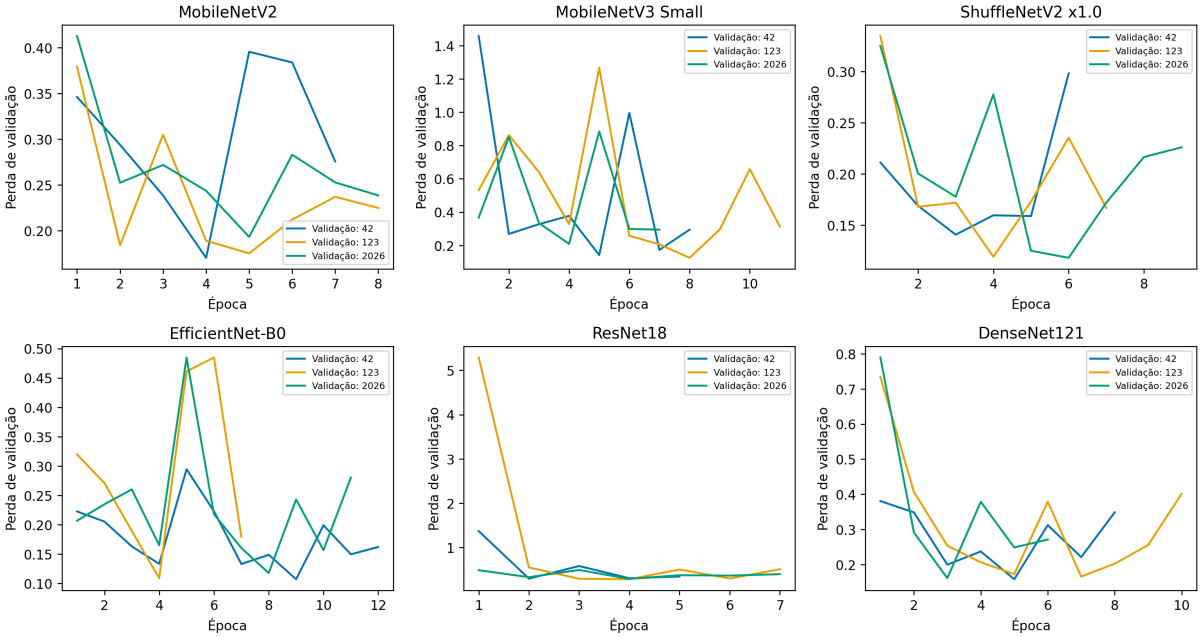


Figura 17 – Evolução de validação dos checkpoints apresentados pelo relatório. O checkpoint de cada execução é determinado pela menor perda de validação. Fonte: Autor.