



UNIVERSIDADE FEDERAL DA PARAÍBA

Programa de Pós-Graduação em Modelos de Decisão e Saúde

Sistema de Suporte ao Diagnóstico de Psoríase usando Aprendizado de Máquina

GUILHERME VIEIRA MUNIZ

João Pessoa
2026

GUILHERME VIEIRA MUNIZ

Sistema de Suporte ao Diagnóstico de Psoríase usando Aprendizado de Máquina

Dissertação apresentada ao Programa de Pós-Graduação em Modelos de Decisão e Saúde da Universidade Federal da Paraíba, como requisito para obtenção do título de Mestre em Modelos de Decisão e Saúde.

UNIVERSIDADE FEDERAL DA PARAÍBA
Programa de Pós-Graduação em Modelos de Decisão e Saúde

Orientadora: Profª. Dra. Esther Bastos Palitot de Brito
Coorientador: Prof. Zildomar Carlos Féliz

João Pessoa
2026

AGRADECIMENTOS

Agradeço, primeiramente, à minha esposa pelo apoio, pela compreensão e pelo incentivo ao longo de toda esta trajetória. A conclusão deste trabalho representa não apenas o encerramento de uma importante etapa acadêmica, mas também o resultado do suporte recebido durante os desafios e aprendizados vivenciados ao longo do mestrado.

À minha orientadora, Profa. Esther Bastos Palitot de Brito, agradeço pela orientação, pela disponibilidade, pelas contribuições acadêmicas e pelo acompanhamento durante o desenvolvimento desta dissertação. Suas considerações foram fundamentais para o amadurecimento deste trabalho e para minha formação no Programa de Pós-Graduação em Modelos de Decisão e Saúde.

Ao Prof. Ronei Marcos de Moraes, registro meu sincero agradecimento pela orientação recebida ao longo do mestrado. Sua participação em minha trajetória acadêmica, suas contribuições, ensinamentos e direcionamentos foram importantes para a construção e o desenvolvimento desta pesquisa.

Ao Prof. Zildomar Carlos Féliz, que passou a integrar formalmente a orientação deste trabalho após esse processo, agradeço pela disponibilidade em assumir essa responsabilidade e pelas contribuições oferecidas para a conclusão desta etapa.

Aos professores do Programa de Pós-Graduação em Modelos de Decisão e Saúde da Universidade Federal da Paraíba (PPGMDS/UFPB), agradeço pelos conhecimentos compartilhados, pelas discussões e pelas experiências acadêmicas que contribuíram para minha formação científica e profissional.

Aos colegas do Programa, agradeço pelas trocas de experiências, pelo companheirismo e pelas discussões que, direta ou indiretamente, contribuíram para o desenvolvimento desta pesquisa e tornaram essa trajetória mais enriquecedora.

Ao Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), agradeço pela concessão da bolsa de estudos que proporcionou suporte durante minha formação no mestrado e contribuiu para a realização desta pesquisa.

Por fim, agradeço a todas as pessoas que, de alguma maneira, estiveram presentes nesta trajetória e contribuíram para que este trabalho pudesse ser concluído.

RESUMO

A psoríase é uma doença inflamatória crônica cujas manifestações cutâneas motivam a investigação de ferramentas computacionais de apoio à análise de imagens. Este trabalho comparou redes neurais convolucionais para classificação binária entre psoríase e condições não psoriáticas, considerando desempenho preditivo e recursos computacionais, e integrou o modelo selecionado a um protótipo Android. O conjunto experimental reuniu 798 imagens de tronco, braços, pernas, nádegas e algumas dobras cutâneas, sem incluir cabeça, unhas, pés ou regiões íntimas. Foram utilizadas 558 imagens para treinamento, 118 para validação e 122 para teste, com 386 registros PSOR e 412 NonPsor. MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0, EfficientNet-B0, ResNet18 e DenseNet121 foram ajustadas em três sementes, totalizando 18 execuções em CPU. A seleção utilizou o maior F1 médio de validação, com AUC média como desempate. A EfficientNet-B0 foi selecionada e apresentou, no teste, F1 de $0{,}919 \pm 0{,}023$ e AUC de $0{,}974 \pm 0{,}010$. A MobileNetV2 alcançou F1 de $0{,}918 \pm 0{,}018$ com menor latência que a EfficientNet-B0; a MobileNetV3 Small apresentou a menor latência da comparação. Grad-CAM, LIME e SHAP foram aplicados a quatro imagens para inspeção exploratória das respostas. O checkpoint EfficientNet-B0 da semente 2026 foi exportado para ONNX e verificado em 122 imagens, com erro absoluto máximo de $1{,}7285347 \times 10^{-6}$ e preservação das decisões classificatórias. O aplicativo implementou importação de modelo por ZIP, autoteste, inferência local, instrumentação de tempo e memória e exportação de registros em CSV.

Palavras-chave: psoríase; redes neurais convolucionais; eficiência computacional; explicabilidade; inferência local.

ABSTRACT

Psoriasis is a chronic inflammatory disease whose cutaneous manifestations motivate the investigation of computational tools for image analysis. This study compared convolutional neural networks for binary classification of psoriasis and non-psoriatic conditions, considering predictive performance and computational resources, and integrated the selected model into an Android prototype. The experimental dataset comprised 798 images of the trunk, arms, legs, buttocks, and selected skin folds; head, nails, feet, and intimate regions were excluded. The dataset included 558 training, 118 validation, and 122 test images, with 386 PSOR and 412 NonPsor records. MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0, EfficientNet-B0, ResNet18, and DenseNet121 were fine-tuned using three random seeds, totaling 18 CPU runs. Architecture selection used the highest mean validation F1, with mean validation AUC as a tie-breaker. EfficientNet-B0 was selected and achieved a test F1 of 0.919 ± 0.023 and AUC of 0.974 ± 0.010. MobileNetV2 achieved an F1 of 0.918 ± 0.018 with lower latency than EfficientNet-B0, while MobileNetV3 Small had the lowest latency in the comparison. Grad-CAM, LIME, and SHAP were applied to four images for exploratory inspection of model responses. The EfficientNet-B0 checkpoint from seed 2026 was exported to ONNX and checked on 122 images, yielding a maximum absolute error of 1.7285347×10^{-6} and preserving classification decisions. The application implemented ZIP model import, self-testing, on-device inference, time and memory instrumentation, and CSV export. These deliverables connect the experimental comparison to execution on the device, supported by documented code, artifacts, and a user manual.

Keywords: psoriasis; convolutional neural networks; computational efficiency; explainability; on-device inference.

LISTA DE ILUSTRAÇÕES

Figura 1 – Subtipos clínicos de psoríase com manifestações características. Fonte: (BRASIL, 2021) 15
Figura 2 – Exemplos de dermatoses que compõem o diagnóstico diferencial da psoríase. 16
Figura 3 – Esquema didático do processamento em uma rede neural convolucional, da imagem de entrada à saída de classificação. A organização dos blocos e das operações varia conforme a arquitetura. Fonte: elaboração do autor. 19
Figura 4 – EfficientNet-B0 adaptada ao estudo: (A) etapas da rede, com dimensões na saída de cada grupo; (B) operações de um MBConv e condição para o atalho residual. BN indica normalização em lotes. Fonte: elaboração do autor, com base em Tan e Le (2019) e na implementação Torchvision utilizada. 23
Figura 5 – Fluxo de desenvolvimento e avaliação. A validação orienta a seleção da arquitetura e dos checkpoints representativos; o teste caracteriza os checkpoints das 18 execuções e não integra os critérios de seleção. A integração ao Android utiliza o modelo selecionado. Fonte: elaboração do autor. 33
Figura 6 – Estratégia de levantamento e organização do material bibliográfico de apoio. Fonte: elaboração do autor. 34
Figura 7 – Organização da integração Android: no computador, exportação e conferência do modelo; no dispositivo, importação do ZIP, autoteste, preparação da imagem, inferência em CPU e apresentação da resposta, com exportação local de medições. Fonte: elaboração do autor. 45
Figura 8 – Síntese do desempenho classificatório e da latência em CPU para as seis arquiteturas. As barras de variabilidade representam o desvio entre sementes na partição fixa; os tempos são do computador, não do aplicativo Android. Fonte: Autor. 52
Figura 9 – Matrizes de teste de checkpoints escolhidos pela validação. Linhas: classe real; colunas: classe estimada. Os percentuais são calculados por linha, e a escala de cor é comum a todos os painéis. Para PSOR como classe positiva, a célula superior direita indica falsos positivos e a inferior esquerda, falsos negativos. Fonte: Autor. 53

Figura 10 – Comparação das explicações produzidas por LIME, SHAP e Grad-CAM para os exemplos 03_PSOR e 04_PSOR, utilizando a EfficientNet-B0, semente 2026. Todas as explicações se referem à saída PSOR. A intensidade das cores foi ajustada separadamente em cada mapa. Fonte: saídas do experimento. 55
Figura 11 – Capturas de uma sessão do Sistema de Suporte ao Diagnóstico de Psoríase. Os valores visíveis documentam um registro pontual de uso e não constituem uma série de avaliação em aparelhos. Fonte: registros de tela fornecidos pelo autor. 57
Figura 12 – Fluxo de importação e autoteste do modelo no celular. A ativação depende da aprovação das verificações técnicas; se houver recusa, o modelo anterior aprovado é preservado. Fonte: elaboração do autor. . . 77
Figura 13 – Preparação da fotografia pelo usuário e etapas executadas pelo aplicativo. A orientação e o enquadramento antecedem a seleção; a imagem inteira é redimensionada e normalizada. Fonte: elaboração do autor. 78
Figura 14 – Regras de classificação e mensagens associadas às classes Psoríase e Não é psoríase. O esquema utiliza o limiar 0,5 do pacote V5 e não representa uma predição de imagem específica. Fonte: elaboração do autor. 79
Figura 15 – Protocolo de medição do aplicativo: preparação da entrada, cinco aquecimentos e trinta inferências temporizadas sobre a mesma fotografia. O esquema diferencia estatísticas de latência e memória PSS; não apresenta medições experimentais. Fonte: elaboração do autor. 81
Figura 16 – Fluxo de exportação e exemplos de campos previstos no CSV. São apresentados cabeçalhos e orientações de leitura, sem linhas de medições. Fonte: elaboração do autor. 82
Figura 17 – Síntese de tempo e memória dos modelos no computador, apresentada em página girada para ampliar a leitura. Fonte: relatório V5. 91
Figura 18 – Curvas ROC de teste dos checkpoints representativos escolhidos pela validação. AUCs individuais não devem ser confundidas com médias entre sementes. Fonte: Autor. 92
Figura 19 – Evolução de validação dos checkpoints apresentados pelo relatório. O checkpoint de cada execução é determinado pela menor perda de validação. Fonte: Autor. 93

LISTA DE TABELAS

Tabela 1 – Categorias temáticas dos 36 estudos selecionados no levantamento bibliográfico 17
Tabela 2 – Exemplos da evolução das aplicações computacionais à psoríase e à análise móvel de imagens cutâneas 18
Tabela 3 – Distribuição das imagens do conjunto final segundo a origem indicada nos registros de coleta 36
Tabela 4 – Distribuição das imagens entre os conjuntos experimentais 37
Tabela 5 – Implementações e dimensões das redes adaptadas à classificação binária 39
Tabela 6 – Desempenho no teste: média e desvio-padrão entre as três sementes . . 49
Tabela 7 – Complexidade e tempos em CPU: cada resumo de latência é agregado entre sementes 50
Tabela 8 – Picos observados de RSS do processo Python 51
Tabela 9 – Contagens de teste dos checkpoints representativos escolhidos pela validação 53
Tabela 10 – Indicadores da explicabilidade: alvo PSOR nos quatro exemplos 54
Tabela 13 – Organização dos principais artefatos publicados no repositório 87

SUMÁRIO

1 INTRODUÇÃO 11
1.1 Contextualização do problema 11
1.2 Relevância científica 12
1.3 Objetivos do trabalho 13

2 REVISÃO DA LITERATURA 14
2.1 Psoríase: aspectos clínicos e epidemiológicos 14
2.2 Diagnóstico diferencial e desafios 16
2.3 Aprendizado de máquina em dermatologia 17
2.4 Redes neurais convolucionais 18
2.5 Fundamentos das arquiteturas comparadas 20
2.5.1 Convoluções separáveis e blocos móveis 20
2.5.2 MobileNetV2: expansão e gargalo linear 21
2.5.3 MobileNetV3 Small: atenção por canais e ativações eficientes 21
2.5.4 ShuffleNetV2 x1.0: divisão e reorganização dos canais 22
2.5.5 EfficientNet-B0: blocos MBConv e dimensionamento composto 22
2.5.6 ResNet18: aprendizagem de transformações residuais 24
2.5.7 DenseNet121: conectividade densa e reutilização de características 25
2.5.8 Saída binária e função de aprendizagem 25
2.6 Transferência de aprendizado 26
2.7 Explicabilidade e interpretabilidade 27
2.7.1 Grad-CAM 27
2.7.2 LIME 27
2.7.3 SHAP 28
2.7.4 Apresentação e leitura conjunta 28
2.8 Trabalhos relacionados 29

3 MATERIAIS E MÉTODOS 32
3.1 Desenho do estudo e fluxo de desenvolvimento 32
3.2 Levantamento bibliográfico de apoio 33
3.3 Base de imagens, procedência e preparação dos conjuntos 34
3.3.1 Recorte anatômico e classes 35
3.3.2 Distribuição por fonte de origem 35
3.3.3 Conjunto experimental e partição 36
3.4 Modelagem e treinamento dos classificadores 37

3.4.1 Pré-processamento e aumento de dados . . . 38
3.4.2 Arquiteturas comparadas e adaptação para a tarefa . . . 38
3.4.3 Treinamento, repetição e seleção . . . 39
3.5 Avaliação classificatória, recursos e explicabilidade . . . 41
3.5.1 Métricas classificatórias . . . 41
3.5.2 Medição de tempo e memória no computador . . . 42
3.5.3 Protocolo de explicabilidade exploratória . . . 43
3.6 Desenvolvimento e integração do protótipo Android . . . 44
3.6.1 Plataforma de desenvolvimento e organização funcional . . . 44
3.6.2 Exportação ONNX e critérios de equivalência . . . 44
3.6.3 Importação, verificação e persistência do modelo . . . 46
3.6.4 Preparação da fotografia e apresentação da classificação . . . 46
3.6.5 Instrumentação no aparelho e exportação dos registros . . . 47
3.7 Ambiente computacional e rastreabilidade . . . 47
3.8 Aspectos éticos e âmbito de utilização . . . 48

4 RESULTADOS . . . 49
4.1 Cobertura experimental e seleção . . . 49
4.2 Desempenho classificatório . . . 49
4.3 Desempenho e recursos computacionais . . . 50
4.4 Matrizes de confusão dos checkpoints representativos . . . 52
4.5 Explicabilidade exploratória . . . 53
4.6 Protótipo Android e integração do modelo . . . 55
4.6.1 Modelo exportado e conferência numérica . . . 56
4.6.2 Interface e fluxo de utilização . . . 56
4.6.3 Registros, disponibilização e alcance das verificações . . . 57
4.7 Síntese dos resultados . . . 58

5 DISCUSSÃO . . . 59
5.1 Contribuição da comparação ao desenvolvimento da ferramenta . . . 59
5.2 Desempenho classificatório e requisitos de implantação . . . 60
5.3 Explicabilidade e inspeção das respostas . . . 61
5.4 Composição do acervo e alcance da avaliação . . . 62
5.5 Integração Android e continuidade da avaliação . . . 63

6 CONCLUSÃO . . . 64
6.1 Perspectivas de continuidade . . . 64

REFERÊNCIAS BIBLIOGRÁFICAS . . . 66

APÊNDICES 72

APÊNDICE A – MANUAL DE UTILIZAÇÃO DO APLICATIVO 73

A.1 Finalidade e visão geral 73

A.2 Arquivos e requisitos 73

A.2.1 Diferenciar os três pacotes 73

A.2.2 Requisitos do aparelho 74

A.3 Instalação e atualização 74

A.3.1 Primeira instalação 74

A.3.2 Atualizar uma instalação existente 75

A.4 Preparação e exportação no computador 75

A.4.1 Quando esta etapa é necessária 75

A.4.2 Identificar a execução correta 75

A.4.3 Conferir a aprovação 76

A.5 Importação e autoteste no celular 76

A.6 Seleção e preparação da fotografia 77

A.7 Leitura da classificação 78

A.8 Rótulo de referência e repetição da análise 79

A.9 Medição de desempenho 80

A.9.1 Uma execução e benchmark 80

A.9.2 O que está sendo temporizado 80

A.9.3 Memória e condições de comparação 81

A.10 Exportação e leitura do CSV 81

A.10.1 Dicionário dos campos 83

A.11 Solução de problemas 84

A.12 Roteiro de uma sessão documentada 85

APÊNDICE B – REPRODUTIBILIDADE E ORGANIZAÇÃO DOS ARQUIVOS 87

B.1 Disponibilidade dos artefatos e identificação da versão 87

B.2 Identificação do experimento 88

B.3 Estrutura das saídas 88

B.4 Comandos de manutenção 89

B.5 Computador e celular: medidas diferentes 89

APÊNDICE C – RESULTADOS GRÁFICOS COMPLEMENTARES 90

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO DO PROBLEMA

A psoríase é uma doença inflamatória crônica, de natureza imunomediada, cuja expressão cutânea pode envolver placas eritematosas e descamativas em diferentes regiões do corpo. Além dos sinais visíveis, a condição repercute na qualidade de vida e pode estar associada a estigma e sofrimento emocional, tornando seu reconhecimento e acompanhamento relevantes para o cuidado em saúde (BRASIL, 2021; SILVA; SILVA, 2007). Sua apresentação varia entre indivíduos e formas clínicas, o que precisa ser considerado ao investigar ferramentas de análise de imagens.

O diagnóstico é predominantemente clínico e considera as características das lesões e as informações obtidas na avaliação do paciente. Fotografias de apresentações atípicas podem compartilhar elementos com outras dermatoses, como eczemas, dermatites e infecções fúngicas, exigindo atenção ao diagnóstico diferencial (BRASIL, 2021; GRIFFITHS; BARKER, 2007). Essa diversidade motiva a investigação de métodos computacionais que contribuam para organizar a análise visual e possam ser avaliados como componentes de apoio ao julgamento profissional.

Na análise computacional de imagens cutâneas, o aprendizado de máquina permite estimar relações entre características visuais e rótulos de referência. As redes neurais convolucionais, pertencentes ao aprendizado profundo, aprendem representações a partir dos exemplos e têm sido investigadas em tarefas como classificação, segmentação e avaliação de gravidade (JEONG et al., 2023; YU et al., 2020; MCMULLEN et al., 2025). Esses objetivos produzem resultados de naturezas distintas: atribuir uma fotografia a uma classe não equivale a medir a extensão da doença ou estabelecer um diagnóstico no contexto de atendimento.

Quando a finalidade inclui uma aplicação móvel, o desempenho preditivo precisa ser examinado juntamente com os recursos de execução. Memória disponível, capacidade de processamento e implementação dos operadores participam da viabilidade do modelo no dispositivo. Arquiteturas compactas procuram responder a essas restrições por organizações diferentes de filtros, canais e conexões; sua adequação à tarefa, contudo, depende de comparação nas condições de interesse (OTA et al., 2017; SANDLER et al., 2018; MA et al., 2018). A documentação de latência, memória e tamanho dos artefatos acrescenta, assim, uma dimensão necessária à escolha da rede.

A implantação também requer preparar o modelo treinado para uma biblioteca de inferência e conectá-lo ao fluxo de uso do aplicativo. O formato ONNX e o ONNX Runtime oferecem recursos para essa passagem entre ambientes, permitindo executar no aparelho um

artefato exportado do treinamento (PyTorch, [s.d.]c; ONNX Runtime, [s.d.]b). A execução local é pertinente ao projeto porque reduz a dependência de conectividade durante a análise e possibilita acompanhar o processamento por meio de registros produzidos no próprio dispositivo.

O tratamento de imagens de saúde deve considerar sua procedência, a finalidade de utilização e as informações que possam identificar indivíduos. A Lei Geral de Proteção de Dados Pessoais (LGPD) define como sensíveis os dados referentes à saúde quando vinculados a uma pessoa natural (Brasil, 2018). Essa atenção ao ciclo das informações dialoga com a proteção da privacidade desde a concepção dos sistemas (CAVOUKIAN; JONAS, 2012). No protótipo investigado, a fotografia é processada no aparelho, e os arquivos de medição se concentram nos dados técnicos da execução.

Nesse contexto, esta dissertação compara seis redes convolucionais na classificação binária de fotografias entre PSOR e NonPsor e integra o checkpoint selecionado a uma aplicação Android. O trabalho utiliza imagens secundárias e articula avaliação interna, medição de recursos, explicabilidade exploratória e desenvolvimento de software. A proposta oferece um processo documentado para investigar o classificador e sua execução local, estabelecendo uma base para ensaios em dispositivos e avaliações assistenciais posteriores.

1.2 RELEVÂNCIA CIENTÍFICA

A relevância deste trabalho está na articulação entre desempenho classificatório, custo computacional e implementação de uma ferramenta experimental de apoio à análise dermatológica. A comparação de arquiteturas sob um protocolo comum permite examinar quais redes oferecem alternativas para ambientes com restrições de memória e processamento, sem reduzir a escolha à acurácia isolada. A execução em três sementes, os registros de recursos e a separação entre seleção por validação e avaliação no teste conferem rastreabilidade ao processo.

Na interface entre computação e saúde, a pesquisa produz três entregas complementares: uma avaliação interna de seis CNNs, uma análise exploratória de suas explicações visuais no checkpoint selecionado e um protótipo Android capaz de executar o modelo localmente. O aplicativo amplia o alcance aplicado do estudo ao demonstrar a integração entre o experimento e uma interface de uso, com importação independente dos pesos e exportação de medições. A avaliação assistencial permanece uma etapa própria, que poderá utilizar essa base técnica já implementada.

A inferência local também permite explorar formas de processamento sem envio das fotografias a um servidor. Essa característica é pertinente à pesquisa em saúde digital, pois reduz a dependência de conectividade para a execução e oferece maior controle sobre o fluxo das imagens. O estudo, assim, contribui com um processo documentado que pode ser

ampliado em investigações sobre desempenho em aparelhos, auditoria de explicabilidade e avaliação com profissionais de saúde.

1.3 OBJETIVOS DO TRABALHO

Objetivo geral

Desenvolver e avaliar um sistema experimental de suporte à classificação de imagens de psoríase, integrando a comparação de arquiteturas convolucionais, a análise de eficiência computacional, a explicabilidade exploratória e a implementação de inferência local em um protótipo Android.

Objetivos específicos

- Organizar e auditar uma base de imagens de psoríase e de condições não psoriáticas, mantendo rastreável sua distribuição em treinamento, validação e teste.
- Comparar seis arquiteturas pré-treinadas em três sementes, sob um protocolo comum de ajuste fino e avaliação.
- Avaliar F1 da classe psoríase, sensibilidade, especificidade, AUC, acurácia e concordância, mantendo a seleção da arquitetura restrita à validação.
- Medir tempo de execução, latência, memória do processo, número de parâmetros e tamanho dos checkpoints.
- Aplicar Grad-CAM, LIME e SHAP a uma amostra exploratória do checkpoint selecionado, documentando parâmetros, status e limites de interpretação.
- Exportar o modelo selecionado para ONNX e verificar a equivalência numérica e classificatória em relação ao modelo PyTorch.
- Implementar um aplicativo Android com importação de modelo, inferência local, medição de recursos e exportação em CSV, acompanhado de manual de utilização.

2 REVISÃO DA LITERATURA

A fundamentação do estudo parte das características clínicas da psoríase e das dificuldades de sua diferenciação por imagem, avançando para os métodos computacionais utilizados nessa tarefa. Em seguida, são apresentados os princípios das redes convolucionais, os mecanismos das seis arquiteturas comparadas, a transferência de aprendizado e as técnicas de explicabilidade. Esse percurso permite relacionar as escolhas do experimento aos problemas investigados na literatura e à finalidade de inferência local do protótipo.

O levantamento reuniu trabalhos sobre classificação, segmentação, avaliação de gravidade e outras aplicações de inteligência artificial à psoríase. Como essas tarefas utilizam desfechos e unidades de análise distintos, sua apresentação considera o contexto em que cada resultado foi produzido. A estratégia de busca e organização desse material está descrita na Seção 3.2; os estudos mais próximos à proposta são discutidos na Seção 2.8.

2.1 PSORÍASE: ASPECTOS CLÍNICOS E EPIDEMIOLÓGICOS

A psoríase é uma doença inflamatória crônica da pele que apresenta diferentes formas clínicas, as quais podem variar quanto à morfologia das lesões, extensão do acometimento cutâneo e gravidade. Essas variações podem, em determinados contextos clínicos, ser confundidas com outras dermatoses, especialmente a depender da região corporal afetada e do estágio evolutivo das placas eritematosas.

Clinicamente, a forma mais comum é a psoríase em placas (ou psoríase vulgar), responsável por aproximadamente 75% a 90% dos casos. Caracteriza-se por lesões eritematosas bem delimitadas, recobertas por escamas prateadas, com predileção por regiões como cotovelos, joelhos, couro cabeludo e região lombar. Em alguns casos, pode haver também o acometimento ungueal (GRIFFITHS; BARKER, 2007; BRASIL, 2021).

Além da forma em placas, outras variantes clínicas relevantes para a contextualização incluem a psoríase gutata e a psoríase eritrodérmica. A psoríase gutata manifesta-se por múltiplas lesões pequenas, em formato de gotas, frequentemente associadas a infecções estreptocócicas prévias, sendo mais comum em crianças e adultos jovens. Já a psoríase eritrodérmica representa uma forma grave e potencialmente ameaçadora à vida, caracterizada por eritema difuso e descamação generalizada, podendo comprometer a termorregulação e o estado geral do paciente (BRASIL, 2021).

Outras manifestações, como acometimento invertido, pustuloso, articular, ungueal e do couro cabeludo, apresentam particularidades clínicas. A Figura 1 contextualiza a diversidade de apresentações (GRIFFITHS; BARKER, 2007).



(a) Psoríase em placas



(b) Psoríase eritrodérmica



(c) Psoríase gutata



(d) Psoríase pustulosa

Figura 1 – Subtipos clínicos de psoríase com manifestações características. Fonte: (BRASIL, 2021)

Do ponto de vista fisiopatológico, a psoríase resulta de uma ativação exacerbada da resposta imune inata e adaptativa, com papel central das células T, particularmente Th1, Th17 e Th22. Essa ativação leva à hiperproliferação dos queratinócitos e à inflamação crônica da epiderme. A produção excessiva de citocinas inflamatórias, como TNF-α, IL-17 e IL-23, tem sido alvo de terapias biológicas modernas (LOWES; BOWCOCK; KRUEGER, 2007).

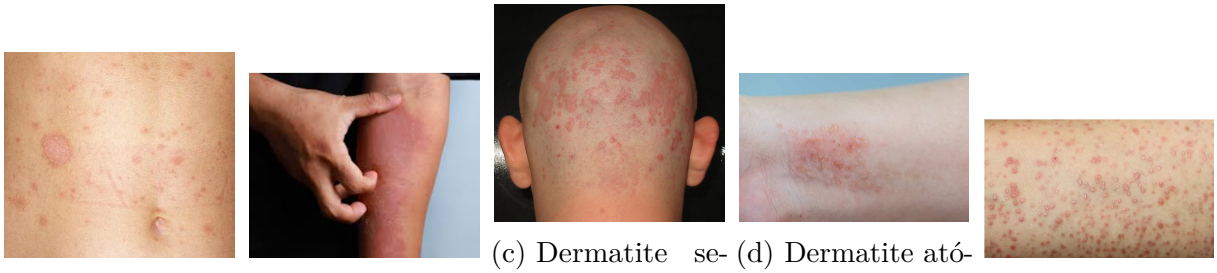
Além dos sintomas dermatológicos, a psoríase está associada a diversas comorbidades sistêmicas, incluindo artrite psoriásica (presente em até 30% dos casos), síndrome metabólica, obesidade, diabetes tipo 2, hipertensão arterial e risco cardiovascular aumentado. Tais associações reforçam seu caráter sistêmico e a necessidade de abordagem multidisciplinar no cuidado ao paciente (BOEHNCKE, 2018; TAKESHITA et al., 2017).

Do ponto de vista epidemiológico, há um predomínio da doença em adultos jovens e de meia-idade, com impacto socioeconômico significativo, especialmente quando associada a quadros graves ou refratários. A carga emocional e o estigma social decorrentes das lesões visíveis são fatores importantes na redução da qualidade de vida, contribuindo para quadros de ansiedade e depressão (SILVA; SILVA, 2007).

2.2 DIAGNÓSTICO DIFERENCIAL E DESAFIOS

O diagnóstico da psoríase é, na maioria dos casos, clínico, baseado na observação direta das características morfológicas das lesões. Em geral, dermatologistas experientes são capazes de reconhecer a doença com alta acurácia. No entanto, em estágios iniciais ou formas clínicas atípicas, o diagnóstico pode ser dificultado, especialmente por profissionais não especializados (BRASIL, 2021; RENDON; SCHÄKEL, 2019).

Um dos principais desafios reside no diagnóstico diferencial com outras dermatoses inflamatórias, como dermatite atópica, dermatite seborreica, líquen plano, pitiríase rósea, eczemas e infecções fúngicas. Muitas dessas condições compartilham sinais clínicos semelhantes, como eritema, descamação e prurido, dificultando a distinção com base apenas no exame físico (BRASIL, 2021; RENDON; SCHÄKEL, 2019).



(a) Pitiríase rósea (b) Eczema (c) Dermatite seborreica (d) Dermatite atópica (e) Líquen plano

Figura 2 – Exemplos de dermatoses que compõem o diagnóstico diferencial da psoríase.

A apresentação das lesões também deve ser considerada em relação ao tom de pele. O relato de Desai, Alexis e Jacobson (2020), por exemplo, documenta alterações de pigmentação no acompanhamento de um paciente negro com psoríase, ilustrando um aspecto que participa da leitura visual da condição. Em casos duvidosos, a biópsia cutânea pode ser solicitada para confirmação histopatológica. Contudo, esse método é invasivo, pode gerar desconforto ao paciente, e nem sempre é factível em contextos de atenção primária ou em locais com acesso restrito à dermatologia especializada (BRASIL, 2021).

Essas dificuldades motivam a investigação de ferramentas complementares que apoiem a análise das fotografias. Modelos de aprendizado de máquina podem aprender relações entre padrões visuais e rótulos, oferecendo uma resposta padronizada para a tarefa em que foram ajustados. O interesse em sua aplicação depende de verificar como essa resposta se comporta em diferentes imagens, grupos e condições de aquisição, relacionando o desempenho experimental à utilização pretendida (JEONG et al., 2023; YU et al., 2020). A classificação de uma fotografia constitui, nesse percurso, um componente a ser avaliado em conjunto com o contexto clínico.

2.3 APRENDIZADO DE MÁQUINA EM DERMATOLOGIA

O aprendizado de máquina tem sido empregado em diferentes etapas da análise dermatológica, desde a identificação de padrões em fotografias até a estimativa de gravidade e a exploração de dados clínicos. Nas tarefas por imagem, redes convolucionais podem participar tanto da classificação de uma entrada quanto da localização ou segmentação de estruturas; na psoríase, essas aplicações também se estendem à avaliação da área acometida e ao acompanhamento da doença (JEONG et al., 2023; MCMULLEN et al., 2025; YU et al., 2020). A distinção entre as tarefas é necessária para compreender o significado das métricas relatadas e sua relação com a ferramenta que se pretende desenvolver.

No levantamento desta dissertação, 36 estudos foram selecionados entre 173 registros inicialmente identificados. A Tabela 1 organiza a classificação temática registrada pelo autor. As categorias não são mutuamente exclusivas: um trabalho pode, por exemplo, abordar segmentação e gravidade, ou apresentar uma revisão que reúna diferentes aplicações. As frequências correspondem, portanto, às ocorrências dos temas no material selecionado.

Tabela 1 – Categorias temáticas dos 36 estudos selecionados no levantamento bibliográfico

Categoria	n	Abordagens registradas	Aplicações principais
Classificação e diagnóstico por imagem	18	CNN, U-Net, ResNet, DenseNet e transformadores visuais	Classificação e segmentação
Predição de gravidade clínica	12	CNN, Mask R-CNN e Swin Transformer	PASI, BSA e NAPSI
Predição de resposta terapêutica	8	CNN, gradient boosting e modelos multimodais	Mudança de terapia e resposta ao tratamento
Processamento de linguagem natural	3	Modelos de linguagem	Extração de informações de prontuários
Modelos parcimoniosos	3	Agrupamento fuzzy e otimização	Segmentação de lesões
Revisões e diretrizes	12	Síntese da literatura	Avaliação crítica e recomendações

Nota: as categorias se sobrepõem. Suas frequências somam 56 ocorrências temáticas em 36 estudos, sem representar 56 trabalhos distintos. PASI: índice de área e gravidade da psoríase; BSA: área de superfície corporal; NAPSI: índice de gravidade da psoríase ungueal.

Fonte: Organização temática do levantamento bibliográfico do autor.

A diversidade das aplicações também pode ser acompanhada por exemplos publicados em momentos diferentes. O trabalho de Ihtatho et al. (2007) utilizou informação de cor para estimar a área de lesões, componente do PASI. Mais recentemente, a literatura incorporou transferência de aprendizado para classificação, AutoML para mudança terapêutica e execução de modelos em aplicações móveis. A Tabela 2 apresenta exemplos com tarefa e unidade de análise identificadas, permitindo reconhecer essa ampliação sem equiparar seus desfechos.

Tabela 2 – Exemplos da evolução das aplicações computacionais à psoríase e à análise móvel de imagens cutâneas

Estudo	Tarefa e abordagem	Resultado ou contribuição relatada
Ihtatho et al. (2007)	Área de lesões por informação de cor e distância euclidiana	Estimativa de um componente do PASI em imagens
Milani et al. (2023)	Psoríase versus pele saudável; três CNNs pré-treinadas	InceptionV3: acurácia média de 97,5% sem aumento de dados
Chakraborty et al. (2024)	Recortes de psoríase versus pele saudável; ajuste de CNNs	MobileNetV1: acurácia reportada de 99,13%
Schaffert et al. (2024)	Mudança de terapia em dados clínicos; AutoML	AUC de 0,9078 para mudança em 24 semanas no conjunto de avaliação
Tanantong et al. (2025)	Recortes lesionais e não lesionais; aumento de dados e CNNs	EfficientNet-B4: acurácia de 93,00%
Sutradhar et al. (2026)	Classificação de lesões cutâneas; aplicação Android	Protótipo com execução local por TensorFlow Lite

Nota: os exemplos possuem dados, tarefas e protocolos distintos. Os valores descrevem os respectivos estudos e não constituem uma comparação direta entre modelos. O último trabalho trata de lesões cutâneas em geral.

Fonte: Elaboração do autor com base nos estudos citados.

Esse percurso ajuda a delimitar a pergunta da presente dissertação. A classificação binária de fotografias completas exige um protocolo próprio, assim como a avaliação de sua execução no computador e a integração ao celular. O levantamento oferece antecedentes para essas escolhas, enquanto a comparação experimental utiliza as mesmas imagens e condições de treinamento para examinar as seis implementações selecionadas.

2.4 REDES NEURAIS CONVOLUCIONAIS

As redes neurais artificiais são modelos formados por unidades de processamento organizadas em camadas, nas quais as informações de entrada são combinadas por meio de pesos e submetidas a transformações sucessivas até a produção de uma saída. No aprendizado supervisionado, essa saída é comparada ao rótulo de referência dos exemplos, e a diferença observada orienta o ajuste dos parâmetros. Ao longo do treinamento, a rede aprende relações que contribuem para a tarefa proposta, como distinguir as classes de um problema de classificação (GOODFELLOW; BENGIO; COURVILLE, 2016).

No processamento de imagens, as redes neurais convolucionais, ou CNNs, exploram a organização espacial dos pixels por meio de filtros que percorrem regiões da entrada. Esses filtros compartilham pesos entre diferentes posições e são ajustados durante o treinamento, permitindo aprender respostas a padrões visuais sem que cada descritor de cor, textura ou contorno precise ser definido antecipadamente. Essa organização torna as CNNs pertinentes à análise de imagens, nas quais a disposição das características também

participa da informação disponível para a classificação (LECUN; BENGIO; HINTON, 2015).

A aplicação de um filtro produz um mapa de características, que reúne suas respostas nas posições examinadas. Vários filtros originam diferentes mapas, posteriormente utilizados como entrada por outras camadas. Com a sucessão desse processamento, a rede pode combinar informações locais e construir representações de maior abrangência, associando respostas a detalhes da imagem a padrões formados por suas combinações. As características aprendidas dependem dos exemplos apresentados e da maneira como a rede é organizada.

Esse fluxo inclui operações complementares à convolução. As funções de ativação introduzem relações não lineares, enquanto as normalizações atuam sobre a distribuição das características intermediárias. Também podem ser utilizadas operações de *pooling*, que resumem regiões de cada mapa: o *max pooling* seleciona o maior valor de uma janela, e o *average pooling* calcula sua média. Conforme a configuração da janela e do deslocamento, esse resumo reduz as dimensões espaciais das representações e o volume de informação encaminhado às camadas seguintes. A redução espacial também pode ocorrer por convoluções com deslocamento maior que um, de acordo com o desenho da rede (ZAFAR et al., 2022).

Na etapa final, as representações produzidas são agregadas e encaminhadas ao componente responsável pela classificação. Esse percurso estabelece uma relação entre a imagem apresentada, as características aprendidas e a saída estimada pelo modelo. A Figura 3 apresenta uma ilustração didática desse fluxo, oferecendo uma visão de conjunto antes da descrição das arquiteturas utilizadas no estudo.

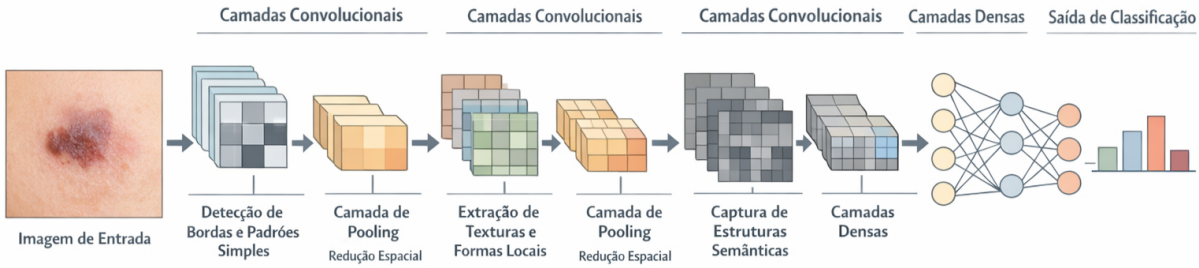


Figura 3 – Esquema didático do processamento em uma rede neural convolucional, da imagem de entrada à saída de classificação. A organização dos blocos e das operações varia conforme a arquitetura. Fonte: elaboração do autor.

Os princípios apresentados podem ser organizados de diferentes maneiras, dando origem a arquiteturas que variam na composição das camadas, nas conexões entre elas e nos recursos necessários à execução. A compreensão desse fluxo geral permite avançar para os mecanismos que distinguem as redes comparadas, apresentados na Seção 2.5.

2.5 FUNDAMENTOS DAS ARQUITETURAS COMPARADAS

A comparação entre arquiteturas torna-se mais informativa quando se reconhece que reduzir parâmetros, facilitar a otimização e reutilizar características são problemas relacionados, porém distintos. As seis redes escolhidas representam respostas diferentes a esses problemas: MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0 e EfficientNet-B0 privilegiam estratégias de eficiência; ResNet18 e DenseNet121 acrescentam referências de conectividade residual e densa. A apresentação avança, assim, dos operadores convolucionais aos mecanismos de cada família, preparando a descrição das implementações utilizadas no protocolo.

Uma imagem RGB pode ser representada por $X \in \mathbb{R}^{H\times W\times C_{\text{in}}}$, com $C_{\text{in}} = 3$ na entrada. Para um filtro de dimensão $k \times k$, deslocamento s e preenchimento p, a transformação de um canal de saída o pode ser escrita como

$$Y_{i,j,o} = b_o + \sum_{c=1}^{C_{\text{in}}} \sum_{u=0}^{k-1} \sum_{v=0}^{k-1} K_{u,v,c,o}\, X_{si+u-p,sj+v-p,c}. \tag{2.1}$$

Nessa expressão, K contém os pesos aprendidos e b_o representa o viés, quando empregado. Adota-se a convenção de correlação cruzada dos operadores convolucionais, sem inversão espacial do filtro (GOODFELLOW; BENGIO; COURVILLE, 2016). Para uma saída com dimensões $H_o \times W_o$ e C_{out} canais, o número de pesos, sem vieses, é $k^2 C_{\text{in}} C_{\text{out}}$, e a contagem aproximada de multiplicações e acumulações (MACs) é

$$\text{MAC}_{\text{conv}} \approx H_o W_o k^2 C_{\text{in}} C_{\text{out}}. \tag{2.2}$$

Essa contagem descreve o operador e ajuda a compreender as estratégias de economia das redes móveis. O tempo de execução da arquitetura completa também depende da movimentação de dados, dos acessos à memória e da implementação das operações, motivo pelo qual a descrição estrutural é acompanhada de medições no experimento (MA et al., 2018).

2.5.1 Convoluções separáveis e blocos móveis

Nas convoluções separáveis em profundidade, a filtragem espacial é executada por canal, em uma operação *depthwise*, e a combinação entre canais ocorre por uma convolução pontual 1×1, denominada *pointwise*. Para a mesma dimensão espacial de saída, a contagem aproximada torna-se (HOWARD et al., 2017)

$$\text{MAC}_{\text{sep}} \approx H_o W_o \left(k^2 C_{\text{in}} + C_{\text{in}} C_{\text{out}}\right), \qquad \frac{\text{MAC}_{\text{sep}}}{\text{MAC}_{\text{conv}}} \approx \frac{1}{C_{\text{out}}} + \frac{1}{k^2}. \tag{2.3}$$

O resultado evidencia o potencial de economia na combinação de dimensões espaciais e canais. Ele se refere às duas convoluções descritas, sem incluir o custo de uma eventual expansão de canais, atenção ou conexão de atalho. Essa distinção é relevante porque os blocos móveis combinam justamente esses componentes para preservar capacidade de representação com um orçamento computacional reduzido.

2.5.2 MobileNetV2: expansão e gargalo linear

A MobileNetV2, proposta por Sandler et al. (2018), organiza suas unidades em uma sequência de expansão, filtragem espacial e projeção. A expansão pontual leva uma representação de C canais para um espaço com aproximadamente tC canais, no qual se aplica a convolução em profundidade. Em seguida, uma projeção pontual retorna ao espaço de saída. O termo *resíduo invertido* decorre da conexão entre representações estreitas, com processamento intermediário expandido.

Se E representa a expansão, D a filtragem em profundidade e P a projeção, a unidade pode ser sintetizada por

$$\begin{aligned} F(X) &= P(\rho_6(D(\rho_6(E(X))))) \,, \\ Y &= \begin{cases} X + F(X), & \text{se o atalho é compatível,} \\ F(X), & \text{nos demais casos,} \end{cases} \end{aligned} \tag{2.4}$$

com $\rho_6(a) = \min\{6, \max\{0, a\}\}$. O atalho é utilizado quando o bloco preserva as dimensões espaciais, emprega *stride* unitário e mantém o número de canais. A notação omite a normalização para destacar a organização das transformações. A projeção final permanece sem ativação não linear, característica que define o gargalo linear. No presente experimento, essa arquitetura oferece uma referência compacta para avaliar a relação entre capacidade de discriminação, tamanho do checkpoint e tempo de inferência após a adaptação binária.

2.5.3 MobileNetV3 Small: atenção por canais e ativações eficientes

A MobileNetV3 combina busca de arquitetura orientada ao dispositivo, refinamento da configuração dos blocos e escolhas de operadores voltadas à execução móvel. A variante Small foi concebida para orçamentos menores de recursos e reúne convoluções em profundidade, conexões residuais quando compatíveis e atenção por canais em parte dos blocos (HOWARD et al., 2019).

O mecanismo de *squeeze-and-excitation* (SE) resume cada canal de um tensor U por uma média espacial e aprende fatores de reponderação (HU; SHEN; SUN, 2018):

$$q_c = \frac{1}{HW} \sum_{i=1}^{H} \sum_{j=1}^{W} U_{i,j,c}, \qquad a = g(W_2\, \delta(W_1 q)) \,, \qquad \widetilde{U}_{i,j,c} = a_c U_{i,j,c}. \tag{2.5}$$

As matrizes W_1 e W_2 parametrizam a transformação do descritor de canais, δ representa a ativação ReLU interna e g realiza o controle dos fatores de escala. Na formulação original de SE, utiliza-se uma sigmoide; na implementação móvel da MobileNetV3, o controle emprega sua aproximação *hard-sigmoid*. Outra escolha da rede é a ativação *hard-swish*, definida por

$$\text{h-sigmoid}(a) = \frac{\rho_6(a+3)}{6}, \qquad \text{h-swish}(a) = a\, \frac{\rho_6(a+3)}{6}. \tag{2.6}$$

Essas operações permitem examinar, no estudo, uma evolução da família MobileNet sob a mesma entrada de 224×224 e o mesmo procedimento de ajuste fino. A relevância dessa comparação está em observar como as escolhas internas se traduzem em resultados medidos na tarefa dermatológica e no hardware utilizado, além das motivações de projeto apresentadas pelos autores.

2.5.4 ShuffleNetV2 x1.0: divisão e reorganização dos canais

A ShuffleNetV2 foi desenvolvida a partir de uma análise de fatores que afetam a velocidade de execução, como acesso à memória, fragmentação das operações e paralelismo. Em suas unidades com *stride* unitário, os canais são divididos em dois ramos: um preserva a entrada e o outro aplica transformações convolucionais. Os resultados são concatenados e passam por uma permutação que reorganiza os canais (MA et al., 2018).

Denotando por $[X_a, X_b]$ a divisão da entrada e por Π a operação de *channel shuffle*, escreve-se

$$Y = \Pi([X_a, F(X_b)]) \,. \tag{2.7}$$

A concatenação conserva características de um ramo e acrescenta as do ramo transformado; a permutação favorece a circulação dessas informações nas unidades seguintes. Nos blocos de redução espacial, ambos os ramos realizam transformações, conforme a configuração da rede. A designação x1.0 identifica a variante de largura adotada. Para o trabalho, sua inclusão amplia a comparação com uma implementação compacta cujo desenho valoriza explicitamente o custo de execução das operações, tornando especialmente pertinente confrontar número de parâmetros e latência efetivamente observada.

2.5.5 EfficientNet-B0: blocos MBConv e dimensionamento composto

A EfficientNet-B0 constitui o modelo-base da família proposta por Tan e Le (2019), desenvolvida para articular capacidade de representação e custo computacional. Sua organização reúne blocos convolucionais compactos, atenção por canais e uma agregação final das características. A compreensão dessa estrutura permite acompanhar como a imagem é transformada até a produção da saída utilizada no aplicativo.

Na configuração adotada, a entrada RGB de 224×224 passa por uma convolução inicial 3×3, com deslocamento 2, produzindo mapas de 112×112 com 32 canais. Seguem-se sete grupos que totalizam 16 blocos MBConv, com filtros 3×3 ou 5×5. Ao longo deles, a resolução diminui até 7×7, enquanto a quantidade de canais chega a 320. A Figura 4 reúne o percurso completo e as operações internas do bloco (TAN; LE, 2019; PyTorch, 2026).

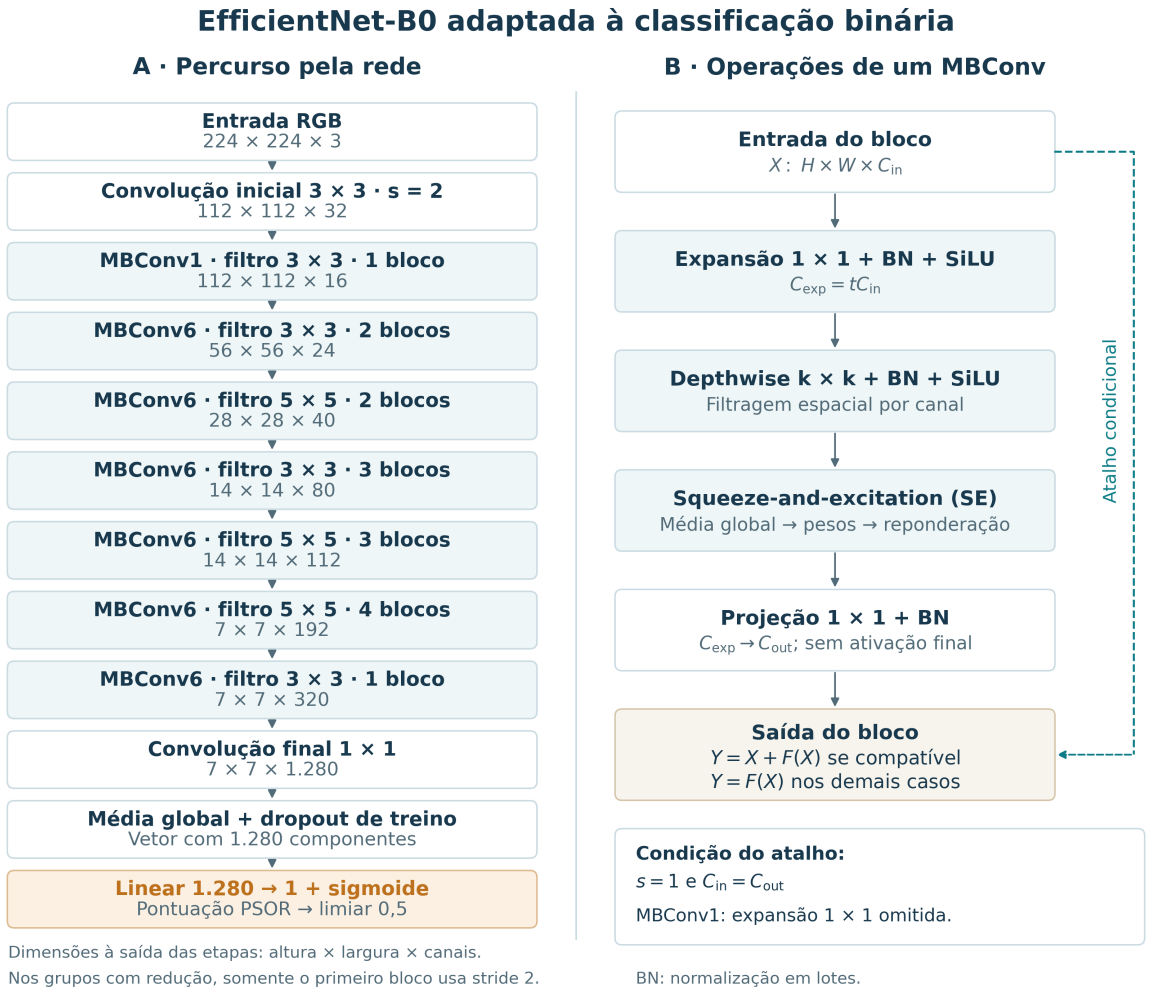


Figura 4 – EfficientNet-B0 adaptada ao estudo: (A) etapas da rede, com dimensões na saída de cada grupo; (B) operações de um MBConv e condição para o atalho residual. BN indica normalização em lotes. Fonte: elaboração do autor, com base em Tan e Le (2019) e na implementação Torchvision utilizada.

O MBConv utiliza o princípio do gargalo residual invertido, no qual uma representação compacta é expandida para o processamento intermediário e posteriormente projetada para o número de canais de saída (SANDLER et al., 2018). A expansão ocorre por convolução 1×1: nos blocos MBConv6, o número de canais intermediários corresponde a seis vezes o número de canais de entrada. O MBConv1 inicial mantém fator unitário e dispensa essa convolução de expansão.

Em seguida, uma convolução em profundidade, ou *depthwise*, realiza a filtragem espacial separadamente em cada canal. A combinação entre canais fica a cargo das convoluções pontuais de expansão e projeção, preservando a separação de funções característica dos blocos móveis. Na B0, expansão e filtragem em profundidade incluem normalização em lotes e ativação SiLU, expressa por $\mathrm{SiLU}(a) = a\sigma(a)$, em que σ representa a função sigmoide (PyTorch, 2026).

Antes da projeção, o mecanismo *squeeze-and-excitation* (SE) calcula uma média

espacial de cada canal e transforma esse descritor em fatores de reponderação. O resumo global permite que o ajuste de um canal considere informações dos demais, modulando as respostas conforme o conteúdo apresentado (HU; SHEN; SUN, 2018). Na implementação da B0, duas transformações 1×1, com SiLU intermediária e sigmoide final, produzem os fatores aplicados aos canais do tensor expandido.

A projeção 1×1 reúne essas respostas e define os canais de saída, com normalização e sem ativação final. Quando o bloco preserva as dimensões espaciais e o número de canais, a conexão residual acrescenta a entrada à transformação aprendida, retomando a organização discutida para os gargalos invertidos. Na inferência, o processamento pode ser sintetizado por

$$F(X) = P(S(D(E(X)))),$$
$$Y = \begin{cases} X + F(X), & \text{se } s = 1 \text{ e } C_{\text{in}} = C_{\text{out}}, \\ F(X), & \text{nos demais casos.} \end{cases} \tag{2.8}$$

Nessa notação, E representa a expansão, ou a identidade no MBConv1; D, a filtragem em profundidade; S, a reponderação SE; e P, a projeção. As normalizações e ativações correspondentes estão incorporadas nesses operadores.

Ao final dos grupos MBConv, uma convolução 1×1 produz 1.280 canais. A média espacial global converte os mapas em um vetor de 1.280 componentes, encaminhado ao classificador. No estudo, sua última camada linear foi substituída para gerar um único logit; a sigmoide fornece a pontuação PSOR, comparada ao limiar de 0,5. Durante o treinamento, a implementação utiliza dropout na cabeça e regularização estocástica nos ramos residuais; essas operações são desativadas no modo de avaliação.

O dimensionamento composto explica como a família amplia essa configuração-base, coordenando profundidade d, largura w e resolução r (TAN; LE, 2019):

$$d = \alpha^{\varphi}, \qquad w = \beta^{\varphi}, \qquad r = \gamma^{\varphi}, \qquad \alpha\beta^2\gamma^2 \approx 2, \quad \alpha, \beta, \gamma \geq 1. \tag{2.9}$$

O coeficiente φ controla a ampliação, enquanto α, β e γ distribuem o crescimento entre as três dimensões. A condição apresentada corresponde à aproximação do custo de operações utilizada na proposta. Neste trabalho, foi mantida a configuração B0 com entrada de 224×224, sem executar uma busca de escalonamento. O ajuste fino e a seleção por validação determinaram o checkpoint integrado ao Android, relacionando a estrutura aqui descrita ao procedimento experimental.

2.5.6 ResNet18: aprendizagem de transformações residuais

As redes residuais reformulam o processamento de um bloco como a aprendizagem de uma transformação adicional à representação recebida. Na ResNet18, o bloco básico

reúne duas convoluções 3×3 e uma conexão de atalho, cuja soma é seguida por uma ativação ReLU (HE et al., 2016):

$$Y = \mathrm{ReLU}(F(X;\theta) + S(X)), \qquad S(X) = \begin{cases} X, & \text{quando as dimensões coincidem,} \\ W_s * X, & \text{quando é necessária projeção.} \end{cases} \tag{2.10}$$

O operador S permite compatibilizar resolução e número de canais quando ocorre mudança de estágio; a notação da projeção omite a normalização. O atalho cria um caminho de propagação que se soma ao ramo aprendido, facilitando o treinamento de redes profundas. A variante de 18 camadas foi mantida como referência residual de menor profundidade dentro dessa família. No contexto do estudo, ela contribui para investigar se uma rede com maior quantidade de parâmetros do que as alternativas móveis proporciona ganhos classificatórios proporcionais ao custo adicional observado.

2.5.7 DenseNet121: conectividade densa e reutilização de características

A DenseNet121 explora a reutilização de características por concatenação. Dentro de um bloco denso, a camada ℓ recebe os mapas produzidos por todas as camadas anteriores, o que estabelece diferentes caminhos de comunicação entre representações (HUANG et al., 2017):

$$X_\ell = H_\ell([X_0, X_1, \ldots, X_{\ell-1}]), \qquad C_\ell = C_0 + k\ell. \tag{2.11}$$

Os colchetes indicam concatenação de canais, H_ℓ representa a transformação aprendida e k é a taxa de crescimento, isto é, a quantidade de novos mapas acrescentados por camada. Assim, C_ℓ representa o total de canais acumulados pela concatenação após ℓ camadas de um bloco iniciado com C_0 canais. A configuração DenseNet121 utilizada pela biblioteca emprega $k = 32$ e quatro blocos com 6, 12, 24 e 16 unidades, separados por transições de redução espacial e de canais (PyTorch, 2026).

Esse desenho favorece a circulação de características já produzidas, ao mesmo tempo que torna relevante acompanhar o armazenamento e a movimentação das representações intermediárias. Sua inclusão amplia o contraste com a ResNet18, cuja conexão combina respostas por soma, e com as redes móveis, que procuram economizar operações e canais. Desse modo, o protocolo compara mecanismos arquiteturais distintos sob uma tarefa comum, permitindo discutir seus efeitos a partir das métricas e dos recursos registrados no experimento.

2.5.8 Saída binária e função de aprendizagem

Embora os caminhos internos sejam diferentes, todas as implementações foram adaptadas para produzir um único logit. Se $h_\theta(x)$ representa o vetor que chega à última

camada linear, a decisão pode ser escrita como

$$z = w^{\mathsf{T}} h_\theta(x) + b, \qquad p_{\mathrm{PSOR}} = \frac{1}{1+e^{-z}}, \qquad \widehat{y} = \mathbf{1}(p_{\mathrm{PSOR}} \geq \tau)\,, \quad \tau = 0{,}5. \tag{2.12}$$

O vetor h_θ inclui as camadas preservadas de cada arquitetura, inclusive eventuais componentes de sua cabeça classificadora. O rótulo $y = 1$ corresponde a PSOR (positivo para condição psoriásica) e $y = 0$ a NonPsor (negativo para condição psoriásica). Durante o treinamento, a função `BCEWithLogitsLoss` combina a transformação sigmoide e a entropia cruzada binária em uma avaliação numericamente estável (PyTorch, [s.d.]a). Para uma observação, a perda pode ser expressa por

$$\ell(z, y) = \max(z, 0) - yz + \log\left(1 + e^{-|z|}\right). \tag{2.13}$$

A perda orienta a atualização dos parâmetros, enquanto o limiar transforma a pontuação em uma das duas classes operacionais. Essa pontuação descreve a resposta do modelo ao padrão apresentado; sua interpretação como risco clínico individual exigiria um estudo próprio de calibração e validação.

2.6 TRANSFERÊNCIA DE APRENDIZADO

A transferência de aprendizado consiste em aproveitar conhecimentos adquiridos em uma tarefa de origem para apoiar a aprendizagem de uma tarefa de destino. Em redes neurais, esse conhecimento pode estar representado nos parâmetros estimados durante um treinamento anterior, que passam a constituir o ponto de partida para a adaptação ao novo problema. Essa possibilidade é particularmente relevante quando o conjunto de destino dispõe de poucos exemplos rotulados, pois permite reutilizar representações previamente aprendidas (KIM et al., 2022).

Na classificação de imagens com redes convolucionais, uma aplicação frequente dessa estratégia utiliza modelos pré-treinados no ImageNet. A adaptação pode ocorrer de diferentes formas. Na extração de características com base fixa, preservam-se os parâmetros do extrator e treina-se um classificador para as novas categorias. No ajuste fino, denominado *fine-tuning*, também são atualizados parâmetros das camadas previamente treinadas, permitindo adaptar as representações ao domínio de destino. Quando essa atualização abrange todas as camadas com parâmetros treináveis, o procedimento caracteriza um ajuste fino integral (DAVILA; COLAN; HASEGAWA, 2024).

Em imagens médicas, a escolha da estratégia de adaptação ganha relevância porque as características visuais e as categorias de interesse diferem daquelas utilizadas no pré-treinamento. Davila, Colan e Hasegawa (2024) compararam oito estratégias de ajuste fino em diferentes modalidades médicas, incluindo dermatoscopia, e observaram que seu desempenho variou conforme a arquitetura e o conjunto analisado. Esses resultados apoiam

a avaliação da transferência em condições compatíveis com cada aplicação e a descrição explícita de como os modelos foram adaptados.

No contexto desta dissertação, a transferência fornece a condição inicial das seis arquiteturas que serão comparadas. Os pesos ImageNet representam características aprendidas em categorias gerais de imagens; a distinção entre PSOR e NonPsor é construída no ajuste supervisionado ao acervo dermatológico. As versões dos pesos, a substituição da saída e a atualização integral dos parâmetros são especificadas na Seção 3.4.2. Essa descrição permite compreender o papel do pré-treinamento sem pressupor que ele já constitua um classificador de psoríase.

2.7 EXPLICABILIDADE E INTERPRETABILIDADE

As métricas classificatórias resumem o comportamento das predições, mas oferecem pouca informação sobre como uma imagem específica se relaciona com a resposta produzida. As técnicas de explicabilidade pós-hoc acrescentam uma perspectiva local a essa avaliação, permitindo inspecionar regiões da lesão, do fundo e de outros elementos presentes na entrada. No estudo, Grad-CAM, LIME e SHAP foram utilizados de forma exploratória para explicar o mesmo alvo, PSOR, construindo um painel que acompanha a classificação com diferentes formas de atribuição visual (SELVARAJU et al., 2017; RIBEIRO; SINGH; GUESTRIN, 2016; LUNDBERG; LEE, 2017).

2.7.1 Grad-CAM

O Grad-CAM combina mapas convolucionais e gradientes do escore de interesse para produzir uma localização aproximada de contribuições positivas (SELVARAJU et al., 2017). Para um logit z e mapas A^k com Z posições espaciais, os pesos e o mapa são obtidos por

$$\alpha_k = \frac{1}{Z}\sum_i \sum_j \frac{\partial z}{\partial A^k_{ij}}, \qquad L_{\text{Grad-CAM}} = \text{ReLU}\left(\sum_k \alpha_k A^k\right). \tag{2.14}$$

A ampliação para o tamanho da imagem permite sobrepor esse mapa à entrada, enquanto a resolução da camada escolhida define o detalhamento espacial disponível. Essa propriedade orienta sua leitura como localização aproximada, e não como delimitação segmentada da lesão. O acompanhamento do mapa antes de seu ajuste de cores permite reconhecer situações sem variação espacial e documentá-las na apresentação dos resultados.

2.7.2 LIME

O LIME constrói uma aproximação interpretável do classificador nas proximidades de uma entrada. Em imagens, essa vizinhança é formada por perturbações de regiões, agrupadas em superpixels, cujas respostas são novamente avaliadas pelo modelo. A

formulação geral combina fidelidade local e simplicidade da aproximação (RIBEIRO; SINGH; GUESTRIN, 2016):

$$g_x^\star = \arg\min_{g \in \mathcal{G}} \{\mathcal{L}(f, g, \pi_x) + \Omega(g)\}. \tag{2.15}$$

O termo π_x pondera a proximidade das perturbações em relação à imagem, $\mathcal{L}$ avalia a aproximação à resposta de f e Ω representa sua complexidade. Os coeficientes de $g_x^\star$ permitem visualizar contribuições positivas e negativas para a saída explicada. O R^2 local registrado no estudo complementa a figura ao descrever a fidelidade da aproximação nas perturbações utilizadas, sem se confundir com a qualidade classificatória do modelo ou com a correção clínica da região destacada.

2.7.3 SHAP

O SHAP organiza atribuições aditivas em torno de uma referência. Na formulação clássica de Shapley, a contribuição de um atributo j considera o ganho marginal que sua inclusão produz em diferentes coalizões (LUNDBERG; LEE, 2017):

$$\phi_j = \sum_{S \subseteq M \setminus \{j\}} \frac{|S|!\,(m - |S| - 1)!}{m!} \left[v(S \cup \{j\}) - v(S)\right], \qquad m = |M|. \tag{2.16}$$

Nessa expressão, M representa o conjunto de atributos e $v(S)$ a saída associada à coalizão considerada. A decomposição aditiva relaciona a predição a um valor de referência e às contribuições atribuídas às características da entrada.

Na implementação Partition, as características são organizadas em uma estrutura hierárquica de coalizões, relacionada aos valores de Owen. Essa organização permite construir uma atribuição aproximada respeitando os agrupamentos definidos pela hierarquia (SHAP, [s.d.]). A Equação 2.16 apresenta o fundamento clássico de atribuição; a interpretação de uma aplicação concreta também depende da referência usada para ocultar regiões e do número de avaliações permitidas. Essas escolhas são explicitadas no protocolo de explicabilidade da Seção 3.5.3.

2.7.4 Apresentação e leitura conjunta

A comparação visual reúne a entrada original, a classe de referência quando conhecida, a classe estimada, a pontuação PSOR, a arquitetura e o alvo explicado. O Grad-CAM adotado explica contribuições positivas ao logit, ao passo que LIME e SHAP foram aplicados à pontuação sigmoide. Essas definições ajudam a compreender por que as técnicas podem produzir destaques diferentes mesmo ao analisar uma mesma imagem.

As escalas são normalizadas por mapa e devem ser interpretadas dentro de cada explicação. A leitura conjunta favorece a inspeção do comportamento do modelo e a identificação de casos que mereçam investigação, enquanto a avaliação da localização

clínica exige um protocolo específico com anotações pertinentes (ARUN et al., 2021). Nesta versão do sistema, os mapas permanecem no relatório produzido no computador; o aplicativo Android apresenta a classificação e as medições de execução.

2.8 TRABALHOS RELACIONADOS

A análise computacional de imagens cutâneas reúne pesquisas sobre reconhecimento de lesões, diferenciação entre doenças e avaliação de sua extensão ou gravidade. Entre os antecedentes desse campo, Haenssle et al. (2018) compararam uma rede convolucional com 58 dermatologistas no reconhecimento dermatoscópico de melanoma. O estudo exemplifica a investigação do desempenho de modelos em tarefas dermatológicas delimitadas, estabelecendo um precedente para a avaliação de sistemas de apoio à decisão. A revisão de Jeong et al. (2023) amplia essa perspectiva ao reunir aplicações de CNNs em dermatologia e discutir como a origem das imagens, as características das bases e os procedimentos de avaliação participam da interpretação dos resultados.

A composição dos dados constitui um dos aspectos que aproximam essas investigações, mesmo quando as doenças analisadas são diferentes. Ao avaliar modelos de identificação de malignidade cutânea em uma base clínica com diversidade de tons de pele, Daneshjou et al. (2022) observaram diferenças de desempenho entre grupos e verificaram que o ajuste com dados mais diversos reduziu essas diferenças nos modelos examinados. Esses achados relacionam a composição da base ao comportamento dos classificadores e oferecem um fundamento empírico para considerar a representatividade na avaliação. Como o estudo trata de malignidade cutânea, sua aproximação com a investigação da psoríase se dá pelo desenho da avaliação e pela atenção à diversidade dos dados.

Ao delimitar a discussão à psoríase, é necessário reconhecer que a literatura investiga diferentes perguntas sobre a mesma condição. Na revisão sistemática de McMullen et al. (2025), dedicada à predição de gravidade, foram incluídos 30 estudos, dos quais 29 empregaram modelos baseados em imagens. As abordagens utilizaram principalmente o índice PASI e a área de superfície corporal acometida. Esse conjunto evidencia uma frente de pesquisa voltada à mensuração da doença e ao seu acompanhamento. A classificação binária de fotografias, foco desta dissertação, investiga outro desfecho: a atribuição de uma imagem às categorias PSOR ou NonPsor, sem estimar a gravidade clínica.

Entre os trabalhos diretamente relacionados à classificação, Milani et al. (2023) compararam ResNet50, VGG19 e InceptionV3 em um acervo de 2.260 imagens, utilizando transferência de aprendizado e validação cruzada com cinco partições. A InceptionV3 apresentou o melhor desempenho entre as configurações avaliadas, com acurácia média de 97,5% na configuração sem aumento de dados. A avaliação incluiu configurações com e sem aumento de dados, permitindo discutir o efeito dessa etapa em conjunto com a arquitetura e o treinamento. Trata-se de um antecedente próximo pela comparação de

modelos na distinção entre imagens com psoríase e pele saudável.

O interesse por alternativas de menor custo computacional aparece no CAD-PsorNet, de Chakraborty et al. (2024). Os autores compararam VGG16, VGG19, MobileNetV1 e ResNet50 em recortes de imagens de psoríase e pele saudável obtidas em um hospital, destacando a MobileNetV1 após a adaptação dos modelos pré-treinados. O artigo reporta acurácia de 99,13% após otimização de hiperparâmetros. A inclusão da MobileNetV1 aproxima essa investigação da busca por modelos com menor custo computacional. Na leitura do desempenho reportado, a aquisição hospitalar e a classificação de recortes identificam o cenário ao qual os resultados se referem.

A preparação das imagens também foi investigada por Tanantong et al. (2025), que combinaram aumento de dados e transferência de estilo para simular variações de tons de pele tailandeses. O procedimento empregou recortes de 64×64 pixels, classificados como lesionais ou não lesionais conforme a proporção de área afetada. Os autores compararam EfficientNet-B4, MobileNetV3-Large, ResNet50 e DenseNet201, destacando acurácia de 93,00% e sensibilidade de 91,19% para a EfficientNet-B4. O estudo relaciona a preparação dos dados ao comportamento das redes em uma tarefa de análise localizada. O emprego de recortes define, assim, uma unidade de análise diferente da fotografia inteira considerada nesta dissertação.

Ao considerar a implantação em dispositivos móveis, a relação entre desempenho e recursos passa a integrar a própria comparação dos modelos. Tanantong et al. (2024) examinaram cinco arquiteturas, incluindo variantes MobileNetV3, em diferentes resoluções de entrada, registrando, no ambiente computacional do estudo, tempos de treinamento e teste para a classificação de grupos de doenças cutâneas. O estudo mostrou que a redução da resolução pode diminuir o tempo de processamento, com efeitos sobre o desempenho que dependem da arquitetura. Esse antecedente fundamenta a discussão do custo operacional a partir de medições e condições de execução identificadas, aproximando a escolha do modelo das exigências de uma aplicação móvel.

Quanto à execução no aparelho, Sutradhar et al. (2026) desenvolveram o SkinLearn, um aplicativo Android com um modelo de classificação baseado em YOLO11 e execução local por TensorFlow Lite. O trabalho trata da classificação de lesões cutâneas e apresenta a inferência sem conexão com um servidor como parte do protótipo. A passagem do modelo treinado à execução no aparelho aproxima esse antecedente da etapa de implementação desta dissertação, situando a implantação local como uma etapa com documentação e avaliação próprias, articuladas à investigação do classificador.

A leitura conjunta desses trabalhos mostra que os resultados precisam ser compreendidos em relação à tarefa, à unidade de análise e ao procedimento de avaliação. A identificação de recortes lesionais, a diferenciação entre psoríase e pele saudável e a predição de gravidade respondem a perguntas distintas. Da mesma forma, valores obtidos por validação cruzada estão vinculados a um protocolo diferente daquele que utiliza conjuntos

fixos de treinamento, validação e teste. Por essa razão, os indicadores apresentados nesta seção caracterizam os resultados dos respectivos estudos e permitem reconhecer suas contribuições, sem constituir uma ordenação direta de desempenho entre pesquisas.

Nesse percurso, o presente trabalho articula a comparação de seis arquiteturas, o registro de recursos computacionais, a explicabilidade exploratória e o desenvolvimento de um protótipo Android para inferência local. As redes são ajustadas em três sementes sobre uma divisão fixa do acervo, com resolução comum e seleção por validação. A avaliação no computador relaciona desempenho preditivo, tempo, memória e tamanho dos artefatos; a integração do modelo selecionado ao aplicativo permite dar continuidade à investigação operacional no aparelho. A contribuição está na organização dessas etapas em um fluxo documentado, que conecta a comparação experimental à implementação e fornece resultados e registros para acompanhar o desenvolvimento do sistema.

3 MATERIAIS E MÉTODOS

3.1 DESENHO DO ESTUDO E FLUXO DE DESENVOLVIMENTO

O estudo adotou um desenho experimental quantitativo de classificação binária de imagens dermatológicas, articulado ao desenvolvimento de um protótipo de software. A investigação relacionou duas perguntas: como diferentes redes convolucionais se comportam diante de uma mesma tarefa e quais recursos demandam nas condições avaliadas. Por essa razão, o desempenho classificatório foi acompanhado por medidas de tempo, memória e dimensão dos modelos, permitindo discutir a continuidade da implantação a partir de resultados preditivos e operacionais.

O processo compreendeu a preparação e a auditoria do acervo, o treinamento de seis arquiteturas em três sementes, a avaliação de seus checkpoints, a seleção por validação, a produção de explicações exploratórias e a integração ao Android. Cada combinação de arquitetura e semente foi avaliada na validação e no teste. A escolha da arquitetura e dos checkpoints representativos utilizou exclusivamente as métricas de validação; as métricas do teste caracterizaram as 18 execuções, sem participar dos critérios de escolha. Essa distinção preserva a função dos conjuntos, embora a implementação calcule os resultados de teste antes de consolidar a seleção final (CAWLEY; TALBOT, 2010; MUNIZ, 2026).

O desenvolvimento utilizou dois ambientes complementares. No computador, foram realizados treinamento, avaliação, explicabilidade e exportação; no celular, o aplicativo executa o modelo já treinado e registra medidas operacionais. A exportação estabelece a ligação entre os ambientes, enquanto as verificações numéricas e os autotestes conferem a compatibilidade técnica do artefato. A Figura 5 sintetiza esse percurso, da organização das imagens à utilização do protótipo.

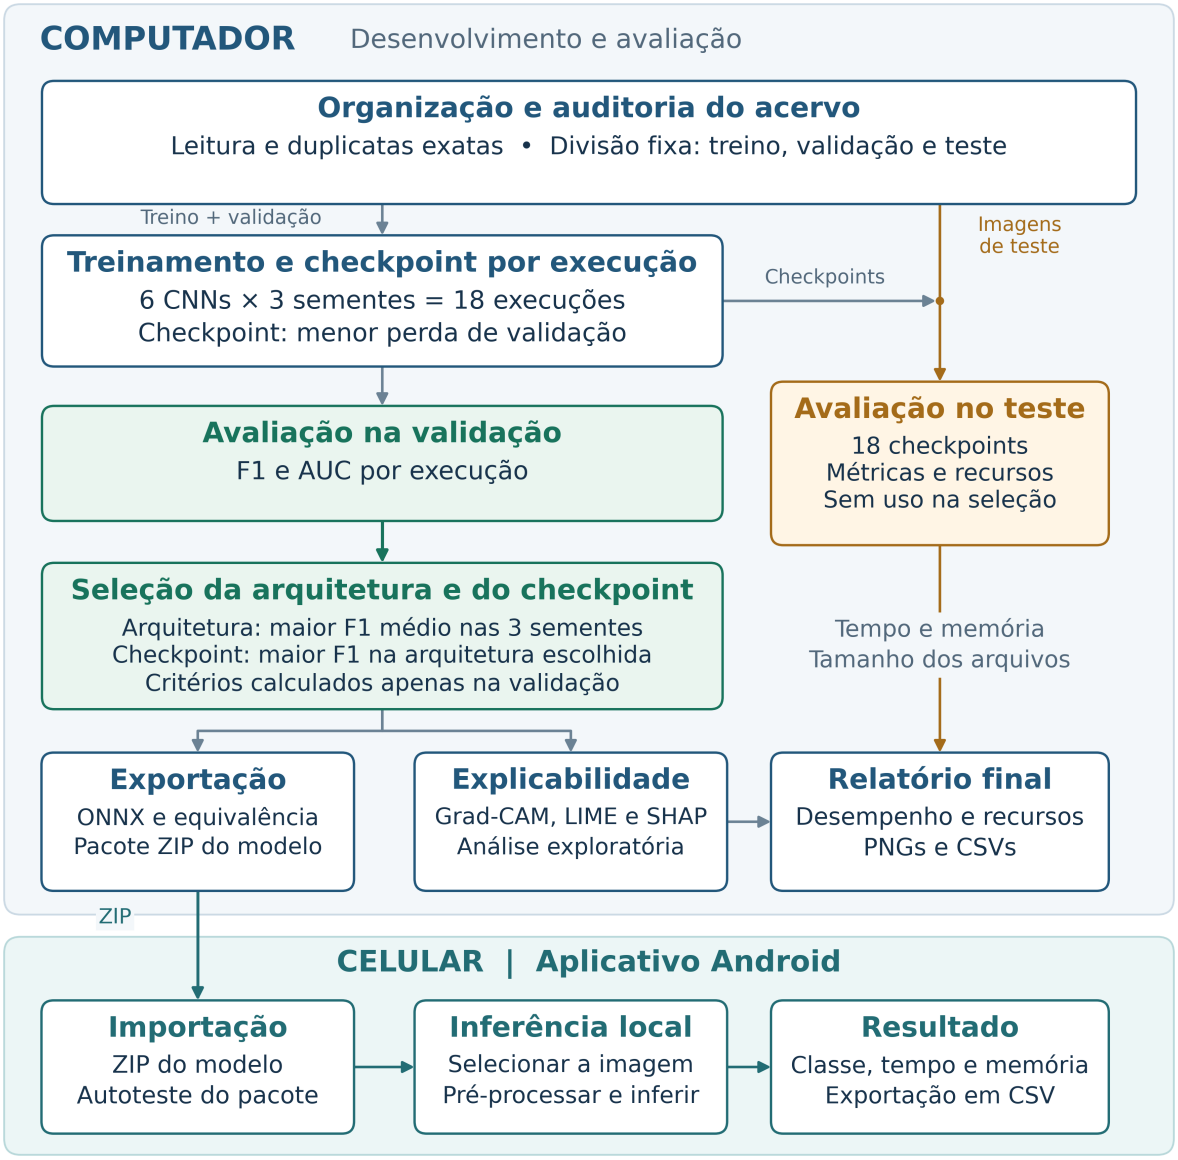


Figura 5 – Fluxo de desenvolvimento e avaliação. A validação orienta a seleção da arquitetura e dos checkpoints representativos; o teste caracteriza os checkpoints das 18 execuções e não integra os critérios de seleção. A integração ao Android utiliza o modelo selecionado. Fonte: elaboração do autor.

3.2 LEVANTAMENTO BIBLIOGRÁFICO DE APOIO

A fundamentação foi organizada por um levantamento sistematizado de caráter descritivo e crítico, voltado às aplicações de inteligência artificial à psoríase. A busca combinou descritores como *psoriasis*, *artificial intelligence*, *machine learning*, *deep learning* e *systematic review*, considerando publicações de 2018 a 2025. Foram consultadas PubMed, Scopus e Embase, além de plataformas editoriais da Wiley, Springer e Elsevier. Essa organização priorizou a literatura biomédica e interdisciplinar relacionada à tarefa dermatológica investigada.

Os registros do levantamento indicam 173 documentos inicialmente identificados e 36 estudos selecionados. A inclusão contemplou estudos originais e revisões pertinentes à classificação de imagens, segmentação, predição de gravidade, resposta terapêutica e integração de dados clínicos e visuais. Foram extraídos o objetivo, o tipo de dado, a abordagem computacional, as métricas e as limitações descritas pelos autores. A Figura 6 apresenta o esquema de organização utilizado, e a Tabela 1 reúne as categorias temáticas do material selecionado.



Figura 6 – Estratégia de levantamento e organização do material bibliográfico de apoio. Fonte: elaboração do autor.

A fundamentação técnica foi complementada por artigos de origem das arquiteturas e dos métodos de explicabilidade, trabalhos clássicos e documentação oficial das bibliotecas. Essa consulta complementar inclui referências anteriores e posteriores ao intervalo da busca temática. Como IEEE Xplore e ACM Digital Library não integraram a busca principal, o levantamento não pretende esgotar a produção sobre implantação móvel; sua função é sustentar a contextualização da tarefa e as escolhas técnicas explicitadas nesta dissertação.

3.3 BASE DE IMAGENS, PROCEDÊNCIA E PREPARAÇÃO DOS CONJUNTOS

A base foi organizada para investigar a distinção entre fotografias rotuladas como psoríase e condições não psoriáticas reunidas no acervo. Sua descrição considera a região corporal representada, a procedência das imagens e os critérios de preparação dos arquivos.

Esses elementos definem o material ao qual os resultados se referem e permitem acompanhar a formação dos conjuntos utilizados na comparação.

O acervo compartilhado encontra-se em <Pesquisa/Dataset>, no repositório do projeto. Para a conferência documental, foi considerada a revisão identificada pelo commit `f48fe3102f6b`, de 27 de outubro de 2026 (MUNIZ, 2026). A descrição dessa revisão distingue os arquivos coletados do conjunto final empregado na execução experimental.

3.3.1 Recorte anatômico e classes

O recorte do acervo concentra-se em fotografias do tronco, dos braços, das pernas e das nádegas, incluindo algumas regiões de dobra, como axilas e dobras do tronco. Imagens de cabeça, unhas, pés e regiões íntimas não foram incluídas. Essa delimitação organiza a tarefa em torno das apresentações cutâneas representadas nas fotografias e orienta a interpretação do classificador como uma ferramenta experimental para esse conjunto de regiões.

As imagens foram organizadas em PSOR, para os registros rotulados como psoríase, e NonPsor, para as condições não psoriáticas presentes no material coletado. A classe NonPsor reúne diferentes condições, sem constituir uma classificação específica de cada diagnóstico diferencial. A avaliação tem como unidade a imagem e não estima gravidade, área corporal acometida ou subtipo clínico. Também não foi produzida uma análise quantitativa por região anatômica, pois essa estratificação não integra os registros experimentais disponíveis.

3.3.2 Distribuição por fonte de origem

A composição de um acervo dermatológico envolve a escolha de imagens que representem a condição investigada e as demais condições incluídas na comparação. A identificação de sua procedência ajuda a compreender como esse material foi reunido e quais contextos de aquisição estão presentes no experimento. Neste estudo, o conjunto final reúne fotografias de bases e portais dermatológicos, complementadas por um acervo clínico privado, organizadas nas classes PSOR e NonPsor para a tarefa de classificação binária.

Entre as fontes utilizadas, o PUMCH-ISD foi desenvolvido no *Peking Union Medical College Hospital* e reúne fotografias clínicas e imagens dermatoscópicas de doenças inflamatórias cutâneas (WANG et al., 2025). O DermIS (*Dermatology Information System*) disponibiliza atlas de imagens acompanhadas de informações sobre diagnósticos e diagnósticos diferenciais, enquanto a biblioteca DErmPICX reúne imagens clínicas de psoríase em placas, com diferentes apresentações e tons de pele (DermIS, [s.d.]; DErmPICX, [s.d.]). A formação da classe NonPsor também utilizou fontes complementares com imagens e informações sobre outras dermatoses, incluindo eczemas, dermatites e infecções fúngicas.

O acervo clínico privado foi cedido para fins acadêmicos por uma clínica dermatológica vinculada à orientação do projeto. As fotografias foram recebidas previamente anonimizadas, sem nomes, documentos, prontuários ou outros identificadores diretos associados aos indivíduos. Sua contribuição ao estudo foi incorporada às mesmas classes utilizadas na organização das imagens das demais fontes.

A Tabela 3 apresenta a distribuição das 798 imagens efetivamente incluídas no conjunto final, com 386 registros PSOR e 412 NonPsor. Os quantitativos correspondem à contribuição de cada origem ao experimento, e não ao tamanho completo dos bancos consultados. Os nomes das fontes e dos portais contêm hiperlinks para consulta na versão digital do documento; a nota esclarece o agrupamento das fontes complementares.

Tabela 3 – Distribuição das imagens do conjunto final segundo a origem indicada nos registros de coleta

Fonte de origem	PSOR	NonPsor	Total
PUMCH-ISD	9	18	27
Acervo clínico privado anonimizado	250	44	294
DermIS	5	50	55
DErmPICX	122	0	122
Fontes complementares National Eczema Association; Manuais MSD; DermNet; DermAtlas	0	300	300
Total do conjunto final	**386**	**412**	**798**

A distribuição mostra que as fontes contribuem de maneira distinta para a formação das classes. O acervo clínico privado concentra a maior parcela das imagens PSOR, a DErmPICX contribui exclusivamente para essa classe e o grupo de fontes complementares reúne a maior parcela de NonPsor. Como enquadramento, iluminação, resolução e padrões de apresentação podem variar entre as origens, o detalhamento da procedência auxilia a interpretação dos resultados e o planejamento de avaliações por fonte. A conclusão da vinculação individual permitirá ampliar essa caracterização para os conjuntos de treinamento, validação e teste.

3.3.3 Conjunto experimental e partição

Após a preparação e a auditoria descritas, o conjunto experimental compreendeu **798 imagens**, sendo **386 PSOR** e **412 NonPsor**. Para organizar o desenvolvimento e a avaliação dos classificadores, adotou-se uma partição nominal de 70% para treinamento, 15% para validação e 15% para teste.

Essa distribuição buscou conciliar a disponibilidade de exemplos para aprendizagem com a reserva de observações para seleção e avaliação dos modelos. A maior parcela foi destinada ao treinamento, responsável pelo ajuste dos parâmetros das redes. A

validação orientou a preservação dos checkpoints e a seleção da arquitetura, enquanto o teste foi utilizado para caracterizar o desempenho dos classificadores, sem integrar os critérios de escolha. A proporção adotada constitui uma convenção de planejamento experimental descrita na literatura, cuja aplicação deve considerar o tamanho do acervo e as características da tarefa (KRAGH; KARSTOFT, 2021). A proporção foi uma decisão do protocolo; sua descrição não pressupõe que seja universalmente ótima para bases de imagens médicas (TEJANI et al., 2024).

A divisão foi realizada separadamente para cada classe e mantida fixa entre todas as arquiteturas e sementes, permitindo comparações sobre as mesmas observações. O arredondamento para baixo das contagens de treinamento e validação, com destinação das imagens restantes ao teste, resultou em 558, 118 e 122 imagens, respectivamente. Esses quantitativos correspondem a aproximadamente 70%, 15% e 15% do conjunto final, conforme a Tabela 4.

Tabela 4 – Distribuição das imagens entre os conjuntos experimentais

Conjunto	NonPsor	PSOR	Total
Treinamento	288	270	558
Validação	61	57	118
Teste	63	59	122
Total	412	386	798

Fonte: Relatório final da execução.

A organização por imagem permitiu executar a comparação no acervo disponível e registrar os resultados de cada combinação de arquitetura e semente. A documentação atual não estabelece um agrupamento completo por paciente ou fotografia clínica original; consequentemente, a unidade da avaliação apresentada é a imagem. O registro dessa unidade de avaliação acompanha os resultados apresentados. Na evolução do acervo, a vinculação entre fotografias relacionadas e sua origem permitirá planejar novas partições por grupos e avaliações independentes (TEJANI et al., 2024).

3.4 MODELAGEM E TREINAMENTO DOS CLASSIFICADORES

A comparação utilizou um protocolo comum de entrada, partição e treinamento, preservando os mecanismos internos de cada arquitetura. Essa organização permite examinar o comportamento das implementações sobre as mesmas observações e relacioná-lo aos recursos registrados. As escolhas de pré-processamento, adaptação da saída e seleção dos parâmetros são descritas a seguir.

3.4.1 Pré-processamento e aumento de dados

As imagens foram carregadas em RGB e redimensionadas para 224×224 pixels. Após conversão para tensores no intervalo $[0, 1]$, os canais foram normalizados por

$$x'_c = \frac{x_c - \mu_c}{\sigma_c}, \qquad \boldsymbol{\mu} = (0{,}485; 0{,}456; 0{,}406), \quad \boldsymbol{\sigma} = (0{,}229; 0{,}224; 0{,}225).$$

As constantes de média e desvio-padrão seguem a normalização associada aos pesos ImageNet disponibilizados pela Torchvision (PyTorch, 2026). No experimento, foram aplicadas explicitamente pelo script Python e preservadas nos metadados da exportação e no pré-processamento Android. A manutenção dessas transformações estabelece a correspondência entre as entradas preparadas nos dois ambientes.

O aumento de dados produz variações dos exemplos durante o ajuste e deve ser distinguido das transformações utilizadas na avaliação (SHORTEN; KHOSHGOFTAAR, 2019). Neste protocolo, somente no treinamento foram aplicados espelhamento horizontal aleatório e rotação aleatória de até $\pm 15°$. Validação e teste utilizaram transformação determinística: redimensionamento, conversão para tensor e normalização. O embaralhamento dos exemplos ocorreu no carregador de treinamento. Não foi implementada segmentação automática da lesão, e a imagem inteira fornecida ao modelo foi redimensionada para o formato de entrada.

3.4.2 Arquiteturas comparadas e adaptação para a tarefa

O protocolo compreendeu MobileNetV2, MobileNetV3 Small, ShuffleNetV2 x1.0, EfficientNet-B0, ResNet18 e DenseNet121. A escolha reuniu quatro alternativas compactas e duas referências de conectividade distintas, permitindo investigar o compromisso entre desempenho classificatório e recursos em um mesmo problema. A VGG16 participou de uma etapa exploratória anterior, mas foi retirada do protocolo final em razão de seu custo pouco alinhado à finalidade de operação móvel. As 18 execuções descritas neste trabalho correspondem exclusivamente às seis arquiteturas da comparação.

As redes foram obtidas da Torchvision 0.25 e inicializadas com os pesos ImageNet indicados na Tabela 5. Aprendidos em imagens de categorias gerais, esses pesos permitem aproveitar representações visuais genéricas como ponto de partida para a adaptação ao domínio dermatológico (PyTorch, 2026; RUSSAKOVSKY et al., 2015; DAVILA; COLAN; HASEGAWA, 2024). Em cada implementação, a última camada linear foi substituída por uma unidade de saída, preservando a estrutura dos demais componentes. A distinção entre PSOR e NonPsor foi aprendida durante o ajuste fino integral com as imagens do estudo, de modo que todas as redes passaram a produzir um logit para a classe PSOR, conforme a Equação 2.12 (MUNIZ, 2026).

Tabela 5 – Implementações e dimensões das redes adaptadas à classificação binária

Arquitetura	Mecanismo predominante	Pesos ImageNet	Parâmetros (milhões)
MobileNetV2	Residual invertido e gargalo linear	1K V2	2,23
MobileNetV3 Small	Blocos móveis e atenção por canais	1K V1	1,52
ShuffleNetV2 x1.0	Divisão, concatenação e reorganização de canais	1K V1	1,25
EfficientNet-B0	MBConv e atenção por canais	1K V1	4,01
ResNet18	Blocos básicos com conexão residual	1K V1	11,18
DenseNet121	Concatenação densa de características	1K V1	6,95

Fonte: Implementações adaptadas do experimento e documentação da Torchvision (PyTorch, 2026).

Os quantitativos de parâmetros se referem às versões binárias utilizadas, e por isso diferem dos valores publicados para os classificadores ImageNet de mil classes. Essa especificação é importante para relacionar dimensão estrutural, tamanho dos checkpoints e execução no experimento. A comparação adota resolução, divisão de dados e procedimento de ajuste comuns, sem pressupor que o pré-treinamento das seis redes tenha seguido uma receita única: a MobileNetV2 utiliza pesos ImageNet1K V2, enquanto as demais implementações empregam as versões V1 indicadas na tabela.

O ajuste fino foi integral, abrangendo os parâmetros da rede e da camada substituída. Com isso, as representações inicializadas no pré-treinamento puderam ser modificadas para responder às características do acervo dermatológico. A escolha de uma arquitetura para o protótipo ocorreu somente após essa adaptação e a comparação por validação, preservando a distinção entre a motivação teórica para incluir uma família e o resultado empírico obtido por sua implementação.

3.4.3 Treinamento, repetição e seleção

A comparação entre arquiteturas considerou a variabilidade associada ao treinamento, uma vez que fontes de aleatoriedade podem influenciar o desempenho observado em uma execução (BOUTHILLIER et al., 2021). Cada arquitetura foi treinada com as sementes 42, 123 e 2026, totalizando $6 \times 3 = 18$ execuções. Foram controlados os geradores de números aleatórios de Python, NumPy e PyTorch, conforme as orientações de controle das fontes de aleatoriedade da biblioteca (PyTorch, 2025c).

As imagens dos conjuntos permaneceram fixas entre arquiteturas e sementes. Os resultados agregados são apresentados como média e desvio-padrão amostral entre as três execuções, permitindo caracterizar o comportamento médio e sua dispersão nas condições avaliadas. Como a partição não foi modificada, esse desvio descreve a variabilidade do treinamento sobre os mesmos conjuntos, sem constituir intervalo de confiança ou resultado de validação cruzada.

Foi empregado ajuste fino integral, com atualização dos parâmetros de todas as camadas, estratégia utilizada na adaptação de modelos pré-treinados à classificação de imagens médicas (DAVILA; COLAN; HASEGAWA, 2024). A otimização utilizou Adam (KINGMA; BA, 2015), com taxa de aprendizado de 0,001 e lote de treinamento de 16 imagens. A função de perda foi `BCEWithLogitsLoss`, que combina a transformação sigmoide e a entropia cruzada binária em uma implementação numericamente estável (PyTorch, [s.d.]a).

O acompanhamento da perda de validação orientou a parada antecipada, apoiando-se no princípio de monitoramento da generalização discutido por Prechelt (2012). No protocolo adotado, o treinamento foi limitado a 20 épocas, com interrupção após três épocas consecutivas sem redução da perda média de validação. Os carregadores de validação e teste utilizaram lote unitário e não realizaram embaralhamento.

O arquivo salvo, denominado *checkpoint*, contém os parâmetros da rede correspondentes a um estado do treinamento. Recuperar esse estado permite avaliar e exportar os mesmos pesos, preservando a ligação entre a época escolhida e as etapas posteriores (PyTorch, [s.d.]b). No presente protocolo, o checkpoint de cada execução foi determinado pela menor perda de validação; a escolha entre arquiteturas utilizou o F1 de validação dos estados já preservados.

A seleção foi organizada em três níveis, distinguindo a preservação dos parâmetros durante o treinamento da escolha da arquitetura e de seu checkpoint representativo:

1. **Época salva em cada execução:** o checkpoint foi atualizado sempre que ocorreu redução da perda de validação. Ao término, manteve-se o estado correspondente à menor perda daquela combinação de arquitetura e semente. O salvamento e a recuperação desse estado utilizaram os mecanismos documentados no PyTorch (PyTorch, [s.d.]b).

2. **Arquitetura selecionada:** entre as arquiteturas com as três execuções concluídas, escolheu-se aquela com maior F1 médio de validação. A AUC média de validação foi utilizada como primeiro desempate; persistindo o empate, o identificador da arquitetura estabeleceu uma ordem determinística.

3. **Semente representativa:** dentro da arquitetura selecionada, escolheu-se o checkpoint com maior F1 de validação, seguido por maior AUC de validação e menor valor da semente em caso de empate.

Os critérios de seleção utilizaram exclusivamente as métricas de validação. A distinção entre os dados empregados na seleção e aqueles destinados à avaliação fundamenta-se na necessidade de controlar o viés introduzido quando os resultados da avaliação influenciam a escolha do modelo (CAWLEY; TALBOT, 2010).

Para cada arquitetura, a regra do terceiro nível também definiu uma semente representativa, utilizada nos painéis de matrizes de confusão e curvas ROC. As métricas de teste foram calculadas para os checkpoints das 18 execuções, enquanto os resultados de validação permaneceram como os únicos dados empregados na seleção. Os valores de taxa de aprendizado, lote, limite de épocas, paciência e desempate constituem as configurações deste experimento, registradas no código e nos arquivos de execução (MUNIZ, 2026).

3.5 AVALIAÇÃO CLASSIFICATÓRIA, RECURSOS E EXPLICABILIDADE

A avaliação relacionou a qualidade das predições ao custo de execução e acrescentou uma inspeção exploratória de respostas individuais. As métricas foram calculadas em conjuntos identificados, os recursos foram medidos em etapas delimitadas e as explicações conservaram o mesmo alvo. Essa separação permite interpretar cada resultado de acordo com a pergunta à qual ele responde.

3.5.1 Métricas classificatórias

As métricas de classificação permitem examinar aspectos diferentes da distribuição dos acertos e erros; por isso, foram utilizadas em conjunto (SOKOLOVA; LAPALME, 2009). A decisão binária utilizou limiar fixo $p_{\mathrm{PSOR}} \geq 0{,}5$. Considerando PSOR como classe positiva, foram calculados

$$\text{Sensibilidade} = \frac{TP}{TP+FN}, \qquad \text{Especificidade} = \frac{TN}{TN+FP}, \qquad \text{Precisão} = \frac{TP}{TP+FP},$$

$$F1_{\mathrm{PSOR}} = \frac{2TP}{2TP+FP+FN}, \qquad \text{Acurácia} = \frac{TP+TN}{TP+TN+FP+FN}.$$

Nessas expressões, TP e TN representam verdadeiros positivos e negativos, enquanto FP e FN representam falsos positivos e negativos. Também foram obtidos a área sob a curva ROC (AUC), o Kappa de Cohen, o F1 macro e a acurácia balanceada. A AUC utiliza as saídas contínuas e resume a ordenação das classes ao variar o limiar; o Kappa corrige a concordância observada pela concordância esperada a partir das marginais. A matriz de confusão explicita os erros e acertos por classe (FAWCETT, 2006; COHEN, 1960).

O F1 principal corresponde à classe positiva, e não à média dos F1 das duas classes. Nos painéis, as matrizes apresentam contagens e percentuais por classe real, com a mesma escala visual. Não foi realizado teste formal de superioridade entre arquiteturas. A saída sigmoide é tratada como pontuação do modelo; não foi realizada calibração de probabilidade clínica.

3.5.2 Medição de tempo e memória no computador

A caracterização operacional considerou o tempo de execução, a ocupação de memória e o tamanho dos checkpoints, permitindo examinar diferentes dimensões do custo computacional do treinamento e da inferência. Os tempos decorridos foram medidos com `time.perf_counter()`, contador de alta resolução com comportamento monotônico no CPython, apropriado à medição de intervalos de execução (Python Software Foundation, [s.d.]).

O treinamento e a avaliação foram executados em processos separados. A avaliação carregou o checkpoint em um processo novo, sem conservar o otimizador ou os tensores utilizados no treinamento. Foram registradas as etapas de inicialização do modelo, treinamento por época, validação, carregamento do checkpoint, avaliação com leitura dos dados e benchmark de inferência. A delimitação dessas etapas foi implementada no código do experimento (MUNIZ, 2026).

O tempo total de treinamento compreendeu as épocas executadas, a validação, a gravação dos checkpoints e a produção dos registros. A inicialização do modelo e eventuais downloads dos pesos pré-treinados foram medidos separadamente. Como a parada antecipada pode encerrar as execuções em épocas diferentes, o tempo total representa o custo do protocolo efetivamente executado, podendo corresponder a quantidades distintas de atualizações dos parâmetros.

Na avaliação com operações de entrada e saída, o intervalo cronometrado abrangeu leitura das imagens, transformação, transferência dos tensores, execução da rede e coleta das saídas. O cálculo final das métricas classificatórias foi realizado fora desse intervalo. No benchmark da rede, por sua vez, cada imagem já estava transformada e transferida antes do início da medição individual, que incluiu a propagação direta (*forward*) e a aplicação da sigmoide, com lote unitário.

A adoção de aquecimento e medições repetidas apoia-se nas práticas de benchmarking descritas pelo PyTorch, que consideram os efeitos de inicialização e a variabilidade entre execuções (PyTorch, 2025a). No protocolo adotado, foram realizadas dez inferências de aquecimento na preparação da avaliação e três passagens sobre as 122 imagens de teste, totalizando 366 registros de latência por execução. A mediana e o percentil 95 foram calculados sobre esses registros e, posteriormente, resumidos entre as sementes.

A ocupação de RAM foi acompanhada pelo campo RSS (*Resident Set Size*) disponibilizado pelo `psutil`, que representa a memória física residente do processo. No Windows, ambiente utilizado no experimento, esse campo corresponde ao *working set* do processo (psutil, [s.d.]). Foram realizadas amostragens com intervalo-alvo de aproximadamente 50 ms, registrando nível inicial, pico observado, incremento do pico em relação ao nível inicial, média amostral e nível final, em MiB.

O RSS caracteriza o processo completo, abrangendo componentes do ambiente de execução, bibliotecas, tensores e outras alocações residentes. No benchmark, seu

monitoramento acompanhou a fase completa, incluindo as operações do carregador de dados, enquanto a latência individual utilizou o intervalo delimitado para a rede. Picos de memória ocorridos entre duas amostragens podem não ser captados. O tamanho do checkpoint foi registrado separadamente como medida do arquivo armazenado.

O tempo acumulado de CPU foi obtido pela soma dos incrementos dos tempos de usuário e de sistema informados pelo `psutil`. Essa medida representa o trabalho de processamento atribuído ao processo e pode superar o tempo decorrido quando há execução simultânea em múltiplos núcleos (psutil, [s.d.]).

Os campos previstos para CUDA distinguem o pico de memória ocupado por tensores do pico de memória reservado pelo alocador do PyTorch (PyTorch, 2025b). Como as execuções apresentadas foram realizadas em CPU, não são reportados valores de utilização de VRAM. A instrumentação não incluiu energia elétrica, descarga de bateria ou temperatura; a caracterização operacional apresentada restringe-se às medidas de tempo, memória e tamanho dos arquivos.

3.5.3 Protocolo de explicabilidade exploratória

A inspeção visual foi aplicada ao checkpoint escolhido para o protótipo. Foram sorteadas, com semente 42, duas imagens de teste por classe, sem seleção visual pela qualidade dos mapas. Grad-CAM, LIME e SHAP explicaram o mesmo alvo, PSOR, inclusive nas imagens NonPsor. Assim, uma explicação de imagem negativa descreve a relação de suas regiões com a resposta PSOR, o que permite acompanhar o mesmo alvo nos quatro exemplos (SELVARAJU et al., 2017; RIBEIRO; SINGH; GUESTRIN, 2016; LUNDBERG; LEE, 2017).

O Grad-CAM utilizou a última etapa do extrator de características da arquitetura selecionada e o logit PSOR, mantendo as contribuições positivas conforme a formulação do método. Antes do ajuste de cores, registrou-se a diferença entre o maior e o menor valor do mapa. Quando essa amplitude é nula, o resultado é identificado como mapa sem variação espacial, preservando essa informação no relatório (SELVARAJU et al., 2017).

O LIME empregou mil perturbações, construídas a partir de regiões da imagem, e segmentação SLIC com solicitação de 50 segmentos. Foram registrados o número efetivamente obtido e o R^2 da aproximação local. O SHAP utilizou a implementação Partition, referência preta e limite de 500 avaliações, com contribuições aproximadas para a pontuação PSOR (RIBEIRO; SINGH; GUESTRIN, 2016; SHAP, [s.d.]). No painel, as atribuições foram agregadas espacialmente e as cores ajustadas por mapa, conservando a distinção entre o alvo no logit do Grad-CAM e na saída sigmoide dos outros métodos.

Foram preservados mapas numéricos, imagens PNG, status e medidas de recursos. Os métodos foram executados sequencialmente no mesmo processo de explicabilidade; por isso, o RSS de cada etapa pode incluir alocações retidas das anteriores. A inspeção não utilizou máscaras de lesão anotadas por especialistas nem realizou uma avaliação clínica

da localização dos destaques. Essa descrição delimita a análise exploratória e distingue conclusão técnica de execução de qualidade clínica da explicação (ARUN et al., 2021; TEJANI et al., 2024).

3.6 DESENVOLVIMENTO E INTEGRAÇÃO DO PROTÓTIPO ANDROID

O protótipo foi desenvolvido para receber um modelo já treinado, preparar uma fotografia e executar a classificação no próprio dispositivo. Essa organização estabelece uma continuidade entre o experimento e a aplicação: a interface utiliza um artefato exportado e verificado, enquanto o treinamento permanece no computador. A separação entre aplicativo e pesos também permite substituir um pacote compatível sem recompilar a interface (ONNX Runtime, [s.d.]b; MUNIZ, 2026).

3.6.1 Plataforma de desenvolvimento e organização funcional

A aplicação nativa foi implementada em Kotlin e integrada à biblioteca ONNX Runtime Android 1.24.3 por sua interface Java, acessível à linguagem utilizada (ONNX Runtime, [s.d.]a). O mecanismo de execução foi configurado para CPU, com quatro threads intraoperação e uma interoperacional; esses parâmetros são opções da sessão de inferência e não representam medições de desempenho (ONNX Runtime, [s.d.]c). O APK contempla processadores ARM de 32 e 64 bits, requer Android 8.0 ou superior e não solicita permissão de internet na versão distribuída.

O fluxo funcional reúne importação do modelo, autoteste, seleção de imagem, pré-processamento, inferência e apresentação da resposta, acompanhado da opção de registrar desempenho e exportar medições. As explicações Grad-CAM, LIME e SHAP permanecem na análise realizada no computador. A Figura 7 apresenta a organização adotada para a integração, enquanto as telas e as verificações concluídas são apresentadas nos resultados.

3.6.2 Exportação ONNX e critérios de equivalência

O ONNX permite representar o grafo e os parâmetros do modelo em um formato utilizado por mecanismos de inferência distintos do ambiente de treinamento. O exportador encapsulou a rede PyTorch com a função sigmoide e produziu uma entrada estática NCHW de dimensão $1 \times 3 \times 224 \times 224$, com saída correspondente à pontuação PSOR (PyTorch, [s.d.]c). Foram mantidos os pesos em FP32, sem quantização, poda ou compressão com perda de precisão.

A conferência da exportação comparou as saídas de PyTorch e ONNX nas 122 imagens de teste, sob o pré-processamento definido no experimento. Como critérios de

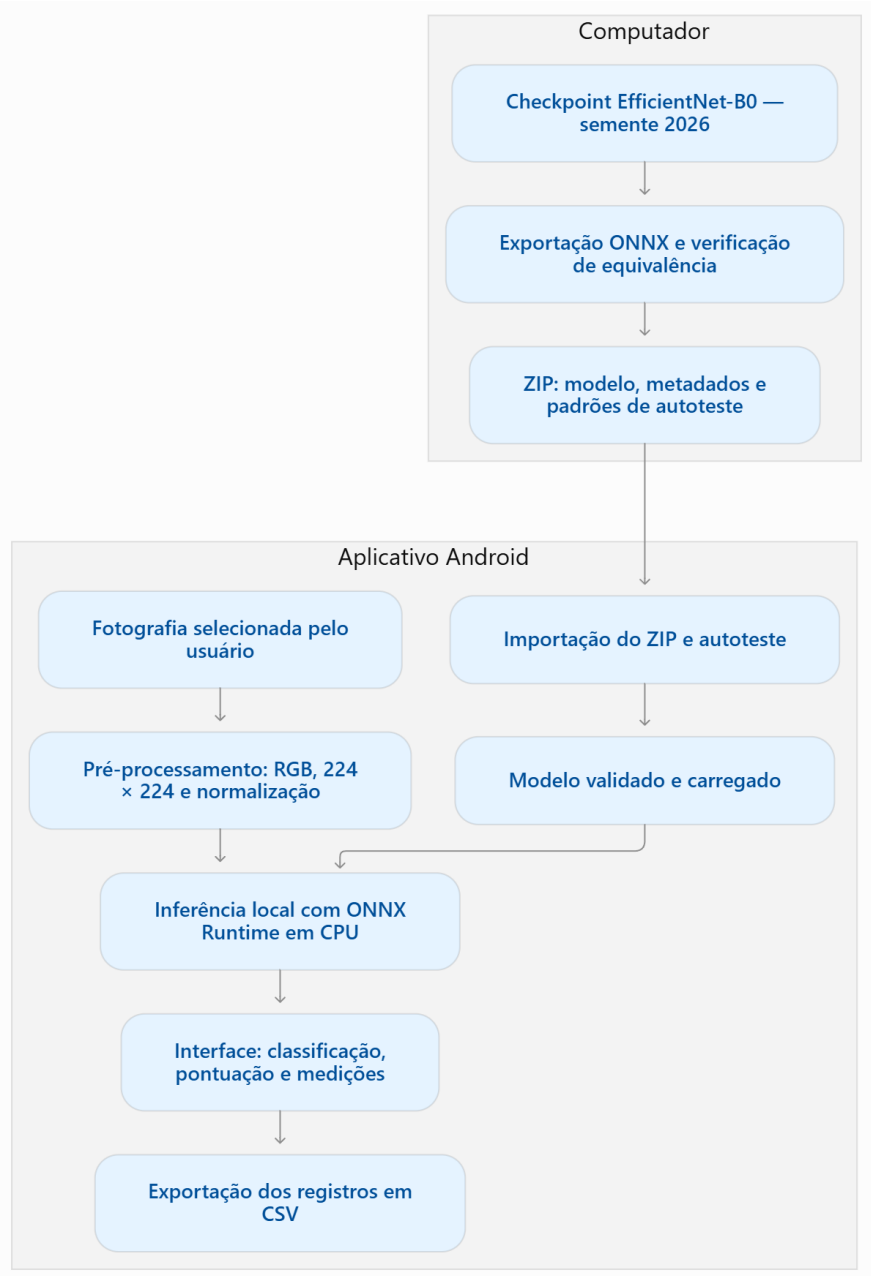


Figura 7 – Organização da integração Android: no computador, exportação e conferência do modelo; no dispositivo, importação do ZIP, autoteste, preparação da imagem, inferência em CPU e apresentação da resposta, com exportação local de medições. Fonte: elaboração do autor.

aprovação, foram exigidos erro absoluto máximo não superior a 10^{-4} e coincidência das decisões no limiar de 0,5. Esse procedimento examinou a fidelidade da conversão nas entradas verificadas; não correspondeu a um novo treinamento ou a uma avaliação clínica adicional. O erro observado e a contagem das decisões coincidentes são apresentados na Seção 4.6.1.

O pacote de importação foi organizado em ZIP, reunindo o modelo ONNX, os metadados de entrada e saída, as constantes de normalização, a identificação do modelo, seu hash e padrões sintéticos de referência. Esses componentes documentam o contrato entre exportador e aplicativo e permitem conferir o artefato recebido pelo aparelho (MUNIZ, 2026).

3.6.3 Importação, verificação e persistência do modelo

A importação verifica a estrutura do ZIP, os arquivos permitidos, a consistência dos metadados e o hash SHA-256 do ONNX. O limite de extração é de 120 MiB descompactados, e a conferência ocorre em uma etapa intermediária antes de ativar o novo pacote. O hash permite verificar a correspondência entre o arquivo e o valor registrado nos metadados; sua função é de integridade, sem autenticar por si só a origem do modelo (National Institute of Standards and Technology, 2015).

O autoteste utiliza três padrões sintéticos e compara os tensores preparados e as saídas com os valores de referência. As tolerâncias máximas implementadas são 2×10^{-5} para a entrada normalizada e 10^{-3} para a saída. Após a aprovação, o pacote é ativado no armazenamento privado do aplicativo e restaurado nas aberturas seguintes, utilizando os mecanismos de arquivos específicos da aplicação (Android Developers, [s.d.]a). A assinatura digital do APK, empregada pelo Android na instalação e atualização, constitui uma verificação distinta daquela realizada sobre o modelo importado (Android Developers, [s.d.]f).

3.6.4 Preparação da fotografia e apresentação da classificação

A imagem é selecionada pelo mecanismo de documentos do Android, que permite ao usuário indicar o arquivo a ser aberto (Android Developers, [s.d.]b). O protótipo admite imagens decodificáveis pelo aparelho de até 16 megapixels. A fotografia inteira é redimensionada para 224×224, convertida para RGB e normalizada com as constantes do pacote. Não foram implementados recorte automático da lesão, segmentação ou correção de orientação EXIF; orientação e enquadramento antecedem a seleção da imagem pelo usuário.

A sessão produz a pontuação PSOR, e o limiar registrado nos metadados determina a classe estimada. O percentual exibido corresponde a $100p_{\mathrm{PSOR}}$, seguindo a mesma formulação utilizada no experimento. As classes da interface foram definidas como *Psoríase*

e *Não é psoríase*, preservando PSOR e NonPsor nos registros técnicos. As mensagens associadas esclarecem a finalidade experimental da classificação. O rótulo de referência, quando informado, é registrado separadamente e não participa da predição.

3.6.5 Instrumentação no aparelho e exportação dos registros

No modo de análise, o aplicativo realiza uma inferência. No modo de desempenho, prepara a imagem uma vez e executa cinco aquecimentos e trinta inferências temporizadas sobre essa mesma entrada. São registrados os tempos de leitura, pré-processamento, carregamento da sessão, execução e duração da etapa, além do tempo acumulado de CPU. As latências individuais permitem obter média, mediana e percentil 95. O tempo de CPU é lido pelo recurso disponibilizado pelo Android para o processo (Android Developers, [s.d.]e).

A memória é acompanhada pelo PSS, ou *Proportional Set Size*, com amostras aproximadamente a cada 50 ms e registros inicial, máximo observado e final. Essa medida contabiliza proporcionalmente a participação do processo em páginas compartilhadas, conforme a documentação do Android (Android Developers, [s.d.]c; Android Developers, [s.d.]d). Ela possui definição diferente do RSS utilizado no computador. Também difere o intervalo de inferência: no aplicativo, ele inclui criação do tensor ONNX, execução e leitura da saída; no benchmark PyTorch, a entrada já está preparada antes da medição. Essas diferenças precisam acompanhar qualquer comparação entre plataformas.

Os registros permanecem na memória da sessão e podem ser exportados em CSV UTF-8 com BOM, separador ponto e vírgula e ponto decimal. O arquivo identifica o modelo, a versão e as condições técnicas da execução, sem incluir fotografias, nomes ou caminhos de imagens. Seu identificador distingue registros e permite reconhecer linhas repetidas entre exportações, mas não identifica a fotografia. Em uma coleta com várias entradas, a correspondência entre imagem e medição deve ser mantida por um protocolo externo codificado. A exportação não apaga a sessão, e o encerramento ou a recriação da atividade pode descartar registros ainda não exportados.

3.7 AMBIENTE COMPUTACIONAL E RASTREABILIDADE

O treinamento e a avaliação foram executados em Windows 11, com Python 3.14.2, PyTorch 2.10.0+cpu, Torchvision 0.25.0+cpu, NumPy 2.4.2 e psutil 7.2.2. A CPU foi identificada pelo sistema como AMD64 Family 25 Model 80 Stepping 0, AuthenticAMD, com 12 núcleos lógicos e aproximadamente 15,79 GiB de RAM física total. O PyTorch foi configurado para quatro threads. Essas versões descrevem o ambiente da execução apresentada e acompanham a interpretação das medições.

O fluxo produz arquivos de configuração, registros por execução, checkpoints, CSVs, figuras PNG e relatório consolidado. A organização por arquitetura e semente permite

relacionar cada resultado aos parâmetros preservados e aos arquivos usados na avaliação. A descrição de software, hardware, seleção e disponibilização dos artefatos atende à necessidade de tornar o experimento examinável, conforme os itens de documentação propostos no CLAIM 2024 (TEJANI et al., 2024).

Os artefatos compartilhados estão vinculados ao repositório identificado na Seção 3.3. Sua organização inclui scripts de pesquisa, acervo, checkpoints, resultados públicos, APK e documentação (MUNIZ, 2026). O Apêndice B apresenta o roteiro de reprodução e a localização dos arquivos, e o Apêndice A descreve a operação do aplicativo.

3.8 ASPECTOS ÉTICOS E ÂMBITO DE UTILIZAÇÃO

O estudo utiliza imagens secundárias e não incluiu atendimento, intervenção ou coleta prospectiva nesta etapa. As fotografias do acervo clínico privado foram recebidas previamente anonimizadas, sem nomes, documentos, prontuários ou identificadores diretos associados. O tratamento das informações foi delimitado à finalidade acadêmica de preparação dos dados, comparação dos classificadores e desenvolvimento do protótipo. A proteção da privacidade e a minimização das informações associadas são consideradas em relação aos princípios e às definições da LGPD (Brasil, 2018).

A execução local foi adotada para que a análise não dependesse do envio da fotografia a um servidor. Os registros exportados se concentram na identificação técnica da execução e em suas medições. O sistema é apresentado como protótipo acadêmico experimental, e suas mensagens distinguem a classificação de uma confirmação ou exclusão diagnóstica. A eventual investigação assistencial requer um protocolo próprio, no qual sejam definidos público, condições de aquisição, avaliação clínica e requisitos institucionais aplicáveis.

4 RESULTADOS

4.1 COBERTURA EXPERIMENTAL E SELEÇÃO

As 18 execuções previstas foram concluídas: seis arquiteturas, cada uma treinada com três sementes na mesma partição. A seleção pela validação indicou a **EfficientNet-B0**, com o checkpoint da **semente 2026**. Esse resultado decorre do critério definido na Seção 3.4.3; a classificação das redes no teste e seus custos computacionais são apresentados como informações complementares.

O experimento permite distinguir a arquitetura selecionada pelo critério preditivo de validação das alternativas de menor custo. Essa distinção é relevante para a continuidade do sistema: o modelo integrado ao aplicativo segue a seleção registrada, enquanto uma eventual escolha baseada em restrições adicionais de latência ou memória exigirá critério próprio, definido e avaliado de forma explícita.

4.2 DESEMPENHO CLASSIFICATÓRIO

A Tabela 6 reúne as métricas do teste como média e desvio-padrão entre as três sementes. Todas as execuções foram avaliadas nas mesmas 122 imagens, sendo 59 PSOR e 63 NonPsor. Portanto, as três avaliações não correspondem a 366 indivíduos independentes, e o desvio entre sementes não expressa incerteza populacional.

Tabela 6 – Desempenho no teste: média e desvio-padrão entre as três sementes

Arquitetura	F1 PSOR	Sensibilidade	Especificidade	AUC	Acurácia	Kappa
MobileNetV2	$0{,}918 \pm 0{,}018$	$0{,}949 \pm 0{,}034$	$0{,}889 \pm 0{,}000$	$0{,}965 \pm 0{,}016$	$0{,}918 \pm 0{,}016$	$0{,}836 \pm 0{,}033$
MobileNetV3 Small	$0{,}889 \pm 0{,}016$	$0{,}927 \pm 0{,}020$	$0{,}852 \pm 0{,}024$	$0{,}965 \pm 0{,}016$	$0{,}888 \pm 0{,}017$	$0{,}776 \pm 0{,}034$
ShuffleNetV2 x1.0	$0{,}913 \pm 0{,}005$	$0{,}955 \pm 0{,}020$	$0{,}873 \pm 0{,}016$	$0{,}977 \pm 0{,}014$	$0{,}913 \pm 0{,}005$	$0{,}825 \pm 0{,}010$
EfficientNet-B0	$0{,}919 \pm 0{,}023$	$0{,}932 \pm 0{,}045$	$0{,}910 \pm 0{,}018$	$0{,}974 \pm 0{,}010$	$0{,}921 \pm 0{,}021$	$0{,}841 \pm 0{,}041$
ResNet18	$0{,}844 \pm 0{,}027$	$0{,}876 \pm 0{,}054$	$0{,}815 \pm 0{,}018$	$0{,}920 \pm 0{,}002$	$0{,}844 \pm 0{,}022$	$0{,}689 \pm 0{,}044$
DenseNet121	$0{,}898 \pm 0{,}024$	$0{,}898 \pm 0{,}045$	$0{,}905 \pm 0{,}016$	$0{,}960 \pm 0{,}017$	$0{,}902 \pm 0{,}022$	$0{,}803 \pm 0{,}044$

Fonte: Relatório final e registros da execução experimental V5.

A EfficientNet-B0 apresentou F1 médio de $0{,}919 \pm 0{,}023$, AUC de $0{,}974 \pm 0{,}010$ e especificidade de $0{,}910 \pm 0{,}018$. A MobileNetV2 apresentou F1 de $0{,}918 \pm 0{,}018$ e sensibilidade de $0{,}949 \pm 0{,}034$. A diferença de 0,001 no F1 médio dessas duas redes é apenas descritiva; não foi realizado teste de superioridade ou equivalência.

A ShuffleNetV2 x1.0 apresentou a maior AUC média de teste, $0{,}977 \pm 0{,}014$, e sensibilidade de $0{,}955 \pm 0{,}020$, com F1 de $0{,}913 \pm 0{,}005$. Esse resultado reforça a utilidade de examinar métricas complementares: a maior AUC no teste não substitui o critério

de F1 médio de validação utilizado na seleção. A MobileNetV3 Small apresentou F1 de $0{,}889 \pm 0{,}016$, compondo uma alternativa de menor custo cuja contrapartida classificatória deve ser considerada.

A DenseNet121 apresentou F1 de $0{,}898 \pm 0{,}024$ e AUC de $0{,}960 \pm 0{,}017$. A ResNet18 obteve F1 de $0{,}844 \pm 0{,}027$ e AUC de $0{,}920 \pm 0{,}002$. Nesse protocolo, as redes de maior dimensão estrutural não apresentaram vantagem geral sobre as alternativas mais compactas. A relação dessas métricas com os recursos computacionais é examinada na seção seguinte.

4.3 DESEMPENHO E RECURSOS COMPUTACIONAIS

A Tabela 7 reúne tamanho estrutural, arquivo de checkpoint e tempos. A MobileNetV3 Small apresentou a menor latência mediana, $7{,}87 \pm 0{,}11$ ms. A ShuffleNetV2 x1.0 apresentou o menor número de parâmetros e o menor checkpoint, aproximadamente 1,25 milhão e 4,95 MiB. A MobileNetV2 combinou F1 descritivamente próximo ao da EfficientNet-B0 com mediana de $12{,}28 \pm 1{,}81$ ms e checkpoint de 8,72 MiB.

Tabela 7 – Complexidade e tempos em CPU: cada resumo de latência é agregado entre sementes

Arquitetura	Parâmetros (milhões)	Checkpoint (MiB)	Treino e validação (s)	Mediana (ms)	p95 (ms)
MobileNetV2	2,23	8,72	$271{,}7 \pm 37{,}8$	$12{,}28 \pm 1{,}81$	$18{,}51 \pm 1{,}39$
MobileNetV3 Small	1,52	5,92	$144{,}4 \pm 35{,}7$	$7{,}87 \pm 0{,}11$	$10{,}02 \pm 0{,}73$
ShuffleNetV2 x1.0	1,25	4,95	$142{,}8 \pm 31{,}4$	$13{,}77 \pm 0{,}23$	$16{,}93 \pm 0{,}35$
EfficientNet-B0	4,01	15,58	$547{,}1 \pm 129{,}5$	$20{,}95 \pm 0{,}40$	$25{,}77 \pm 1{,}14$
ResNet18	11,18	42,71	$304{,}6 \pm 53{,}9$	$27{,}02 \pm 0{,}92$	$30{,}72 \pm 0{,}98$
DenseNet121	6,95	27,10	$688{,}4 \pm 96{,}8$	$49{,}59 \pm 8{,}76$	$55{,}12 \pm 4{,}86$

Fonte: Relatório final e registros da execução experimental V5.

A EfficientNet-B0, selecionada pela validação, apresentou mediana de $20{,}95 \pm 0{,}40$ ms e checkpoint de 15,58 MiB. A ResNet18 apresentou o maior checkpoint, 42,71 MiB, enquanto a DenseNet121 apresentou a maior latência mediana, $49{,}59 \pm 8{,}76$ ms. Esses resultados indicam que arquitetura selecionada, menor latência e menor arquivo são atributos diferentes, permitindo fundamentar decisões de implantação de acordo com as restrições do uso pretendido.

O tempo de treinamento inclui validação e gravação de checkpoints. A parada antecipada pode produzir números de épocas diferentes; assim, a comparação descreve o custo para executar o protocolo adotado. Não se atribui toda a diferença de tempo exclusivamente ao custo de uma época de cada arquitetura.

Na Tabela 8, o menor pico médio de RSS durante o treino foi observado na MobileNetV3 Small, $820{,}9 \pm 3{,}6$ MiB, e o maior na DenseNet121, $2747{,}9 \pm 2{,}6$ MiB. Na

Tabela 8 – Picos observados de RSS do processo Python

Arquitetura	Treinamento (MiB)	Inferência (MiB)
MobileNetV2	$1879{,}8 \pm 10{,}4$	$525{,}6 \pm 0{,}5$
MobileNetV3 Small	$820{,}9 \pm 3{,}6$	$504{,}4 \pm 6{,}6$
ShuffleNetV2 x1.0	$901{,}2 \pm 13{,}7$	$504{,}7 \pm 7{,}7$
EfficientNet-B0	$2068{,}6 \pm 32{,}1$	$534{,}6 \pm 0{,}8$
ResNet18	$1098{,}5 \pm 17{,}0$	$586{,}4 \pm 1{,}5$
DenseNet121	$2747{,}9 \pm 2{,}6$	$547{,}4 \pm 15{,}7$

Fonte: Relatório final V5; média e desvio-padrão entre três sementes.

inferência, os picos ficaram entre aproximadamente 504 e 586 MiB. A proximidade de parte desses valores, apesar das diferenças no tamanho dos checkpoints, evidencia a contribuição do processo Python e de suas bibliotecas para o RSS total. Não se deve interpretar o RSS como memória exclusiva dos parâmetros da rede.

Os resultados de tempo e memória documentam a execução em CPU no ambiente registrado. Eles sustentam a escolha de candidatas para avaliação no celular, mas não representam medições de consumo energético, bateria ou latência móvel. O aplicativo possui instrumentação própria para essa etapa, descrita na Seção 3.6.5 e no manual do Apêndice A.

A Figura 8 permite examinar conjuntamente o desempenho classificatório e o tempo de inferência das arquiteturas. O eixo vertical apresenta o F1 médio da classe PSOR no teste, enquanto o horizontal representa a média, entre sementes, das latências medianas por imagem. Assim, posições mais elevadas e à esquerda correspondem à combinação de maior F1 e menor latência. A EfficientNet-B0 apresentou o maior F1 médio observado, de 0,919, com latência de 20,95 ms por imagem. A MobileNetV2 alcançou F1 próximo, de 0,918, com latência de 12,28 ms, evidenciando uma alternativa com desempenho classificatório semelhante em termos das médias observadas e menor tempo de execução (MUNIZ, 2026).

Entre as demais implementações, a MobileNetV3 Small apresentou a menor latência, de 7,87 ms por imagem, acompanhada de F1 médio de 0,889. A ShuffleNetV2 x1.0 reuniu F1 de 0,913 e latência de 13,77 ms, situando-se próxima à MobileNetV2 nos dois indicadores. A ResNet18 apresentou F1 de 0,844 e latência de 27,02 ms, enquanto a DenseNet121 registrou F1 de 0,898 e a maior latência da comparação, de 49,59 ms. Essas diferenças mostram a importância de considerar simultaneamente a capacidade de classificação e o custo temporal nas condições de execução avaliadas.

As barras horizontais e verticais representam, respectivamente, os desvios-padrão entre sementes da latência mediana e do F1. A ShuffleNetV2 x1.0 apresentou a menor dispersão do F1, enquanto a DenseNet121 exibiu a maior dispersão da latência. A interpretação das diferenças entre as médias considera essa variabilidade, cuja relevância para comparações entre modelos é discutida por Bouthillier et al. (2021). A escolha da EfficientNet-B0 para integração ao protótipo decorreu dos critérios de validação estabe-

lecidos no protocolo; a figura acrescenta a caracterização do desempenho no teste e da latência no computador utilizado no experimento.

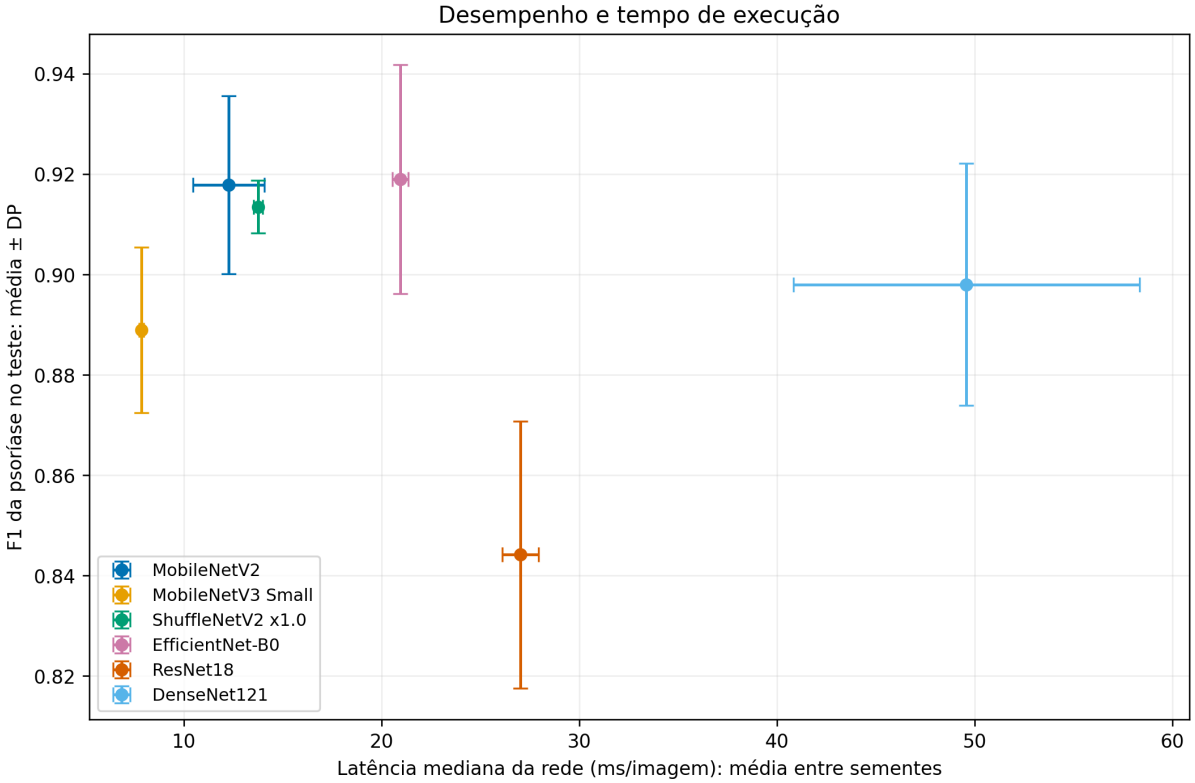


Figura 8 – Síntese do desempenho classificatório e da latência em CPU para as seis arquiteturas. As barras de variabilidade representam o desvio entre sementes na partição fixa; os tempos são do computador, não do aplicativo Android. Fonte: Autor.

4.4 MATRIZES DE CONFUSÃO DOS CHECKPOINTS REPRESENTATIVOS

Para facilitar a comparação de erros, a Figura 9 apresenta um checkpoint por arquitetura, escolhido pela validação. A Tabela 9 transcreve suas contagens. Cada matriz contém 122 observações; as matrizes não são somas ou médias das três sementes.

No checkpoint integrado ao aplicativo, EfficientNet-B0 da semente 2026, foram observados 58 verdadeiros negativos, cinco falsos positivos, dois falsos negativos e 57 verdadeiros positivos. A partir dessas contagens, obtêm-se sensibilidade de $57/59 \approx 96{,}61\%$, especificidade de $58/63 \approx 92{,}06\%$ e F1 PSOR de $114/121 \approx 0{,}942$. Esses valores descrevem o checkpoint individual; não substituem as médias da arquitetura na Tabela 6.

A distribuição evidencia que, nesse checkpoint, dois dos 59 exemplos PSOR foram atribuídos a NonPsor e cinco dos 63 exemplos NonPsor foram atribuídos a PSOR. Esse detalhamento complementa o F1 ao identificar os dois tipos de erro no conjunto avaliado.

Tabela 9 – Contagens de teste dos checkpoints representativos escolhidos pela validação

Arquitetura	Semente	TN	FP	FN	TP
MobileNetV2	2026	56	7	3	56
MobileNetV3 Small	123	54	9	3	56
ShuffleNetV2 x1.0	2026	55	8	2	57
EfficientNet-B0	2026	58	5	2	57
ResNet18	2026	52	11	11	48
DenseNet121	42	57	6	3	56

Fonte: Relatório final e registros da execução experimental V5.

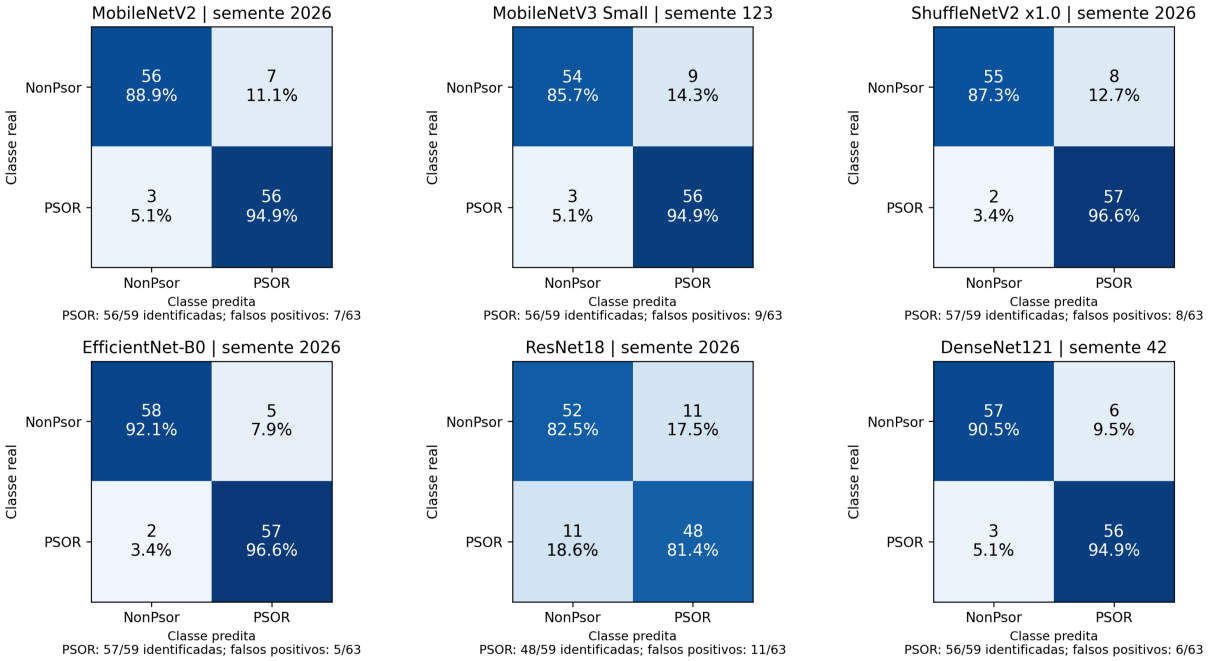


Figura 9 – Matrizes de teste de checkpoints escolhidos pela validação. Linhas: classe real; colunas: classe estimada. Os percentuais são calculados por linha, e a escala de cor é comum a todos os painéis. Para PSOR como classe positiva, a célula superior direita indica falsos positivos e a inferior esquerda, falsos negativos. Fonte: Autor.

Sua interpretação utiliza os denominadores de cada classe e o limiar de 0,5, mantendo a distinção entre a frequência dos erros e a investigação das características visuais que os produziram.

4.5 EXPLICABILIDADE EXPLORATÓRIA

Foram produzidas 12 tentativas de explicação para quatro imagens. O relatório registra **11 saídas com status OK** e **um Grad-CAM sem ativação positiva variável**, correspondente à imagem 01_NonPsor. Não foram registrados erros de execução nesses resultados. O status OK indica conclusão técnica da etapa e não atesta qualidade clínica da explicação.

Tabela 10 – Indicadores da explicabilidade: alvo PSOR nos quatro exemplos

Imagem	R^2 LIME	Segmentos	SHAP	Grad-CAM
`01_NonPsor`	0,580742	44	OK	Sem variação Amplitude: 0
`02_NonPsor`	0,687944	46	OK	OK Amplitude: 0,105724
`03_PSOR`	0,735491	43	OK	OK Amplitude: 0,836909
`04_PSOR`	0,687648	45	OK	OK Amplitude: 0,710662

Fonte: Relatório V5. LIME: mil perturbações; SHAP: Partition, referência preta e limite de 500 avaliações.

No LIME, cada imagem foi analisada a partir de mil versões modificadas, nas quais diferentes regiões foram ocultadas. O método procurou identificar quais dessas regiões influenciaram a resposta PSOR do classificador (RIBEIRO; SINGH; GUESTRIN, 2016). Foram obtidas entre 43 e 46 regiões por imagem, a partir de uma solicitação inicial de 50. Os valores de R^2 variaram de aproximadamente 0,581 a 0,735. Esse indicador descreve quanto a explicação construída pelo LIME conseguiu acompanhar as respostas do classificador nas versões modificadas da imagem; ele não representa a acurácia do diagnóstico.

No SHAP, partes da imagem foram substituídas por áreas pretas para examinar como essas mudanças alteravam a resposta do modelo. Foi utilizada a implementação Partition, com limite de 500 avaliações (SHAP, [s.d.]). A imagem de referência, inteiramente preta, recebeu pontuação PSOR de aproximadamente 0,00801. As cores dos mapas mostram quais regiões contribuíram para aumentar ou reduzir essa resposta em relação à referência adotada.

O Grad-CAM produziu mapas com regiões destacadas em três das quatro imagens analisadas. Esses realces indicam regiões associadas à resposta PSOR da rede (SELVARAJU et al., 2017). Na imagem `01_NonPsor`, o mapa não apresentou variação, e essa condição foi registrada no relatório. A amplitude indicada na Tabela 10 corresponde à diferença entre o maior e o menor valor do mapa antes do ajuste das cores. Como esse ajuste foi realizado separadamente em cada mapa, cores mais intensas não indicam, por si só, maior certeza na classificação.

A Figura 10 apresenta os dois exemplos PSOR. Ambos foram classificados como PSOR, com pontuações de aproximadamente 0,998 e 0,974. As colunas permitem comparar a fotografia original com as regiões destacadas por cada método, observando diferenças na localização e na extensão dos realces. Essa leitura tem finalidade exploratória e auxilia a investigação do comportamento do modelo nos exemplos selecionados.

Na revisão das quatro imagens, foi identificada uma marca de origem em `01_NonPsor`, já presente na fotografia original. Essa observação foi registrada na auditoria

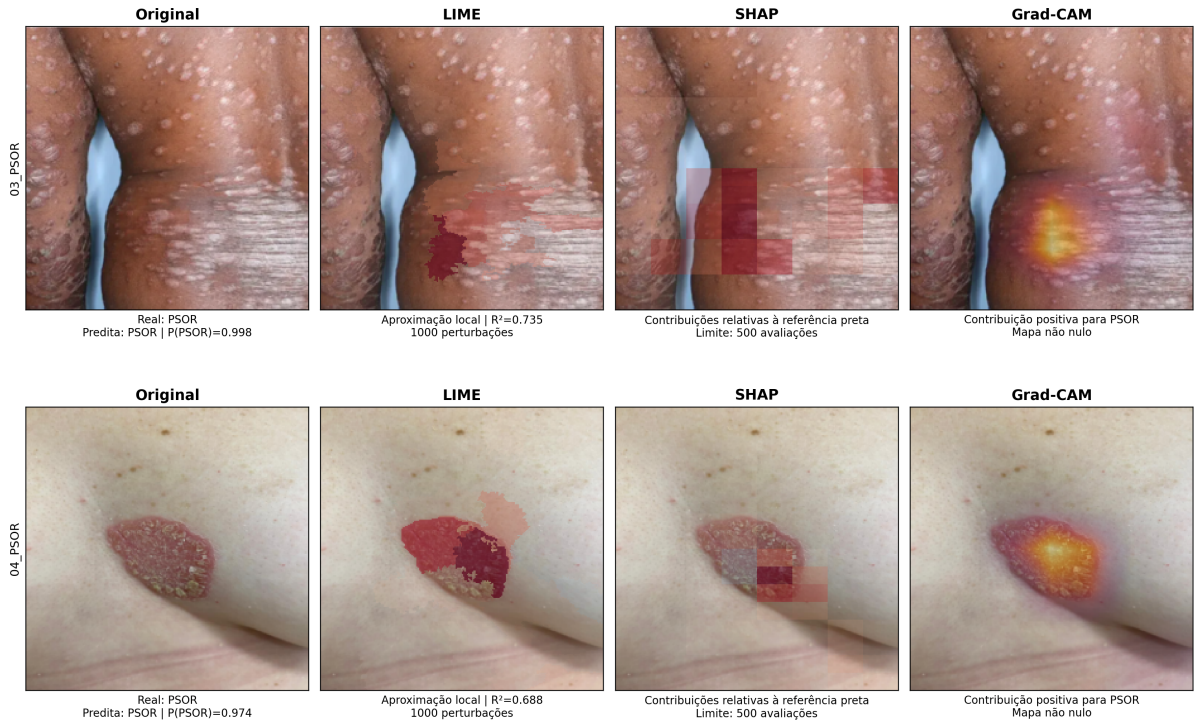


Figura 10 – Comparação das explicações produzidas por LIME, SHAP e Grad-CAM para os exemplos 03_PSOR e 04_PSOR, utilizando a EfficientNet-B0, semente 2026. Todas as explicações se referem à saída PSOR. A intensidade das cores foi ajustada separadamente em cada mapa. Fonte: saídas do experimento.

visual do acervo.

No computador utilizado, o Grad-CAM levou aproximadamente 0,03 a 0,04 segundo para gerar cada explicação. O LIME precisou de 15,74 a 16,02 segundos, enquanto o SHAP levou de 7,47 a 7,68 segundos. Assim, o Grad-CAM apresentou o menor tempo nos quatro exemplos analisados, seguido pelo SHAP e pelo LIME. Esses resultados se referem ao equipamento e às configurações utilizadas neste experimento. Os tempos individuais e os registros da memória RAM ocupada pelo processo estão disponíveis nos arquivos CSV (MUNIZ, 2026).

4.6 PROTÓTIPO ANDROID E INTEGRAÇÃO DO MODELO

A comparação experimental foi acompanhada pela construção do *Sistema de Suporte ao Diagnóstico de Psoríase*, um protótipo nativo Android capaz de executar o classificador no aparelho. Sua entrega reúne a interface de análise, a importação independente dos pesos e os recursos de registro previstos no desenvolvimento. Os resultados dessa integração são apresentados a partir do artefato exportado, das funcionalidades implementadas e das verificações documentadas, distinguindo-os das medições de desempenho realizadas no computador.

4.6.1 Modelo exportado e conferência numérica

O checkpoint EfficientNet-B0 da semente 2026 foi exportado em FP32 e aprovado nos critérios descritos na Seção 3.6.2. Nas 122 imagens verificadas, o erro absoluto máximo entre as saídas PyTorch e ONNX foi $1{,}7285347 \times 10^{-6}$, inferior à tolerância de 10^{-4}. Todas as decisões coincidiram no limiar de 0,5. Esse resultado documenta a preservação numérica observada no computador e vincula o modelo exportado ao checkpoint utilizado na avaliação.

O pacote ZIP foi importado no aplicativo em uma verificação funcional de desenvolvimento, utilizando a EfficientNet-B0 selecionada. A importação por arquivo permitiu ativar o modelo sem reconstruir a interface. O artefato passou a ser identificado no fluxo de uso, reunindo a classificação e os registros sob a mesma versão do modelo. A conferência numérica e o autoteste respondem a etapas de compatibilidade técnica; as medições de execução no aparelho dependem de sessões específicas com sua configuração registrada.

4.6.2 Interface e fluxo de utilização

A interface desenvolvida inclui as identidades visuais da UFPB e do PPGMDS, o nome do sistema, a identificação do modelo carregado e a fotografia selecionada. O resultado é apresentado como classe estimada, pontuação PSOR e mensagem associada. As classes aparecem como *Psoríase* e *Não é psoríase*; a mensagem positiva informa que a classificação não confirma diagnóstico, e a negativa esclarece que ela não descarta a condição. Essa apresentação aproxima a saída técnica da compreensão do usuário e conserva a identificação experimental da ferramenta.

O preparo da fotografia é orientado pela mensagem: “Sugestão: Use uma imagem já orientada, onde a região de interesse está bem enquadrada.” A orientação acompanha o fluxo de seleção porque o aplicativo processa a fotografia inteira e não realiza ajuste automático de enquadramento. A Figura 11 reúne três registros de tela fornecidos pelo autor, documentando a aparência do protótipo construído.



(a) Modelo e fotografia selecionada. (b) Classe estimada e orientação. (c) Medições e comandos de registro.

Figura 11 – Capturas de uma sessão do Sistema de Suporte ao Diagnóstico de Psoríase. Os valores visíveis documentam um registro pontual de uso e não constituem uma série de avaliação em aparelhos. Fonte: registros de tela fornecidos pelo autor.

4.6.3 Registros, disponibilização e alcance das verificações

Além da análise individual, o protótipo implementou o modo de desempenho, com aquecimento, repetições temporizadas e acompanhamento de memória PSS. A exportação em CSV foi integrada ao fluxo para permitir o armazenamento dos registros de cada sessão. As capturas exibem valores de um registro pontual, documentando o funcionamento da apresentação. A comparação quantitativa de latência e memória entre arquiteturas, por sua vez, permanece associada ao experimento em CPU no computador; não foi disponibilizada uma série controlada de CSVs de aparelhos que permitisse apresentar médias de desempenho móvel.

O repositório `guilhevimu/sistema-suporte-psoriase` reúne os artefatos compartilhados, incluindo código de pesquisa, dados, checkpoints, saídas gráficas, relatório, APK e documentação (MUNIZ, 2026). O APK encontra-se em `androidPsoraseApp`, e o acervo em `Pesquisa/Dataset`. A disponibilização no GitHub organiza a distribuição do projeto; após a importação do modelo, a inferência da fotografia ocorre no aparelho.

Na revisão consultada, estão publicados checkpoints PyTorch e um JSON de identificação do modelo selecionado. O ZIP para importação móvel é um artefato próprio

do exportador, contendo ONNX, metadados e autotestes, e não deve ser confundido com o checkpoint PyTorch. A versão 0.1.2 do APK também foi documentada no desenvolvimento quanto à estrutura, à assinatura e à compatibilidade de atualização em relação à 0.1.1. O manual do Apêndice A e o roteiro do Apêndice B acompanham a utilização e a continuidade das verificações.

4.7 SÍNTESE DOS RESULTADOS

As 18 execuções concluídas permitiram comparar seis arquiteturas sobre uma mesma partição, relacionando desempenho, latência, memória e tamanho dos modelos. A seleção por validação indicou a EfficientNet-B0 da semente 2026 para a continuidade do protótipo, enquanto as demais redes compactas apresentaram perfis de interesse para requisitos operacionais diferentes. A explicabilidade acrescentou uma inspeção de quatro imagens com parâmetros e estados de execução registrados.

A conversão aprovada nas 122 entradas e a importação funcional conectaram o checkpoint ao aplicativo Android. Assim, a entrega inclui o classificador avaliado, o pacote preparado para inferência e uma interface com instrumentação e manual. As curvas ROC, a evolução da validação e os painéis complementares de tempo e memória permanecem no Apêndice C, mantendo o corpo principal concentrado nos resultados necessários à interpretação da comparação e da integração.

5 DISCUSSÃO

5.1 CONTRIBUIÇÃO DA COMPARAÇÃO AO DESENVOLVIMENTO DA FERRAMENTA

A investigação de um classificador de imagens para uso móvel envolve decisões que se estendem da preparação dos exemplos à forma de executar e apresentar a resposta. Nesta dissertação, essas decisões foram articuladas em um processo documentado: o acervo definiu a tarefa, a comparação caracterizou seis implementações, a explicabilidade acrescentou uma inspeção de casos e a exportação permitiu incorporar o checkpoint a uma aplicação Android. A contribuição resulta dessa conexão entre avaliação experimental e desenvolvimento, com artefatos que podem apoiar a continuidade da pesquisa.

Esse percurso aproxima o trabalho de duas frentes da literatura. Estudos como os de Milani et al. (2023) e Chakraborty et al. (2024) investigaram a classificação por transferência de aprendizado, enquanto Tanantong et al. (2024) e Sutradhar et al. (2026) incluíram questões relacionadas à execução móvel. O presente estudo articula essas preocupações no mesmo caso de uso, mantendo identificadas a comparação realizada no computador e a integração executada no aparelho. Essa organização torna visível a passagem entre um modelo avaliado e um componente de software utilizável em novas sessões de investigação.

As métricas dos trabalhos relacionados ajudam a compreender as possibilidades do campo, mas precisam ser interpretadas a partir de suas tarefas. A distinção entre psoríase e pele saudável, a classificação de recortes lesionais e a avaliação de gravidade não utilizam o mesmo desfecho ou a mesma unidade de análise. No experimento apresentado, a classe NonPsor reúne condições não psoriáticas do acervo e a entrada corresponde à fotografia inteira redimensionada. Por isso, a contribuição da comparação está no exame das seis redes sob o protocolo comum, enquanto a aproximação com a literatura identifica escolhas e questões compartilhadas, sem estabelecer uma ordenação numérica entre pesquisas (MILANI et al., 2023; CHAKRABORTY et al., 2024; TANANTONG et al., 2025; MCMULLEN et al., 2025).

A disponibilização de código, checkpoints, gráficos, relatório e APK também acrescenta uma dimensão de continuidade. Esses arquivos permitem acompanhar o que foi produzido e relacionar os resultados às configurações descritas (MUNIZ, 2026). A identificação de versões, critérios de seleção e condições de execução favorece essa leitura, em consonância com a atenção à documentação de modelos de imagens médicas proposta no CLAIM 2024 (TEJANI et al., 2024).

5.2 DESEMPENHO CLASSIFICATÓRIO E REQUISITOS DE IMPLANTAÇÃO

A EfficientNet-B0 foi selecionada pelo maior F1 médio de validação e integrada ao protótipo a partir da semente 2026. No teste, a média entre sementes foi de $0{,}919 \pm 0{,}023$ para o F1 e de $0{,}974 \pm 0{,}010$ para a AUC. As métricas de teste foram calculadas para as 18 execuções, sem entrar na regra de escolha. Essa distinção entre cálculo dos resultados e uso na seleção esclarece o protocolo e preserva a interpretação da validação como conjunto decisório, considerando o viés que pode surgir quando a avaliação passa a orientar a escolha do modelo (CAWLEY; TALBOT, 2010).

O resultado é compatível com o interesse arquitetural da EfficientNet em combinar capacidade de representação e custo computacional, mas sua escolha neste acervo decorreu da avaliação empírica. O princípio de dimensionamento composto explica a família, enquanto a configuração B0 foi mantida fixa, com entrada de 224×224 e ajuste fino integral (TAN; LE, 2019). O estudo não realizou uma busca entre diferentes escalas EfficientNet nem comparou o pré-treinamento a uma inicialização aleatória equivalente. Assim, os resultados caracterizam a implementação adaptada sob as condições descritas, sem isolar o efeito de cada componente arquitetural ou o ganho atribuível ao uso de pesos ImageNet.

A proximidade entre o F1 médio da MobileNetV2, 0,918, e o da EfficientNet-B0, 0,919, torna especialmente relevante considerar os recursos. A MobileNetV2 apresentou menor latência mediana e menor checkpoint no ambiente avaliado, constituindo uma candidata para cenários em que esses requisitos recebam maior peso. A MobileNetV3 Small apresentou a menor latência, e a ShuffleNetV2 x1.0 reuniu o menor arquivo e a maior AUC média de teste. Esses perfis mostram que o modelo escolhido pelo critério preditivo não concentra necessariamente todas as vantagens operacionais, permitindo formular alternativas de implantação a partir dos resultados da Seção 4.3.

A AUC e o F1 também descrevem aspectos diferentes do classificador. A primeira resume a ordenação das classes ao variar o limiar, enquanto o F1 apresentado utiliza a decisão no limiar de 0,5 e combina precisão e sensibilidade da classe PSOR (FAWCETT, 2006; SOKOLOVA; LAPALME, 2009). A maior AUC média da ShuffleNetV2 no teste, portanto, não altera a seleção estabelecida pelo F1 médio de validação. Uma regra que incorpore limite de latência, memória ou tamanho de arquivo poderá ser investigada em uma nova etapa, desde que seja definida na validação e acompanhada de avaliação independente.

As diferenças entre médias e a dispersão nas três sementes fornecem uma descrição útil do comportamento observado, sem demonstrar superioridade estatística ou equivalência. A repetição contribuiu para examinar a variação de treinamento sobre a partição fixa; outras fontes de variabilidade, como a composição dos conjuntos, não foram alteradas nesse

desenho (BOUTHILLIER et al., 2021). De modo semelhante, o checkpoint individual integrado ao aplicativo apresenta suas próprias contagens de erros, que devem permanecer distinguidas das médias da arquitetura. Essa leitura mantém articulados o resultado agregado, a seleção do artefato e o modelo efetivamente distribuído.

Os recursos medidos reforçam a necessidade de observar a execução, além do número de parâmetros. A DenseNet121 apresentou a maior latência e o maior pico de RSS durante o treinamento, enquanto a ResNet18 apresentou o maior checkpoint. A relação entre operadores, movimentação de dados e implementação ajuda a compreender por que dimensões estruturais não determinam isoladamente a velocidade, conforme discutido na proposta da ShuffleNetV2 (MA et al., 2018). Neste estudo, a comparação caracteriza o protocolo completo, incluindo os efeitos da parada antecipada nos tempos de treinamento.

5.3 EXPLICABILIDADE E INSPEÇÃO DAS RESPOSTAS

A apresentação conjunta de LIME, SHAP e Grad-CAM aproxima a classificação da inspeção das regiões relacionadas à resposta. Nos quatro exemplos, a manutenção do alvo PSOR permitiu acompanhar a mesma saída, inclusive nas imagens NonPsor. Essa definição é relevante porque a explicação de uma imagem negativa se refere à hipótese PSOR e não muda automaticamente para a classe estimada. O painel e a tabela de indicadores tornam explícito o que foi explicado e como a etapa foi concluída.

Os destaques obtidos refletem procedimentos diferentes. O Grad-CAM utiliza mapas convolucionais e gradientes para localizar contribuições positivas ao logit; o LIME constrói uma aproximação local a partir de versões modificadas da imagem; e o SHAP Partition atribui contribuições em relação à referência de mascaramento e à hierarquia adotadas (SELVARAJU et al., 2017; RIBEIRO; SINGH; GUESTRIN, 2016; SHAP, [s.d.]). Por isso, diferenças de extensão ou localização entre as colunas são esperadas e precisam ser examinadas à luz dessas configurações. As cores ajustadas separadamente por mapa facilitam a visualização, mas não formam uma escala comum de certeza ou importância entre técnicas.

O acompanhamento dos indicadores acrescentou informação à inspeção visual. O R^2 local do LIME descreveu quanto a aproximação acompanhou as respostas nas perturbações avaliadas, e o registro de amplitude nula do Grad-CAM preservou a condição de um mapa sem variação espacial. Esses registros qualificam a documentação técnica dos exemplos. A correspondência entre os destaques e estruturas clinicamente relevantes, por sua vez, exigirá avaliação com anotações e critérios próprios, pois a aparência de um mapa e seu status de execução não bastam para validar sua interpretação (ARUN et al., 2021).

A marca de origem observada em uma das imagens também identifica uma utilidade da auditoria visual. Sua presença na fotografia original pode orientar a revisão do material e a formulação de comparações controladas sobre artefatos. A inspeção, isoladamente, não

demonstra que a marca tenha determinado a predição. O registro desse elemento preserva a rastreabilidade do experimento e oferece uma pergunta concreta para uma nova versão do acervo, com reavaliação dos resultados caso as entradas de treinamento ou teste sejam modificadas.

Nos exemplos examinados, o Grad-CAM demandou menos tempo de geração que SHAP e LIME. Essa observação descreve o equipamento e as configurações adotadas, incluindo as mil perturbações do LIME e o limite de 500 avaliações do SHAP. Os métodos não executam o mesmo procedimento, e o custo temporal não mede fidelidade clínica. A continuidade da investigação pode utilizar os mapas, os registros numéricos e os tempos já produzidos para formular critérios de avaliação que considerem conjuntamente utilidade da explicação e recursos necessários.

5.4 COMPOSIÇÃO DO ACERVO E ALCANCE DA AVALIAÇÃO

O conjunto final representa um recorte anatômico definido: tronco, braços, pernas, nádegas e algumas dobras cutâneas, incluindo axilas e dobras do tronco. Unhas, pés e regiões íntimas não integram a base utilizada. Essa delimitação é parte da tarefa e precisa acompanhar a interpretação do protótipo, pois manifestações da psoríase em locais diferentes apresentam características próprias (RENDON; SCHÄKEL, 2019). Os resultados apresentados referem-se às fotografias e regiões representadas no acervo, sem fornecer uma avaliação específica das áreas excluídas.

A composição por origem acrescenta outra informação relevante. O acervo privado concentra a maior contribuição PSOR, a DErmPICX contribui para essa classe e as fontes complementares reúnem a maior parcela NonPsor. Como a aparência das fotografias pode variar entre fontes, esse arranjo permite que características de aquisição acompanhem os rótulos. A tabela de procedência documenta a composição informada pelo autor; o vínculo individual entre imagem e origem permitirá examinar esse aspecto por fonte e por partição, com novas avaliações planejadas a partir dessa informação.

A auditoria de arquivos explicou a passagem dos 972 registros coletados aos 798 conteúdos distintos utilizados no experimento. Ela também estabeleceu um controle de duplicatas exatas antes do treinamento. A independência entre fotografias relacionadas depende, contudo, de vínculos adicionais que não são recuperados apenas pela identidade binária dos arquivos. Como não foi documentado um agrupamento completo por paciente ou fotografia original, a unidade dos resultados é a imagem. A explicitação dessa unidade e da separação entre conjuntos segue a preocupação com rastreabilidade e independência das observações destacada no CLAIM 2024 (TEJANI et al., 2024).

O mesmo cuidado se aplica à diversidade do acervo. As fotografias disponíveis permitem realizar a comparação proposta, mas não foram fornecidas contagens estratificadas por fototipo, idade, sexo ou região anatômica. Estudos em dermatologia mostram a

relevância de examinar o comportamento de modelos em grupos com representação distinta, embora seus resultados não possam ser transferidos automaticamente para o classificador desta dissertação (DANESHJOU et al., 2022). A consolidação desses metadados e a formação de conjuntos independentes ampliarão a caracterização do sistema sem substituir os resultados internos já documentados.

5.5 INTEGRAÇÃO ANDROID E CONTINUIDADE DA AVALIAÇÃO

A exportação ONNX e a importação funcional demonstraram a ligação técnica entre o checkpoint escolhido e o aplicativo. A coincidência das 122 decisões e o erro máximo inferior à tolerância verificaram a conversão nas entradas avaliadas no computador. O autoteste no aparelho complementa essa conferência com padrões definidos no pacote. Essa sequência transforma o resultado da seleção em um artefato executável, utilizando os recursos de implantação oferecidos pelo ONNX Runtime (PyTorch, [s.d.]c; ONNX Runtime, [s.d.]b).

A separação entre APK e modelo também favorece a evolução do projeto. A interface pode receber outro pacote compatível, enquanto metadados, hash e padrões de conferência acompanham os pesos. No contexto de pesquisa, essa organização permite registrar versões e examinar novas candidatas sem reconstruir todo o fluxo de interação. O mecanismo de importação e os arquivos de medição, assim, integram a contribuição de software e oferecem condições para comparações operacionais futuras.

Os valores medidos no computador ajudam a selecionar candidatas, mas não antecipam diretamente a latência ou a memória de um celular. Hardware, biblioteca de execução e intervalos cronometrados diferem entre os ambientes. Além disso, o PSS do Android e o RSS do processo Python possuem definições próprias, especialmente quanto à contabilização de memória compartilhada (Android Developers, [s.d.]d; psutil, [s.d.]). A instrumentação do protótipo permite investigar essas diferenças, desde que as sessões identifiquem aparelho, versão do sistema, pacote de modelo e condições da coleta.

A entrega alcança, portanto, a comparação interna das redes e a integração funcional de um modelo à ferramenta, com manual e registros previstos para sua utilização. A etapa seguinte poderá examinar desempenho móvel, clareza das mensagens e execução das tarefas pelo público definido. Uma investigação assistencial acrescentará perguntas próprias sobre aquisição de imagens, utilidade da resposta e desempenho no contexto clínico. Essas perspectivas partem dos componentes já implementados e ampliam o caso de uso a partir de evidências identificadas.

6 CONCLUSÃO

Este trabalho desenvolveu um sistema experimental de suporte à classificação de imagens de psoríase e documentou o percurso entre a preparação do acervo e sua integração a um aplicativo Android. O conjunto final reuniu 798 imagens de tronco, braços, pernas, nádegas e algumas dobras cutâneas, mantidas em uma partição fixa de treinamento, validação e teste. A conclusão das 18 combinações de seis arquiteturas e três sementes permitiu caracterizar o desempenho classificatório juntamente com o tempo, a memória e a dimensão dos modelos.

A seleção baseada exclusivamente na validação indicou a EfficientNet-B0, integrada ao protótipo pelo checkpoint da semente 2026. No teste, a arquitetura apresentou F1 médio de $0{,}919 \pm 0{,}023$ e AUC de $0{,}974 \pm 0{,}010$. As demais redes compactas ofereceram perfis de interesse para a implantação: a MobileNetV2 reuniu F1 descritivamente próximo e menor latência que a EfficientNet-B0; a MobileNetV3 Small apresentou a menor latência; e a ShuffleNetV2 x1.0, o menor checkpoint. Esses resultados sustentam a discussão de alternativas conforme requisitos operacionais explícitos.

A explicabilidade incorporou Grad-CAM, LIME e SHAP à inspeção de quatro imagens, acompanhando seus parâmetros, indicadores e estados de execução. A exportação do modelo selecionado preservou as decisões nas 122 imagens verificadas, com erro absoluto máximo de $1{,}7285347 \times 10^{-6}$. No Android, foram implementados importação por ZIP, autoteste, análise local, instrumentação de tempo e memória e exportação em CSV, acompanhados de manual e artefatos compartilhados.

A contribuição central consiste em um processo integrado e documentado que conecta a avaliação experimental à execução de um modelo no aparelho. Os resultados caracterizam a classificação por imagem no acervo delimitado e sua integração técnica ao protótipo. A consolidação dos vínculos de procedência, a avaliação independente, os ensaios quantitativos em celulares e os estudos de utilização ampliarão esse desenvolvimento a partir das entregas já realizadas.

6.1 PERSPECTIVAS DE CONTINUIDADE

A próxima etapa operacional consiste em executar sessões controladas em aparelhos identificados, utilizando versões documentadas do aplicativo e do modelo. O protocolo deverá registrar as condições de cada coleta e manter a correspondência codificada entre entradas e medições. A separação entre leitura, pré-processamento e inferência já instrumentada permitirá examinar os componentes de maior custo; medidas de energia, temperatura e bateria poderão complementar a investigação mediante recursos específicos.

Na organização do acervo, a prioridade é consolidar o inventário individual de origem, permissões de uso e vínculos entre fotografias relacionadas. As contagens agregadas por fonte já apresentadas poderão ser detalhadas por imagem, por conjunto e, quando disponíveis, por características clínicas e anatômicas. Esse registro apoiará novas partições agrupadas por paciente ou fotografia original e a formação de uma avaliação externa, preservando a identificação da execução atual como referência do desenvolvimento.

A análise de explicabilidade poderá abranger mais exemplos, incluindo erros de classificação, diferentes referências de mascaramento e regiões anotadas por especialistas. Essa extensão permitirá investigar a correspondência dos destaques com estruturas relevantes e sua utilidade para a inspeção, acrescentando critérios à aparência dos mapas e ao estado técnico de execução.

Na aplicação, poderão ser examinadas outras arquiteturas compactas já comparadas, quantização acompanhada de nova conferência e suporte explícito à orientação da fotografia. Estudos de usabilidade permitirão avaliar a compreensão das mensagens e a realização das tarefas pelo público previsto. A investigação de uso assistencial deverá ser planejada em um protocolo próprio, articulando desempenho, condições de aquisição e utilidade da ferramenta no contexto de atendimento.

REFERÊNCIAS BIBLIOGRÁFICAS

Android Developers. *Access app-specific files*. [S.l.], [s.d.]. Disponível em: <https://developer.android.com/training/data-storage/app-specific>. Acesso em: 29 out. 2026.

Android Developers. *Access documents and other files from shared storage*. [S.l.], [s.d.]. Disponível em: <https://developer.android.com/training/data-storage/shared/documents-files>. Acesso em: 29 out. 2026.

Android Developers. *Debug: getPss()*. [S.l.], [s.d.]. Disponível em: <https://developer.android.com/reference/android/os/Debug#getPss()>. Acesso em: 29 out. 2026.

Android Developers. *Overview of memory management*. [S.l.], [s.d.]. Disponível em: <https://developer.android.com/topic/performance/memory-overview>. Acesso em: 29 out. 2026.

Android Developers. *Process: getElapsedCpuTime()*. [S.l.], [s.d.]. Disponível em: <https://developer.android.com/reference/android/os/Process#getElapsedCpuTime()>. Acesso em: 29 out. 2026.

Android Developers. *Sign your app*. [S.l.], [s.d.]. Disponível em: <https://developer.android.com/studio/publish/app-signing>. Acesso em: 29 out. 2026.

ARUN, N. et al. Assessing the trustworthiness of saliency maps for localizing abnormalities in medical imaging. *Radiology: Artificial Intelligence*, v. 3, n. 6, p. e200267, 2021. Disponível em: <https://doi.org/10.1148/ryai.2021200267>.

BOEHNCKE, W.-H. Systemic inflammation and cardiovascular comorbidity in psoriasis patients: causes and consequences. *Frontiers in immunology*, Frontiers Media SA, v. 9, p. 579, 2018. Disponível em: <https://doi.org/10.3389/fimmu.2018.00579>.

BOUTHILLIER, X. et al. Accounting for variance in machine learning benchmarks. In: *Proceedings of Machine Learning and Systems*. [s.n.], 2021. v. 3. Disponível em: <https://proceedings.mlsys.org/paper_files/paper/2021/hash/0184b0cd3cfb185989f858a1d9f5c1eb-Abstract.html>.

Brasil. *Lei n. 13.709, de 14 de agosto de 2018: Lei Geral de Proteção de Dados Pessoais (LGPD)*. 2018. Presidência da República. Texto compilado. Disponível em: <https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 29 out. 2026.

BRASIL. *Protocolo clínico e diretrizes terapêuticas da psoríase*. 2021. Portaria Conjunta nº 18, de 14 de outubro de 2021. Disponível em: <https://www.gov.br/conitec/pt-br/midias/relatorios/2021/20211021_relatorio_652_pcdt_psoriase.pdf>. Acesso em: 29 out. 2026.

CAVOUKIAN, A.; JONAS, J. *Privacy by Design in the Age of Big Data*. Toronto, 2012. Disponível em: <https://www.ipc.on.ca/en/media/1774/download?attachment=>. Acesso em: 29 out. 2026.

CAWLEY, G. C.; TALBOT, N. L. C. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, v. 11, p. 2079–2107, 2010. Disponível em: <https://www.jmlr.org/papers/v11/cawley10a.html>.

CHAKRABORTY, C. et al. CAD-PsorNet: deep transfer learning for computer-assisted diagnosis of skin psoriasis. *Scientific Reports*, v. 14, n. 1, p. 26557, 2024. Disponível em: <https://doi.org/10.1038/s41598-024-76852-6>.

COHEN, J. A coefficient of agreement for nominal scales. *Educational and psychological measurement*, Sage Publications Sage CA: Thousand Oaks, CA, v. 20, n. 1, p. 37–46, 1960. Disponível em: <https://doi.org/10.1177/001316446002000104>.

DANESHJOU, R. et al. Disparities in dermatology ai performance on a diverse, curated clinical image set. *Science Advances*, v. 8, n. 32, p. eabq6147, 2022. Disponível em: <https://doi.org/10.1126/sciadv.abq6147>.

DAVILA, A.; COLAN, J.; HASEGAWA, Y. Comparison of fine-tuning strategies for transfer learning in medical image classification. *Image and Vision Computing*, Elsevier, v. 146, p. 105012, 2024. Disponível em: <https://doi.org/10.1016/j.imavis.2024.105012>.

DermIS. *DermIS: Dermatology Information System*. [s.d.]. Disponível em: <https://www.dermis.net/dermisroot/pt/home/index.htm>. Acesso em: 28 out. 2026.

DErmPICX. *About the Database Collection*. [s.d.]. Disponível em: <https://www.dermpicx.com/about-the-database/>. Acesso em: 28 out. 2026.

DESAI, S. R.; ALEXIS, A. F.; JACOBSON, A. Successful management of a black male with psoriasis and dyspigmentation treated with halobetasol propionate 0.01%/tazarotene 0.045% lotion: case report. *Journal of Drugs in Dermatology: JDD*, v. 19, n. 10, p. 1000–1004, 2020. Disponível em: <https://doi.org/10.36849/JDD.2020.5347>.

FAWCETT, T. An introduction to ROC analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006. Disponível em: <https://doi.org/10.1016/j.patrec.2005.10.010>.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org/>. Acesso em: 27 out. 2026.

GRIFFITHS, C. E.; BARKER, J. N. Pathogenesis and clinical features of psoriasis. *The Lancet*, Elsevier, v. 370, n. 9583, p. 263–271, 2007. Disponível em: <https://doi.org/10.1016/S0140-6736(07)61128-3>.

HAENSSLE, H. et al. Man against machine: diagnostic performance of a deep learning convolutional neural network for dermoscopic melanoma recognition in comparison to 58 dermatologists. *Annals of Oncology*, v. 29, n. 8, p. 1836–1842, 2018. Disponível em: <https://doi.org/10.1093/annonc/mdy166>.

HE, K. et al. Deep Residual Learning for Image Recognition. In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2016. p. 770–778. Disponível em: <https://arxiv.org/abs/1512.03385>. Acesso em: 27 out. 2026.

HOWARD, A. et al. Searching for MobileNetV3. In: *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, 2019. p. 1314–1324. Disponível em: <https://arxiv.org/abs/1905.02244>. Acesso em: 27 out. 2026.

HOWARD, A. G. et al. *MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications*. 2017. ArXiv:1704.04861. Disponível em: <https://arxiv.org/abs/1704.04861>.

HU, J.; SHEN, L.; SUN, G. Squeeze-and-Excitation Networks. In: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, 2018. p. 7132–7141. Disponível em: <https://arxiv.org/abs/1709.01507>. Acesso em: 27 out. 2026.

HUANG, G. et al. Densely Connected Convolutional Networks. In: *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2017. p. 2261–2269. Disponível em: <https://arxiv.org/abs/1608.06993>. Acesso em: 27 out. 2026.

IHTATHO, D. et al. Area assessment of psoriasis lesion for PASI scoring. In: *2007 29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. IEEE, 2007. p. 3446–3449. Disponível em: <https://doi.org/10.1109/IEMBS.2007.4353072>.

JEONG, H. K. et al. Deep learning in dermatology: A systematic review of current approaches, outcomes, and limitations. *JID Innovations*, v. 3, n. 1, p. 100150, 2023. Disponível em: <https://doi.org/10.1016/j.xjidi.2022.100150>.

KIM, H. E. et al. Transfer learning for medical image classification: a literature review. *BMC medical imaging*, Springer, v. 22, n. 1, p. 69, 2022. Disponível em: <https://doi.org/10.1186/s12880-022-00793-7>.

KINGMA, D. P.; BA, J. Adam: A method for stochastic optimization. In: *International Conference on Learning Representations (ICLR)*. [s.n.], 2015. Disponível em: <https://arxiv.org/abs/1412.6980>.

KRAGH, M. F.; KARSTOFT, H. Embryo selection with artificial intelligence: how to evaluate and compare methods? *Journal of Assisted Reproduction and Genetics*, v. 38, p. 1675–1689, 2021. Disponível em: <https://doi.org/10.1007/s10815-021-02254-6>.

LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *Nature*, v. 521, n. 7553, p. 436–444, 2015. Disponível em: <https://doi.org/10.1038/nature14539>. Acesso em: 28 out. 2026.

LOWES, M. A.; BOWCOCK, A. M.; KRUEGER, J. G. Pathogenesis and therapy of psoriasis. *Nature*, Nature Publishing Group UK London, v. 445, n. 7130, p. 866–873, 2007. Disponível em: <https://doi.org/10.1038/nature05663>.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems*. Curran Associates, 2017. v. 30. Disponível em: <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>.

MA, N. et al. ShuffleNet V2: Practical guidelines for efficient CNN architecture design. In: *Computer Vision – ECCV 2018*. Springer International Publishing, 2018. (Lecture Notes in Computer Science), p. 122–138. Disponível em: <https://doi.org/10.1007/978-3-030-01264-9_8>.

MCMULLEN, E. P. et al. Predicting psoriasis severity using machine learning: a systematic review. *Clinical and Experimental Dermatology*, v. 50, n. 3, p. 520–528, 2025. Disponível em: <https://doi.org/10.1093/ced/llae348>.

MILANI, A. et al. A deep learning application for psoriasis detection. In: *Anais do XX Encontro Nacional de Inteligência Artificial e Computacional (ENIAC 2023)*. Sociedade Brasileira de Computação, 2023. p. 315–329. Disponível em: <https://doi.org/10.5753/eniac.2023.234030>.

MUNIZ, G. V. *Sistema de Suporte ao Diagnóstico de Psoríase: repositório do projeto.* 2026. GitHub. Revisão consultada: commit f48fe3102f6bf7888f3bcdf6088010673897eca4. Disponível em: <https://github.com/guilhevimu/sistema-suporte-psoriase/tree/f48fe3102f6bf7888f3bcdf6088010673897eca4>. Acesso em: 27 out. 2026.

National Institute of Standards and Technology. *Secure Hash Standard (SHS)*. [S.l.], 2015. Disponível em: <https://csrc.nist.gov/pubs/fips/180-4/upd1/final>. Acesso em: 29 out. 2026.

ONNX Runtime. *Java: ONNX Runtime documentation*. [S.l.], [s.d.]. Disponível em: <https://onnxruntime.ai/docs/get-started/with-java.html>. Acesso em: 29 out. 2026.

ONNX Runtime. *Mobile image recognition on Android*. [S.l.], [s.d.]. Disponível em: <https://onnxruntime.ai/docs/tutorials/mobile/deploy-android.html>. Acesso em: 29 out. 2026.

ONNX Runtime. *Thread management*. [S.l.], [s.d.]. Disponível em: <https://onnxruntime.ai/docs/performance/tune-performance/threading.html>. Acesso em: 29 out. 2026.

OTA, K. et al. Deep learning for mobile multimedia: A survey. *ACM Trans. Multimedia Comput. Commun. Appl.*, Association for Computing Machinery, New York, NY, USA, v. 13, n. 3s, jun. 2017. ISSN 1551-6857. Disponível em: <https://doi.org/10.1145/3092831>.

PRECHELT, L. Early stopping—but when? In: MONTAVON, G.; ORR, G. B.; MÜLLER, K.-R. (Ed.). *Neural Networks: Tricks of the Trade*. 2. ed. Berlin, Heidelberg: Springer, 2012. p. 53–67. Disponível em: <https://doi.org/10.1007/978-3-642-35289-8_5>.

psutil. *psutil 7.2.2 documentation*. [S.l.], [s.d.]. Disponível em: <https://psutil.io/7.2/>. Acesso em: 29 out. 2026.

Python Software Foundation. *time: Time access and conversions: Python 3.14 documentation*. [S.l.], [s.d.]. Disponível em: <https://docs.python.org/3.14/library/time.html>. Acesso em: 28 out. 2026.

PyTorch. *Benchmark Utils: torch.utils.benchmark: PyTorch 2.10 documentation*. [S.l.], 2025. Disponível em: <https://docs.pytorch.org/docs/2.10/benchmark_utils.html>. Acesso em: 29 out. 2026.

PyTorch. *CUDA semantics: Memory management: PyTorch 2.10 documentation*. [S.l.], 2025. Disponível em: <https://docs.pytorch.org/docs/2.10/notes/cuda.html#memory-management>. Acesso em: 28 out. 2026.

PyTorch. *Reproducibility: PyTorch 2.10 documentation*. [S.l.], 2025. Disponível em: <https://docs.pytorch.org/docs/2.10/notes/randomness.html>. Acesso em: 28 out. 2026.

PyTorch. *Models and pre-trained weights: Torchvision 0.25 documentation*. [S.l.], 2026. Disponível em: <https://docs.pytorch.org/vision/0.25/models.html>. Acesso em: 29 out. 2026.

PyTorch. *BCEWithLogitsLoss: PyTorch 2.10 documentation*. [S.l.], [s.d.]. Disponível em: <https://docs.pytorch.org/docs/2.10/generated/torch.nn.BCEWithLogitsLoss.html>. Acesso em: 28 out. 2026.

PyTorch. *Saving and Loading Models*. [S.l.], [s.d.]. Disponível em: <https://docs.pytorch.org/tutorials/beginner/saving_loading_models.html>. Acesso em: 28 out. 2026.

PyTorch. *torch.onnx: PyTorch 2.10 documentation*. [S.l.], [s.d.]. Disponível em: <https://docs.pytorch.org/docs/2.10/onnx.html>. Acesso em: 29 out. 2026.

RENDON, A.; SCHÄKEL, K. Psoriasis pathogenesis and treatment. *International Journal of Molecular Sciences*, v. 20, n. 6, p. 1475, 2019. Disponível em: <https://doi.org/10.3390/ijms20061475>.

RIBEIRO, M. T.; SINGH, S.; GUESTRIN, C. "why should I trust you?": Explaining the predictions of any classifier. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016. p. 1135–1144. Disponível em: <https://doi.org/10.1145/2939672.2939778>.

RUSSAKOVSKY, O. et al. ImageNet large scale visual recognition challenge. *International Journal of Computer Vision*, v. 115, n. 3, p. 211–252, 2015. Disponível em: <https://doi.org/10.1007/s11263-015-0816-y>.

SANDLER, M. et al. MobileNetV2: Inverted Residuals and Linear Bottlenecks. In: *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. IEEE, 2018. p. 4510–4520. Disponível em: <https://arxiv.org/abs/1801.04381>. Acesso em: 27 out. 2026.

SCHAFFERT, D. et al. Using automated machine learning to predict necessary upcoming therapy changes in patients with psoriasis vulgaris and psoriatic arthritis and uncover new influences on disease progression: Retrospective study. *JMIR Formative Research*, v. 8, p. e55855, 2024. Disponível em: <https://formative.jmir.org/2024/1/e55855/>.

SELVARAJU, R. R. et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization. In: *2017 IEEE International Conference on Computer Vision (ICCV)*. IEEE, 2017. p. 618–626. Disponível em: <https://doi.org/10.1109/ICCV.2017.74>.

SHAP. *shap.PartitionExplainer: SHAP documentation*. [S.l.], [s.d.]. Disponível em: <https://shap.readthedocs.io/en/latest/generated/shap.PartitionExplainer.html>. Acesso em: 29 out. 2026.

SHORTEN, C.; KHOSHGOFTAAR, T. M. A survey on image data augmentation for deep learning. *Journal of big data*, Springer, v. 6, n. 1, p. 1–48, 2019. Disponível em: <https://doi.org/10.1186/s40537-019-0197-0>.

SILVA, K. d. S.; SILVA, E. A. T. d. Psoríase e sua relação com aspectos psicológicos, stress e eventos da vida. *Estudos de Psicologia (Campinas)*, v. 24, n. 2, p. 257–266, 2007. Disponível em: <https://doi.org/10.1590/S0103-166X2007000200012>.

SOKOLOVA, M.; LAPALME, G. A systematic analysis of performance measures for classification tasks. *Information Processing and Management*, v. 45, n. 4, p. 427–437, 2009. Disponível em: <https://doi.org/10.1016/j.ipm.2009.03.002>.

SUTRADHAR, U. et al. A real-time mobile AI-assisted system for skin disease prescreening: A technical feasibility study. *Health Science Reports*, v. 9, n. 6, p. e72616, 2026. Disponível em: <https://doi.org/10.1002/hsr2.72616>.

TAKESHITA, J. et al. Psoriasis and comorbid diseases: epidemiology. *Journal of the American Academy of Dermatology*, Elsevier, v. 76, n. 3, p. 377–390, 2017. Disponível em: <https://doi.org/10.1016/j.jaad.2016.07.064>.

TAN, M.; LE, Q. EfficientNet: Rethinking model scaling for convolutional neural networks. In: *Proceedings of the 36th International Conference on Machine Learning*. PMLR, 2019. (Proceedings of Machine Learning Research, v. 97), p. 6105–6114. Disponível em: <https://proceedings.mlr.press/v97/tan19a.html>. Acesso em: 27 out. 2026.

TANANTONG, T. et al. A study on area assessment of psoriasis lesions using image augmentation and deep learning: Addressing the lack of thai skin disease data. *Journal of Current Science and Technology*, v. 15, n. 3, p. 119, 2025. Disponível em: <https://doi.org/10.59796/jcst.v15n3.2025.119>.

TANANTONG, T. et al. Mobile-based deep learning framework for classifying common skin diseases in thailand. *ICIC Express Letters, Part B: Applications*, v. 15, n. 5, p. 495–503, 2024. Disponível em: <http://www.icicelb.org/ellb/contents/2024/5/elb-15-05-08.pdf>.

TEJANI, A. S. et al. Checklist for artificial intelligence in medical imaging (CLAIM): 2024 update. *Radiology: Artificial Intelligence*, v. 6, n. 4, p. e240300, 2024. Disponível em: <https://doi.org/10.1148/ryai.240300>.

WANG, J. et al. Enhancing diagnosis of psoriasis and inflammatory skin diseases: A spatially aligned multimodal model integrating clinical and dermoscopic images. *Journal of Investigative Dermatology*, v. 145, n. 11, p. 2736–2744.e6, 2025. Disponível em: <https://doi.org/10.1016/j.jid.2025.03.034>. Acesso em: 28 out. 2026.

YU, K. et al. Machine learning applications in the evaluation and management of psoriasis: A systematic review. *Journal of Psoriasis and Psoriatic Arthritis*, v. 5, n. 4, p. 147–159, 2020.

ZAFAR, A. et al. A comparison of pooling methods for convolutional neural networks. *Applied Sciences*, MDPI, v. 12, n. 17, p. 8643, 2022. Disponível em: <https://doi.org/10.3390/app12178643>.

Apêndices

APÊNDICE A – MANUAL DE UTILIZAÇÃO DO APLICATIVO

A.1 FINALIDADE E VISÃO GERAL

Este manual descreve a versão **0.1.2-pesquisa** do *Sistema de Suporte ao Diagnóstico de Psoríase*, protótipo acadêmico desenvolvido no contexto do PPGMDS/UFPB. Ele orienta a instalação, a importação do modelo treinado, a análise de uma fotografia, a medição de desempenho e a exportação dos registros.

O fluxo básico é: **instalar o aplicativo; importar o ZIP do modelo; aguardar o autoteste; selecionar uma fotografia; ler a classificação; exportar as medições**. O treinamento e a comparação de modelos são realizados no computador. O celular executa o modelo já treinado e não refaz o aprendizado a cada fotografia.

A ferramenta tem finalidade experimental de pesquisa. As classes exibidas descrevem a estimativa do modelo; a imagem isolada e a pontuação produzida não confirmam nem excluem um diagnóstico clínico. A versão atual não recomenda tratamento.

A.2 ARQUIVOS E REQUISITOS

A.2.1 Diferenciar os três pacotes

APK do aplicativo

Arquivo de instalação Android, por exemplo `<Psoriase_Pesquisa_v0_1_2_corrigido.apk>`. Instala a interface e o mecanismo de inferência. Não contém os pesos treinados do experimento.

ZIP do modelo

Arquivo `<modelo_android.zip>`, produzido pelo exportador. Deve ser selecionado **dentro do aplicativo**, no botão de importação. Mantenha-o compactado, sem renomear seus arquivos internos.

ZIP do projeto

Pacote com código-fonte e documentação para desenvolvimento no computador. Não deve ser importado como modelo. Se contiver uma pasta APK, extraia o APK antes de instalar.

A.2.2 Requisitos do aparelho

O APK fornecido requer Android 8.0 ou superior e processador ARM de 32 ou 64 bits. É necessário espaço para o aplicativo, para o pacote do modelo e para sua extração temporária. O tamanho dos arquivos não determina, isoladamente, a memória necessária para executar a rede. A implementação utiliza CPU e quatro threads; não é necessário configurar GPU ou outro acelerador.

As fotografias devem estar em formato reconhecido pelo decodificador do Android e ter, no máximo, **16.000.000 pixels**. A limitação corresponde ao produto largura por altura, e não ao tamanho do arquivo em megabytes. O pacote de modelo é limitado a **120 MiB descompactados**. Depois de instalados o app e o modelo e disponibilizada a imagem no aparelho, a inferência ocorre sem servidor e sem transmissão da fotografia pelo aplicativo.

A.3 INSTALAÇÃO E ATUALIZAÇÃO

A.3.1 Primeira instalação

1. Copie o APK completo para o celular. Se ele estiver dentro de um ZIP de instalação, extraia-o primeiro.

2. Abra o APK pelo gerenciador de arquivos. Quando o Android solicitar autorização de instalação para essa origem, siga o fluxo apresentado pelo sistema.

3. Conclua a instalação e abra o aplicativo, identificado no launcher como *Psoríase • Pesquisa*.

4. Confira o título *Sistema de Suporte ao Diagnóstico de Psoríase* e os elementos institucionais.

5. Na primeira abertura, a mensagem informa que falta importar o modelo. Essa é uma condição esperada, pois os pesos são fornecidos separadamente.

   O APK corrigido 0.1.2 tem **45.668.605 bytes**. Seu SHA-256 de referência é:

   <c3b0fba2ec2ba5359d9f4f44a9d38ce455e7c4f180819a72b3cccac4383507b3>

Esse tamanho e esse hash identificam especificamente o arquivo fornecido nesta revisão; uma compilação diferente terá outra identificação. A versão avulsa inicialmente enviada estava truncada e foi substituída pela cópia íntegra. Caso tenha guardado o download anterior com erro, utilize a cópia corrigida.

A.3.2 Atualizar uma instalação existente

As versões 0.1.1 e 0.1.2 utilizam o mesmo certificado de assinatura. A atualização da 0.1.1 deve ser instalada por cima da anterior, preservando o armazenamento privado do modelo. Antes de fechar o aplicativo, **exporte as medições pendentes**, pois esses registros pertencem à sessão em memória.

A versão 0.1.0 utiliza outro certificado. Nessa transição, mantenha `<modelo_android.zip>` fora do armazenamento privado do app e exporte os CSVs antes de desinstalar a versão antiga. Após instalar a nova versão, importe novamente o mesmo ZIP. A desinstalação remove os dados privados do aplicativo; não é necessário treinar o modelo novamente.

Não desinstale como primeira tentativa diante de qualquer falha. Confira antes o arquivo, a versão instalada e a mensagem apresentada, para evitar perda desnecessária de dados.

A.4 PREPARAÇÃO E EXPORTAÇÃO NO COMPUTADOR

A.4.1 Quando esta etapa é necessária

Se `<modelo_android.zip>` já foi exportado, aprovado e importado anteriormente, utilize esse mesmo arquivo. A troca de textos ou logos do aplicativo não exige novo treinamento nem nova exportação. Esta etapa é necessária para preparar outro checkpoint compatível ou refazer um pacote que esteja ausente ou danificado.

A.4.2 Identificar a execução correta

A pasta deve conter `<configuracao.json>`, `<modelo_selecionado.json>`, o checkpoint indicado e `<csv/manifesto_imagens.csv>`. Na execução utilizada, a pasta é `<Resultados_Rinha_V5/20261022_151228_934149>`, o modelo é EfficientNet-B0 e a semente é 2026. O checkpoint correspondente é `<checkpoints/efficientnet_b0_s2026.pt>`.

Abra o prompt na pasta `PsoraseApp` do projeto e utilize o mesmo Python que executou a V5. Instale as dependências específicas de exportação:

```
python -m pip install -r ferramentas\requirements_exportacao.txt
```

Em seguida, execute

```
EXPORTAR_MODELO.bat
```

e informe a pasta completa da execução que contém `<configuracao.json>`. Também é possível utilizar

```
python ferramentas\exportar_modelo.py --execucao "PASTA_V5"
```

substituindo `PASTA_V5` pelo caminho completo. A pasta original `Teste` deve continuar acessível, com as mesmas imagens do manifesto. Se apenas sua localização mudou, utilize a opção `-teste` com o novo caminho; ela não autoriza substituir o conjunto por outras imagens.

A.4.3 Conferir a aprovação

O exportador compara PyTorch e ONNX nas imagens do teste e exige decisões iguais e erro máximo não superior a 10^{-4}. A execução de referência aprovou 122 imagens, com erro máximo de $1{,}7285347 \times 10^{-6}$. Ao final, são produzidos `<modelo_android.zip>` e `<modelo_android.equivalencia.csv>`.

Transfira o ZIP para o celular. O CSV de equivalência é um registro de conferência no computador e não precisa ser importado no app. Não descompacte e recomprima o ZIP do modelo acrescentando uma pasta externa: os arquivos esperados devem permanecer em sua estrutura original. Se a saída já existir, o exportador a preserva; utilize `-saida` com outro nome para uma nova exportação.

A.5 IMPORTAÇÃO E AUTOTESTE NO CELULAR

1. Abra o aplicativo e toque em **1. Importar pacote do modelo (.zip)**.
2. No seletor de arquivos, localize `<modelo_android.zip>`. Selecione o arquivo, e não uma pasta ou o ZIP do projeto.
3. Aguarde a mensagem de processamento. Durante uma tarefa, os botões ficam temporariamente desabilitados.
4. O aplicativo confere a estrutura, os metadados, o SHA-256 do modelo e três padrões sintéticos de entrada e saída.
5. Confirme a mensagem **Autoteste OK**, a arquitetura carregada e o tempo de carregamento do modelo.

O autoteste verifica a compatibilidade técnica do pacote com o pré-processamento e o mecanismo de inferência. Ele não mede sensibilidade clínica e não é um teste de uma fotografia do paciente. O botão **Conferir autoteste do modelo** permite repetir essa conferência; ele reabre a sessão e atualiza a medição de carregamento utilizada nos registros seguintes.

O modelo aprovado fica no armazenamento privado do aplicativo e é restaurado nas próximas aberturas. Um novo modelo só é ativado após aprovação das verificações; pacotes anteriores são removidos após a ativação do novo. Mantenha uma cópia do ZIP original fora do app para reinstalações.

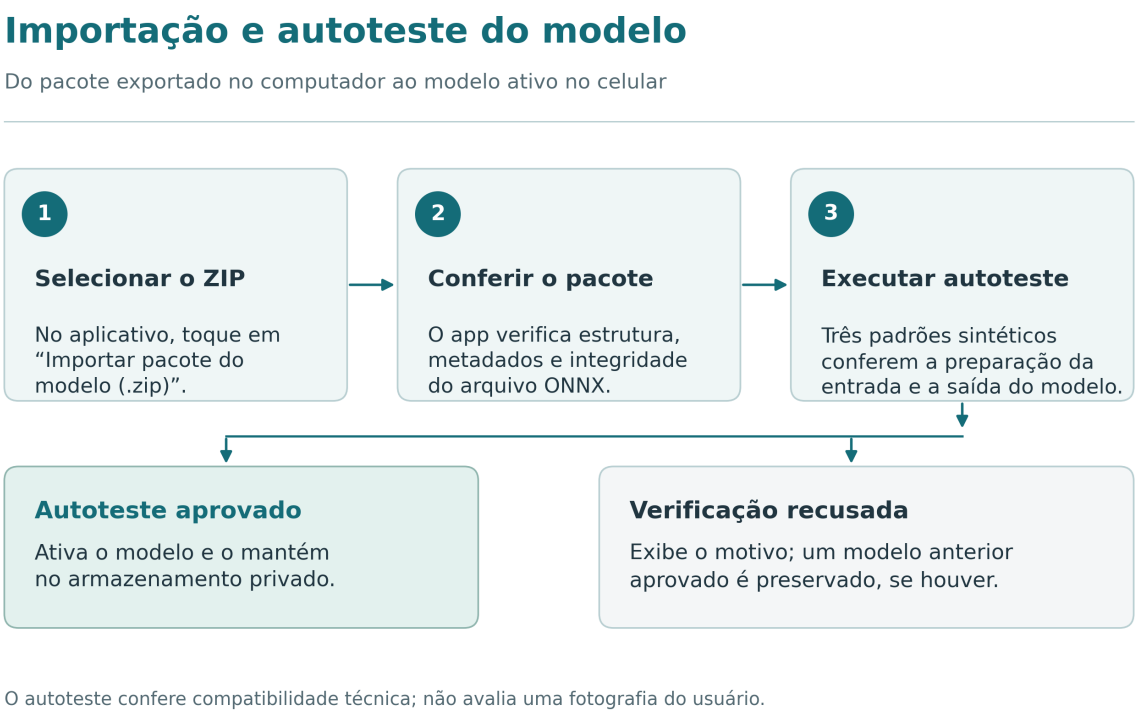


Figura 12 – Fluxo de importação e autoteste do modelo no celular. A ativação depende da aprovação das verificações técnicas; se houver recusa, o modelo anterior aprovado é preservado. Fonte: elaboração do autor.

A.6 SELEÇÃO E PREPARAÇÃO DA FOTOGRAFIA

Toque em **2. Selecionar fotografia** e escolha uma imagem disponível no aparelho. Ao retornar do seletor, o aplicativo inicia automaticamente uma análise e define o rótulo de referência como *Não informado*. Aguarde a conclusão antes de iniciar outra tarefa.

A recomendação da interface é: *Sugestão: Use uma imagem já orientada, onde a região de interesse está bem enquadrada.* Prepare a orientação antes de selecionar. O app utiliza os pixels como são decodificados e não aplica rotação automática baseada em EXIF. A imagem inteira é redimensionada para 224×224; ela não é recortada, segmentada ou centralizada automaticamente na lesão. Uma imagem retangular pode ter suas proporções modificadas por esse redimensionamento.

Para documentar o uso, confira se a região a analisar está visível e com resolução suficiente. Fotografias desfocadas, iluminação extrema, textos, molduras e marcas de origem podem alterar a entrada; o protótipo não detecta nem corrige automaticamente esses problemas. A escolha de exemplos para pesquisa deve seguir o protocolo do estudo, evitando selecionar somente resultados visualmente favoráveis.

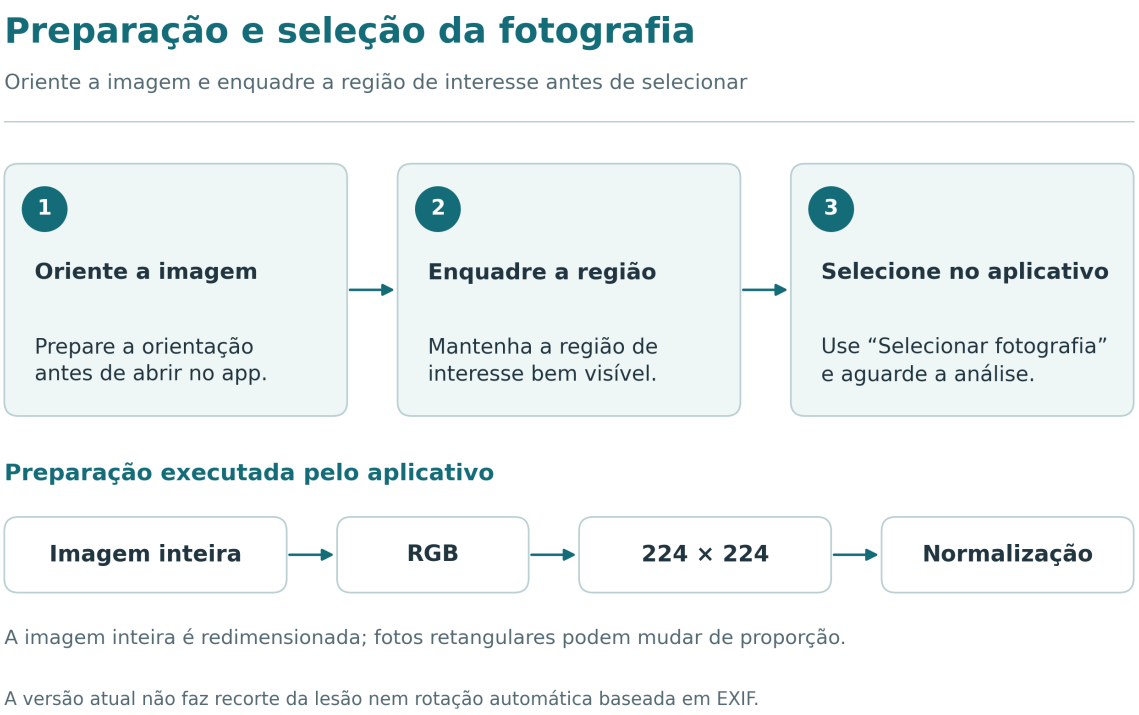


Figura 13 – Preparação da fotografia pelo usuário e etapas executadas pelo aplicativo. A orientação e o enquadramento antecedem a seleção; a imagem inteira é redimensionada e normalizada. Fonte: elaboração do autor.

A.7 LEITURA DA CLASSIFICAÇÃO

O resultado apresenta a classe estimada, a pontuação associada à psoríase e medidas da execução. As classes legíveis correspondem aos códigos internos:

Código	Classe na interface	Regra no limiar de referência
`PSOR`	Psoríase	$p_{\mathrm{PSOR}} \geq 0{,}5$
`NonPsor`	Não é psoríase	$p_{\mathrm{PSOR}} < 0{,}5$

O limiar é lido dos metadados do modelo; o pacote da V5 utiliza 0,5. A pontuação exibida é $100 p_{\mathrm{PSOR}}$, inclusive quando a classe estimada é negativa. Portanto, 8% significa pontuação PSOR de 0,08, e não “8% de acerto” da ferramenta. Não há calibração para interpretar esse valor como probabilidade clínica individual.

Para **Psoríase**, a mensagem associada é:

> Esta imagem foi associada pelo modelo à classe de psoríase. O resultado é experimental e não confirma um diagnóstico.

Para **Não é psoríase**, a mensagem é:

> Esta imagem foi associada pelo modelo à classe sem psoríase. O resultado é experimental e não descarta a condição.

A classe negativa reúne condições não psoriáticas do experimento e não significa necessariamente pele saudável. O aplicativo não identifica qual outra dermatose estaria presente. Grad-CAM, LIME e SHAP são produzidos no computador e não aparecem como funções nesta versão do APK.

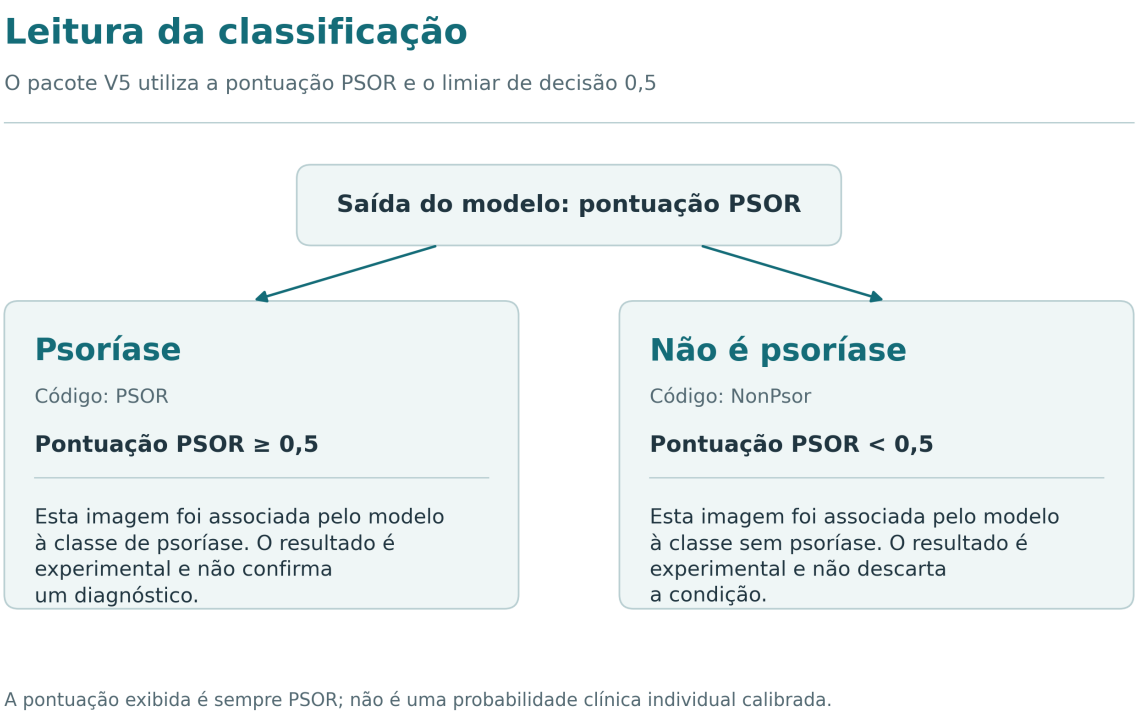


Figura 14 – Regras de classificação e mensagens associadas às classes Psoríase e Não é psoríase. O esquema utiliza o limiar 0,5 do pacote V5 e não representa uma predição de imagem específica. Fonte: elaboração do autor.

A.8 RÓTULO DE REFERÊNCIA E REPETIÇÃO DA ANÁLISE

O campo **Rótulo de referência (opcional, para o CSV)** possui as opções *Não informado*, *Não é psoríase* e *Psoríase*. Use um rótulo apenas quando ele for conhecido por uma fonte independente da predição. Se não houver referência, mantenha *Não informado*; não copie a classe estimada para preencher uma verdade de referência.

Mudar esse campo não altera a predição e **não reescreve um registro já concluído**. Para gerar um registro com a referência escolhida, selecione o rótulo e toque em **Analisar novamente** ou em **Medir desempenho • 30 inferências**. Cada ação concluída acrescenta uma nova linha à sessão. Ao selecionar outra fotografia, a referência é novamente reiniciada como *Não informado*.

Se houver múltiplos registros da mesma fotografia, eles não devem ser tratados como novos indivíduos ou novas imagens independentes em uma avaliação classificatória. O CSV não contém identificador de fotografia; para um estudo com várias imagens, mantenha

externamente uma correspondência codificada entre protocolo, imagem e registros, sem acrescentar identificação pessoal.

A.9 MEDIÇÃO DE DESEMPENHO

A.9.1 Uma execução e benchmark

Analisar novamente relê a fotografia, refaz o pré-processamento e executa uma inferência. **Medir desempenho • 30 inferências** também prepara a imagem uma vez, realiza cinco aquecimentos e mede trinta inferências sobre a mesma entrada. Os aquecimentos não entram nas trinta latências nem em sua média, mediana ou p95; entram no tempo total da etapa e no uso de recursos observado durante ela.

A média resume as trinta latências, a mediana descreve seu centro e o p95 é o percentil 95 calculado por interpolação. A pontuação registrada é a saída da última inferência, não uma média de probabilidades de imagens diferentes. No modo de análise única, média, mediana e p95 são a mesma observação e não descrevem variabilidade.

A.9.2 O que está sendo temporizado

Carregamento
: Criação da sessão ONNX da última abertura ou conferência; exclui cópia do ZIP e o autoteste completo.

Leitura
: Abertura e decodificação da fotografia, incluindo a leitura prévia de suas dimensões.

Pré-processamento
: Extração dos pixels, redimensionamento, normalização e criação da imagem de prévia.

Forward
: Criação do tensor ONNX, execução da sessão e leitura da saída. A fotografia já foi decodificada e normalizada.

Tempo total da etapa
: Inclui preparação e execuções, inclusive aquecimentos no benchmark, com custos de controle do processamento. Não equivale à soma apenas das trinta latências.

CPU do processo
: Tempo acumulado de CPU durante a etapa. Pode diferir do tempo decorrido em relógio por causa do trabalho em múltiplas threads.

A.9.3 Memória e condições de comparação

A memória apresentada é o **PSS do processo Android**, com amostras aproximadamente a cada 50 ms. O pico é o maior valor observado nas amostras, e não uma garantia de capturar todo pico instantâneo. O PSS inclui o processo e sua parcela proporcional de memória compartilhada; não corresponde ao arquivo de pesos nem ao RSS medido no Python.

Para comparar sessões, mantenha aparelho, modelo, versão do app, imagem e modo de execução identificados. Registre também as condições de uso que possam influenciar o resultado. O protótipo não mede temperatura, consumo energético, nível de bateria ou atividade de outros aplicativos; essas condições dependem de documentação externa ou instrumentação posterior. O benchmark de trinta inferências descreve uma única imagem repetida e não substitui um estudo com várias imagens e aparelhos.

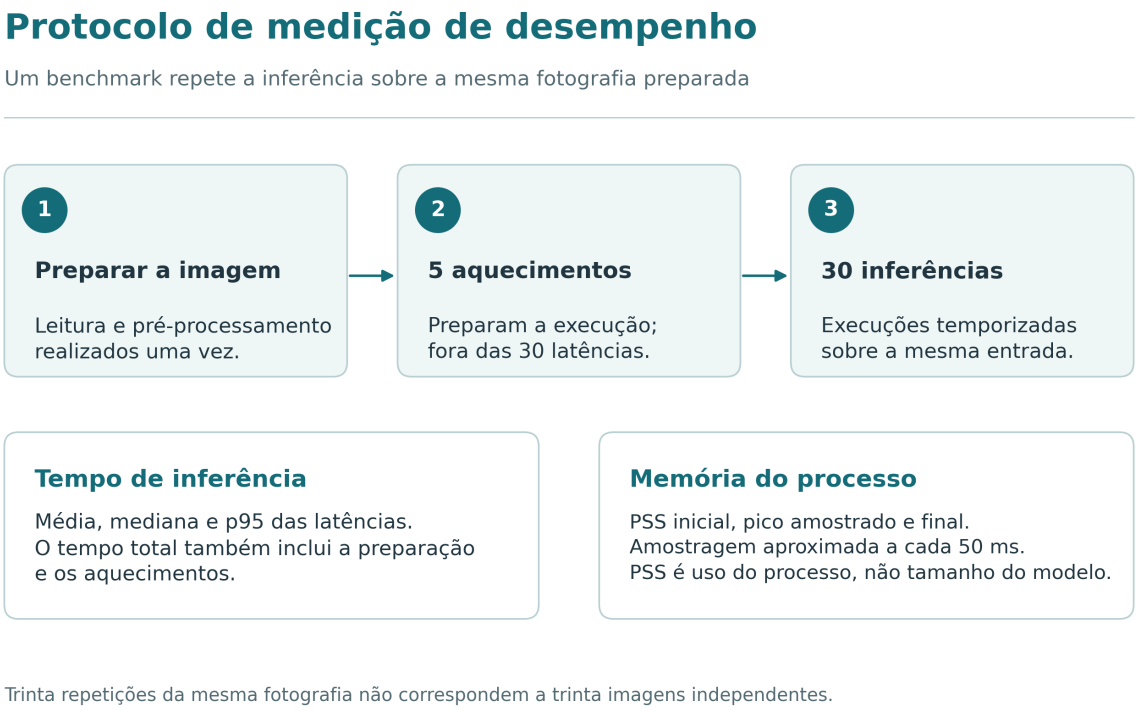


Figura 15 – Protocolo de medição do aplicativo: preparação da entrada, cinco aquecimentos e trinta inferências temporizadas sobre a mesma fotografia. O esquema diferencia estatísticas de latência e memória PSS; não apresenta medições experimentais. Fonte: elaboração do autor.

A.10 EXPORTAÇÃO E LEITURA DO CSV

1. Após ao menos uma análise concluída, toque em **Exportar medições em CSV**.

2. Escolha no seletor do Android o local e o nome do arquivo. O nome sugerido é `<medicoes_psorase.csv>`.

3. Aguarde a mensagem de exportação com a quantidade de registros.

4. Abra o arquivo salvo e confirme a presença dos cabeçalhos e das linhas esperadas antes de encerrar a coleta.

O arquivo CSV reúne uma cópia dos registros disponíveis no momento da solicitação de exportação. A exportação não apaga a sessão; uma segunda exportação pode conter novamente as mesmas linhas. Ao combinar arquivos, utilize `id` para reconhecer registros repetidos. Encerrar ou recriar a atividade, inclusive por ação do Android, pode descartar os registros em memória. Exporte durante a coleta, antes de atualizar, reinstalar ou fechar o aplicativo.

O formato é UTF-8 com BOM e separador ponto e vírgula. Os números decimais são gravados com ponto. No Excel, utilize a importação de texto/CSV, confira UTF-8 e o delimitador e, quando necessário, configure a localidade de conversão dos campos numéricos. Não substitua indiscriminadamente pontos e vírgulas no arquivo. Fotografias, nomes de imagens e caminhos não são incluídos.



Figura 16 – Fluxo de exportação e exemplos de campos previstos no CSV. São apresentados cabeçalhos e orientações de leitura, sem linhas de medições. Fonte: elaboração do autor.

A.10.1 Dicionário dos campos

Os nomes abaixo correspondem à implementação 0.1.2. Campos de latências adicionais aparecem quando há benchmark.

Campo ou grupo	Conteúdo e interpretação
`<id>`	Identificador único do registro, útil para reconhecer repetições entre exportações. Não identifica a imagem.
`<data_hora>`	Data e hora do registro com deslocamento de fuso, obtidas no aparelho.
`<modo>`	`analise` ou `benchmark`.
`<modelo>`, `<semente>`	Arquitetura e semente lidas do pacote importado.
`<versao_app>`, `<onnxruntime>`	Versões do aplicativo e do mecanismo de execução.
`<modelo_sha256>`	Hash do arquivo ONNX usado no registro.
`<modelo_mib>`, `<apk_mib>`	Tamanhos dos arquivos do modelo e do APK em MiB. Não são uso de RAM.
`<aparelho>`, `<android>`, `<api_android>`, `<threads>`	Fabricante/modelo, versão e API Android e número de threads configurado.
`<rotulo_referencia>`, `<rotulo_referencia_texto>`	Código e descrição da referência opcional; o código fica vazio quando não informado.
`<classe_estimada>`, `<classe_estimada_texto>`	Código técnico e descrição legível da predição.
`<mensagem_resultado>`	Texto associado à classificação experimental.
`<p_psor>`, `<limiar>`	Pontuação PSOR entre zero e um e limiar usado para a decisão.
`<carregamento_modelo_ms>`	Tempo da última criação da sessão ONNX, em ms.
`<leitura_imagem_ms>`, `<preprocessamento_ms>`	Tempos de decodificação e preparação da fotografia, em ms.
`<forward_media_ms>`, `<forward_mediana_ms>`, `<forward_p95_ms>`	Resumos das inferências temporizadas.
`<medicoes_forward>`, `<aquecimentos>`	Quantidade de latências registradas e de aquecimentos.
`<forward_1_ms>` a `<forward_30_ms>`	Latências individuais. Na análise única, somente a primeira é preenchida.
`<tempo_total_etapa_ms>`	Tempo decorrido da etapa de análise ou benchmark.
`<cpu_processo_ms>`	Tempo acumulado de CPU do processo durante a etapa.

Campo ou grupo	Conteúdo e interpretação
`<pss_inicial_mib>`, `<pss_pico_amostrado_mib>`, `<pss_final_mib>`	PSS inicial, maior amostra observada e amostra final do monitor.
`<pss_amostras>`, `<monitor_duracao_ms>`	Quantidade de amostras e duração do monitoramento.

A.11 SOLUÇÃO DE PROBLEMAS

Situação	Conferência e ação
Arquivo corrompido ou erro ao instalar	Utilize o APK completo e corrigido; extraia-o se estiver em ZIP. Confira tamanho/hash e compatibilidade Android/ARM. Diferencie truncamento do arquivo de conflito com versão já instalada.
Conflito com instalação anterior	Confira se a versão anterior é 0.1.0, cuja assinatura difere. Preserve CSVs e ZIP do modelo antes de eventual desinstalação.
Importe o modelo primeiro	O aplicativo está instalado, mas ainda não há modelo ativo. Importe `<modelo_android.zip>`.
Arquivo não permitido no pacote	Confirme que selecionou o ZIP do modelo, com a estrutura original, e não o projeto completo ou arquivos adicionais.
Entrada duplicada ou pacote maior que 120 MiB	Utilize um pacote produzido pelo exportador compatível; não reempacote múltiplos modelos no mesmo ZIP.
Assinatura do modelo diverge dos metadados	O SHA-256 do ONNX não coincide com o JSON. Recopie o pacote original ou exporte outra saída válida; não edite o hash para contornar o erro.
Pré-processamento ou inferência divergente	O autoteste não passou. Preserve a mensagem e a identificação do aparelho e do pacote para investigação. Não trate o modelo recusado como validado.
Formato não reconhecido ou falha de leitura	Abra a imagem em um visualizador, confirme que o arquivo está disponível localmente e selecione um formato decodificável.
Imagem maior que 16 megapixels	Prepare uma cópia de dimensão menor antes de selecionar. Essa preparação não é realizada automaticamente pelo app.
Fotografia aparece girada ou esticada	Oriente a imagem antes da seleção e confira o enquadramento. O app não corrige EXIF e redimensiona a imagem inteira para um quadrado.

Situação	Conferência e ação
Botões temporariamente desabilitados	Aguarde o término da tarefa. O modo benchmark executa várias inferências e pode demorar mais que a análise única.
CSV não contém o rótulo recém-selecionado	Selecione a referência e execute novamente a análise ou o benchmark. Registros anteriores não são alterados retroativamente.
Resultados desapareceram ao reabrir	As medições pertencem à sessão em memória. Use um CSV já exportado; o modelo persistente e os registros temporários têm comportamentos diferentes.

Se aparecer *Não foi possível salvar o CSV*, escolha um destino acessível no seletor Android e confira o espaço disponível. A sessão continua precisando ser exportada enquanto estiver ativa.

Para relatar uma falha, registre a mensagem exata, fabricante e modelo do aparelho, versão do Android, versão do aplicativo e arquitetura/semente do pacote. Uma captura da tela pode auxiliar, desde que não exponha fotografias ou informações pessoais sem autorização.

A.12 ROTEIRO DE UMA SESSÃO DOCUMENTADA

1. Identifique aparelho, Android, versão do app e hash do modelo. Confirme o autoteste.
2. Defina previamente as imagens e a ordem de execução. Mantenha uma chave externa codificada para rastrear cada imagem.
3. Selecione a fotografia e aguarde a análise automática; registre que ela fica inicialmente sem referência.
4. Se houver rótulo conhecido, selecione-o e execute a etapa que será usada na coleta. Diferencie análise única de benchmark.
5. Aguarde a conclusão e confira a quantidade de registros. Não interprete as trinta repetições como trinta imagens independentes.
6. Exporte o CSV e confira a gravação. Ao agregar exportações, reconheça linhas repetidas por seu `id`.
7. Guarde o protocolo, os CSVs e a identificação dos arquivos associados. Separe a análise de desempenho computacional de uma avaliação classificatória ou clínica.

O manual descreve o comportamento implementado. As figuras apresentam esquemas dos fluxos e das regras do aplicativo. Capturas reais da versão correspondente podem complementar essa documentação, preservando os resultados e as informações exibidas.

APÊNDICE B – REPRODUTIBILIDADE E ORGANIZAÇÃO DOS ARQUIVOS

B.1 DISPONIBILIDADE DOS ARTEFATOS E IDENTIFICAÇÃO DA VERSÃO

O repositório público do projeto está disponível em <https://github.com/guilhevimu/sistema-suporte-psoriase>. A consulta utilizada nesta revisão corresponde ao commit `<f48fe3102f6bf7888f3bcdf6088010673897eca4>`, de 27 de outubro de 2026. A identificação de uma revisão permite relacionar a organização do acervo e os arquivos compartilhados à versão examinada, mesmo que novos materiais sejam acrescentados posteriormente.

Tabela 13 – Organização dos principais artefatos publicados no repositório

Artefato	Localização
Código de treinamento e avaliação	`<Pesquisa/rinha_modelos_v5.py>`
Separador e auditoria do acervo	`<Pesquisa/separador.py>`
Acervo de imagens	`<Pesquisa/Dataset/>`
Checkpoints por arquitetura e semente	`<resultados_publicos/checkpoints/>`
Gráficos e explicações	`<resultados_publicos/png/>`
Relatório do experimento	`<resultados_publicos/relatorio_final.html>`
APK e identificação da seleção	`<androidPsoraseApp/>`
Documentação em PDF	`<docs/>`

Fonte: Repositório do projeto, na revisão identificada.

Para reproduzir integralmente uma execução, os artefatos devem ser relacionados à configuração, às versões de software, ao manifesto das imagens e às regras de divisão correspondentes. Para reproduzir uma sessão móvel, também é necessário identificar o pacote ONNX importado, a versão do APK e o aparelho utilizado. Essa organização conecta a disponibilidade dos arquivos aos registros que permitem interpretar e repetir cada etapa.

B.2 IDENTIFICAÇÃO DO EXPERIMENTO

A execução de referência é a pasta <Resultados_Rinha_V5/20261022_151228_934149>. O arquivo <configuracao.json> registra as seis arquiteturas, as sementes 42, 123 e 2026, os parâmetros de treinamento, as versões de software e a assinatura dos dados. O arquivo <modelo_selecionado.json> identifica EfficientNet-B0, semente 2026, e o critério de validação utilizado.

O código-fonte associado ao processo é <rinha_modelos_v5.py>. A identificação registrada pelo relatório é:

<718cab1a042f60e5393d7886098d0491a632b9f5e47f9c330d8e5ef66939a7a7>

O pacote de documentação inclui uma cópia do script disponível para conferência. Sua identidade é registrada no arquivo de conferência; alterações futuras devem ter nova identificação. O código e seus parâmetros devem corresponder à execução utilizada nas tabelas, sem misturar versões do experimento.

B.3 ESTRUTURA DAS SAÍDAS

<csv/>

Manifesto de imagens, resultados individuais, resumo por arquitetura, checkpoints representativos, históricos, predições, matrizes, latências e recursos.

<png/>

Figuras de síntese, matrizes de confusão, recursos, curvas ROC, evolução de validação e painéis de explicabilidade.

<checkpoints/>

Pesos de cada arquitetura e semente. O selecionado para o aplicativo é <efficientnet_b0_s2026.pt>.

<dados/>

Resultados intermediários, mapas numéricos e descrições de classificação.

<logs/>

Registros de execução e eventuais erros.

<relatorio_final.html>

Síntese visual com figuras incorporadas, configuração e ambiente.

<resumo_final.txt>

Resumo textual das métricas e do estado das execuções.

As médias e os desvios entre sementes devem ser conferidos nos resultados agregados. Matrizes e curvas de checkpoints representativos não devem ser descritas como médias. A pasta de uma execução é a unidade de rastreabilidade: dados, configuração, pesos e relatório devem permanecer associados.

B.4 COMANDOS DE MANUTENÇÃO

Para o experimento já concluído, não é necessário executar novamente o separador. No diretório que contém o script, a verificação inicial pode ser acionada por

```
python rinha_modelos_v5.py --verificar
```

Para reconstruir apenas o relatório ou as explicações, substituir `PASTA_V5` pela pasta completa da execução:

```
python rinha_modelos_v5.py --so-relatorio "PASTA_V5"
python rinha_modelos_v5.py --so-explicabilidade "PASTA_V5"
```

A opção `-retomar` destina-se à continuação de uma execução compatível e exige consistência de dados, configuração, código e versões. Alterar a base ou os parâmetros não é mera atualização editorial do relatório: requer novo registro experimental.

B.5 COMPUTADOR E CELULAR: MEDIDAS DIFERENTES

No computador, o benchmark de rede temporiza forward e sigmoide com entrada preparada; a memória é RSS do processo Python. No Android, o forward inclui criação do tensor ONNX, execução e leitura da saída; a memória é PSS do processo do aplicativo. Os arquivos originais devem preservar essas definições. Uma comparação entre plataformas pode colocar as medidas lado a lado com seus escopos, mas não deve tratá-las como variáveis idênticas ou como consumo energético.

APÊNDICE C – RESULTADOS GRÁFICOS COMPLEMENTARES

As figuras deste apêndice foram extraídas sem alteração das imagens incorporadas no relatório final V5 anexado. As curvas ROC representam checkpoints escolhidos pela validação, enquanto os resumos entre sementes permanecem nas tabelas do capítulo de resultados.

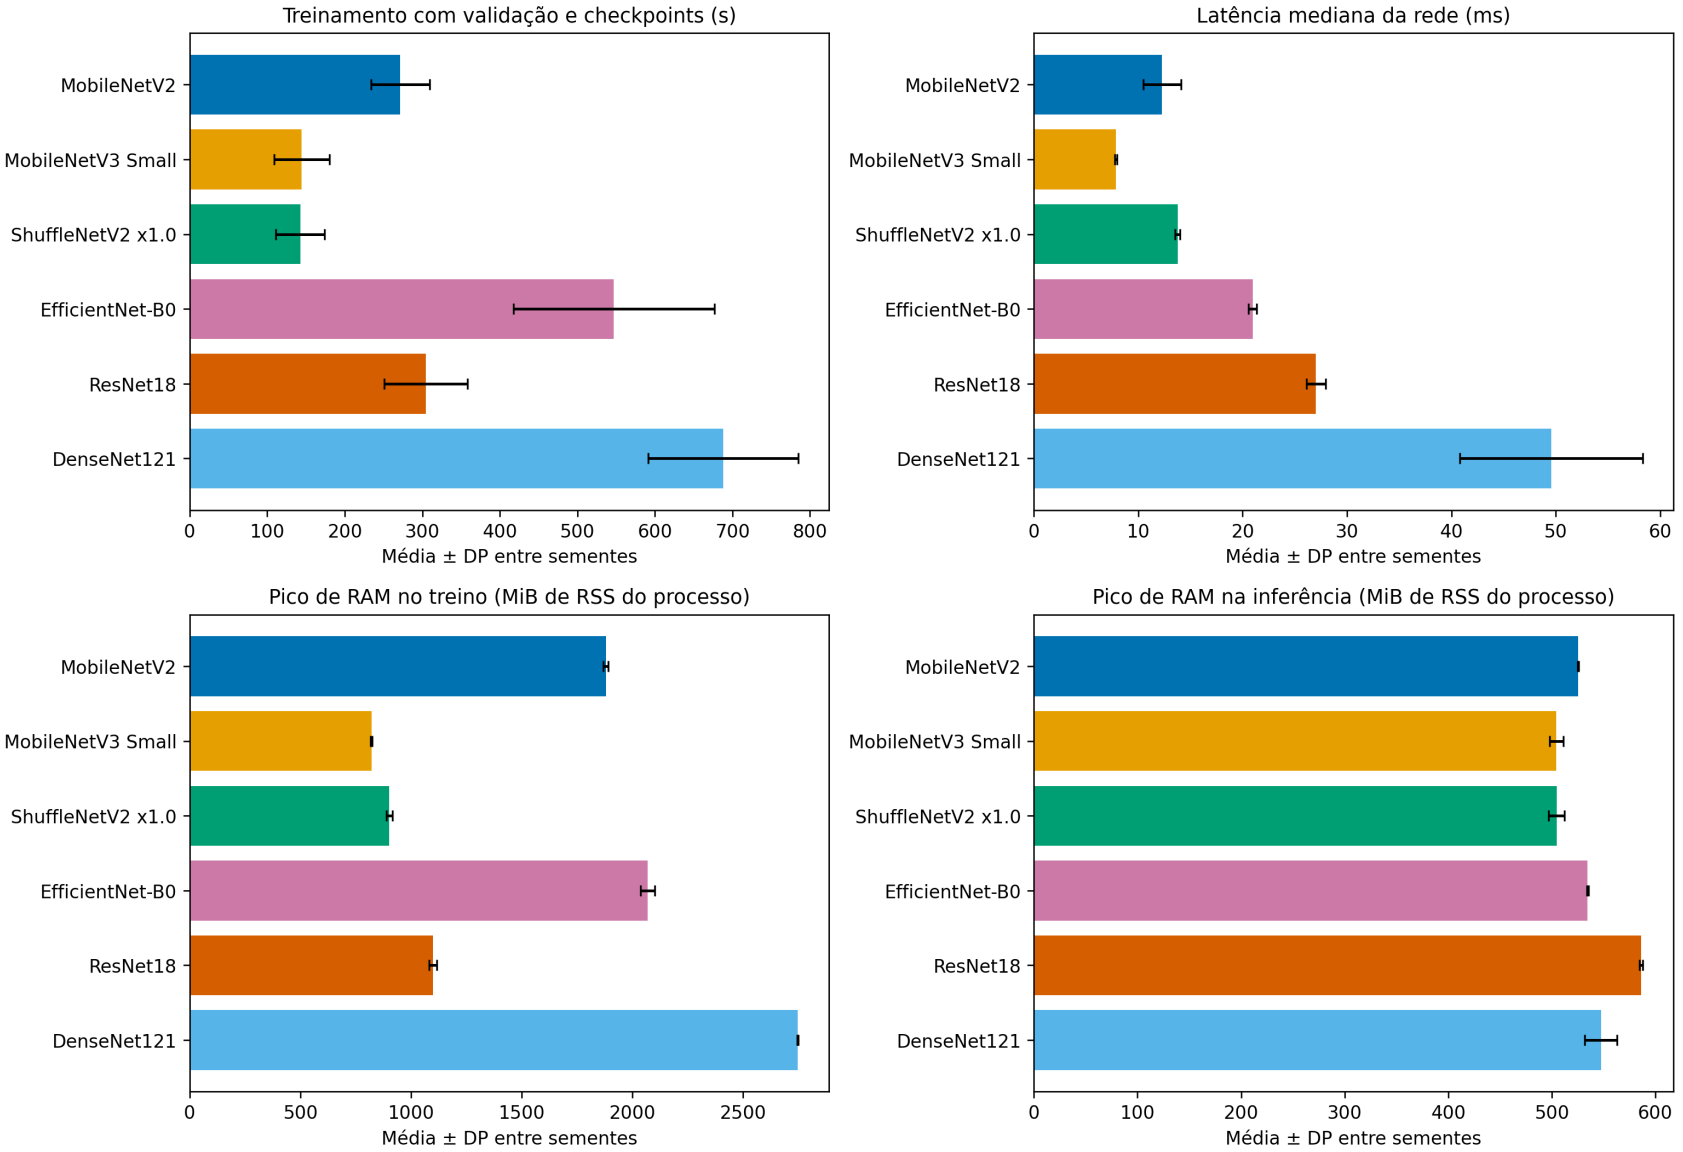


Figura 17 – Síntese de tempo e memória dos modelos no computador, apresentada em página girada para ampliar a leitura. Fonte: relatório V5.

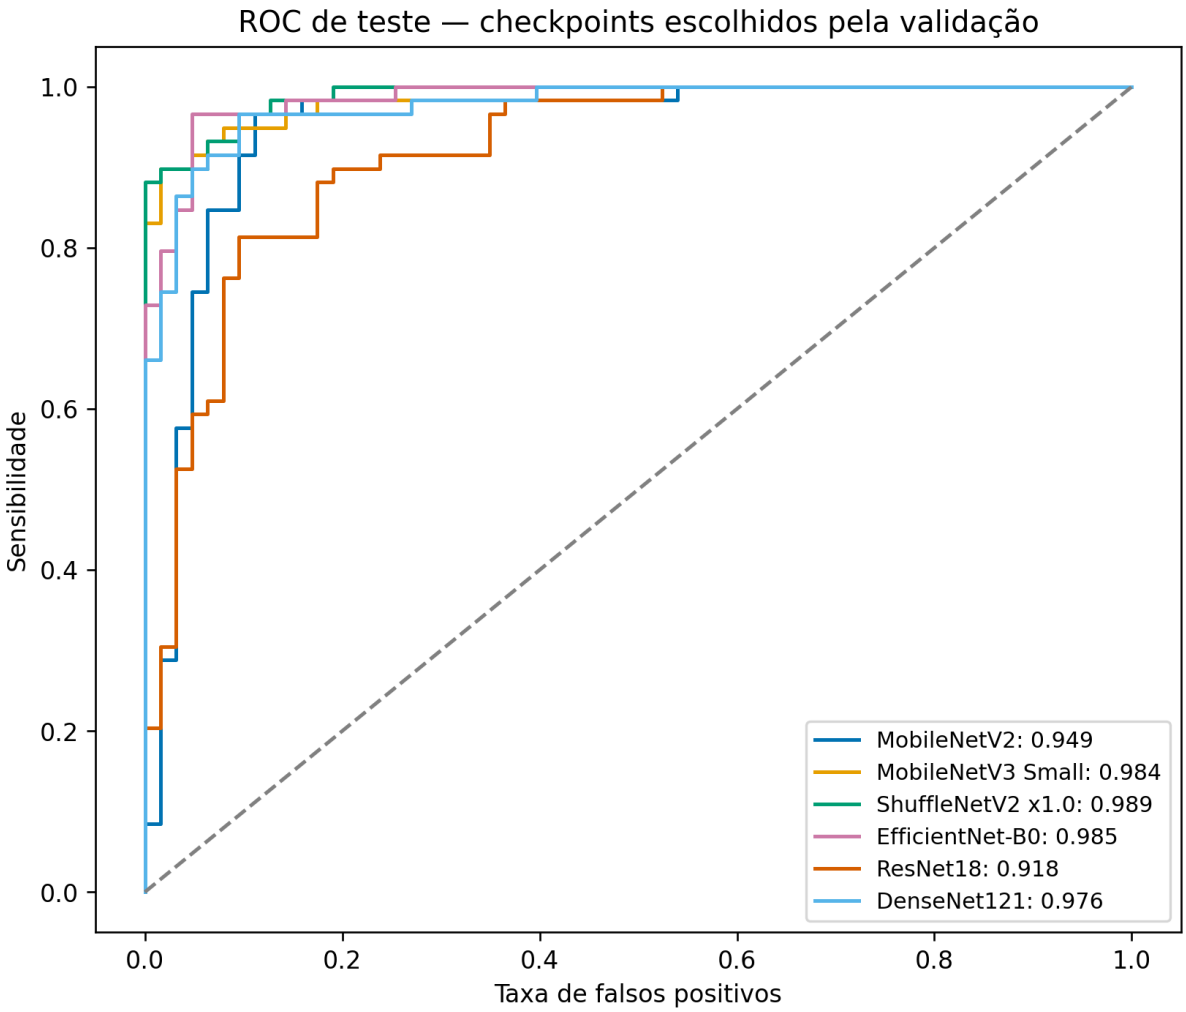


Figura 18 – Curvas ROC de teste dos checkpoints representativos escolhidos pela validação. AUCs individuais não devem ser confundidas com médias entre sementes. Fonte: Autor.

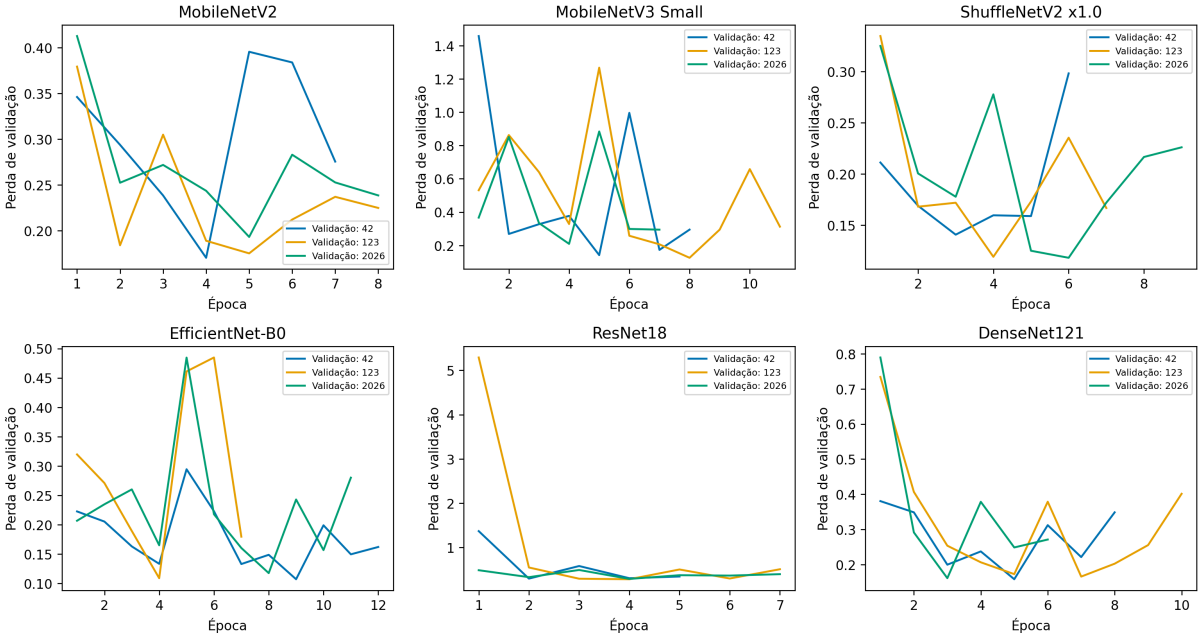


Figura 19 – Evolução de validação dos checkpoints apresentados pelo relatório. O checkpoint de cada execução é determinado pela menor perda de validação. Fonte: Autor.